TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Lê Hoàng Đạt

KHÔI PHỤC NHÃN DỮ LIỆU TRONG HỌC MÁY BỎ QUÊN THÔNG QUA TẤN CÔNG ĐẢO NGƯỢC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Lê Hoàng Đạt - 22127060

KHÔI PHỤC NHÃN DỮ LIỆU TRONG HỌC MÁY BỎ QUÊN THÔNG QUA TẤN CÔNG ĐẢO NGƯỢC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lê Kim Hùng

ThS. Trần Anh Duy

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Dưới sự hướng dẫn và hỗ trợ trong suốt quá trình thực hiện khóa luận tốt nghiệp từ hai thầy PGS.TS Lê Kim Hùng và thầy ThS.Trần Anh Duy, em đã tiến hành thực hiện đề tài này một cách nghiêm túc và có trách nhiệm. Công trình này là kết quả của quá trình tự nghiên cứu, tìm hiểu tài liệu, phân tích và thực nghiệm của chính em, không sao chép hay dựa vào bất kỳ sản phẩm nghiên cứu nào khác. Trong phần nội dung lý thuyết, nhóm có sử dụng một số nguồn tài liệu tham khảo và đã ghi rõ trong danh mục tài liệu cuối luận văn. Các số liệu và kết quả thu được trong quá trình thực hiện đều đảm bảo tính trung thực và độc lập, không trùng lặp cũng như có hình thức làm giả nào.

Lời cảm ơn

Lời đầu tiên, em xin bày tỏ lòng biết ơn chân thành đối với sự đồng hành, hướng dẫn và hỗ trợ tận tình trong suốt quá trình thực hiện khóa luận tốt nghiệp từ hai thầy PGS.TS Lê Kim Hùng và ThS. Lê Anh Duy. Với sự tận tâm, hai thầy đã cùng góp ý, định hướng nội dung và giúp em điều chỉnh cách tiếp cận phù hợp hơn với mục tiêu nghiên cứu. Những nhận xét và phản hồi từ hai thầy không chỉ giúp em hoàn thiện khóa luận về mặt nội dung và phương pháp mà còn góp phần nâng cao tư duy phân tích và cách trình bày kết quả một cách rõ ràng, logic hơn. Sự đồng hành của hai thầy là một phần quan trọng giúp em giữ vững định hướng và hoàn thành công việc đúng tiến độ.

Em cũng xin gửi lời cảm ơn đến Khoa Công nghệ Thông tin và các thầy cô giảng viên trong khoa, Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM, đã tạo điều kiện học tập thuận lợi, cung cấp kiến thức nền tảng và hỗ trợ nhóm trong suốt quá trình học tập và nghiên cứu.

Bên cạnh đó, em xin chân thành cảm ơn Quỹ Hỗ trợ Nghiên cứu Khoa học Trường Đại học Công nghệ Thông tin ĐHQG-HCM đã hỗ trợ em trong suốt thời gian thực hiện nghiên cứu. Em đã được tạo điều kiện sử dụng các trang thiết bị cần thiết như GPU phục vụ cho việc huấn luyện và thử nghiệm mô hình. Sự hỗ trợ này góp phần không nhỏ vào việc giúp em mở rộng phạm vi nghiên cứu và triển khai nhiều phương pháp khác nhau một cách hiệu quả. Em xin chân thành cảm ơn.

Đề cương chi tiết

fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

KHÔI PHỤC ĐẶC TRƯNG TRONG HỌC MÁY BỎ QUÊN THÔNG QUA TẤN CÔNG ĐẢO NGƯỢC

(Feature Recovery in Machine Unlearning via Inversion Attacks)

1. THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lê Kim Hùng (Trường Đại học Công nghệ Thông tin)
- ThS. Trần Anh Duy (Khoa Công nghệ Thông tin – Trường Đại học Khoa học Tự Nhiên)

Sinh viên thực hiện:

1. Lê Hoàng Đạt (MSSV: 22127060)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ *1/2026* đến *7/2026*

2. NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Độ nhạy cảm của dữ liệu đã trở thành một mối quan tâm hàng đầu trong kỷ nguyên kỹ thuật số, nơi thông tin ngày càng được thu thập, xử lý và phân phối trên toàn cầu [1, 3]. Mối quan tâm này càng trở nên sâu sắc hơn bởi sự phát triển nhanh chóng của Học máy (Machine Learning), bởi vì quá trình huấn luyện không chỉ đòi hỏi các tập dữ liệu khổng lồ mà còn khiến dữ liệu được ghi nhớ sâu hơn và khó bị xóa khỏi các mô hình đã được huấn luyện [2, 4]. Để đối phó với những lo ngại này, các quy định như Quy định chung về bảo vệ dữ liệu (GDPR) ở Liên minh Châu Âu, Đạo luật quyền riêng tư của người tiêu dùng California (CCPA) ở Hoa Kỳ và Đạo luật bảo vệ quyền riêng tư của người tiêu dùng (CPPA) ở Canada đã trao "quyền được lãng quên", cho phép các cá nhân yêu cầu xóa hoặc loại bỏ dữ liệu cá nhân của họ và cấm việc tiếp tục lưu trữ dữ liệu đó [3, 5]. Do đó, việc phát triển các giải pháp để xóa dữ liệu huấn luyện khỏi các mô hình đã được huấn luyện đã trở thành một nhu cầu cấp thiết nhằm bảo vệ quyền riêng tư của chủ sở hữu dữ liệu [2, 6].

Các kỹ thuật hủy học máy (Machine unlearning - MU) được thiết kế để loại bỏ có chọn lọc dữ liệu huấn luyện khỏi các mô hình đã được huấn luyện [2, 4, 6]. Trong MU, có hai mô hình tham gia vào quá trình hủy học; mô hình đã được huấn luyện ban đầu và mô hình đã qua quá trình hủy học [7, 9]. Các nghiên cứu hiện tại đã khẳng định rằng MU là một giải pháp công nghệ thiết yếu để đáp ứng các yêu cầu pháp lý và đảm bảo quyền được lãng quên của người dùng [2, 7]. Tuy nhiên, do các nghiên cứu gần đây đã chỉ ra rằng sự khác biệt về trọng số giữa các mô hình trước và sau khi hủy học là một ước lượng chính xác về

gradient của các mẫu đã bị hủy học, điều này khiến quá trình hủy học dễ bị tổn thương trước các cuộc tấn công dựa trên gradient [9, 18] . Trong số các cuộc tấn công này, Suy luận Phân phối Nhãn (Label Distribution Inference - LDI) đã nổi lên như một mối đe dọa lớn đối với quyền riêng tư của người dùng [10]. Mục tiêu chính của cuộc tấn công này là ước lượng chính xác số lượng mẫu đã bị hủy học trên mỗi lớp để suy luận ra các thông tin nhạy cảm. Ví dụ, việc trích xuất phân phối nhãn chẩn đoán từ hồ sơ chụp X-quang của một bệnh nhân cung cấp những hiểu biết nhạy cảm hơn về tình trạng y tế của họ so với việc chỉ khôi phục các hình ảnh gốc [10, 11].

2.2 Mục tiêu đề tài

Mặc dù đã có những tiến bộ đáng kể trong các nghiên cứu về LDI, nhưng những khoảng trống trong nghiên cứu vẫn còn tồn tại. Thứ nhất, các phương pháp hiện tại chủ yếu sử dụng dấu của các gradient để biểu diễn hướng nhằm phát hiện sự tồn tại của nhãn, cùng với độ lớn của chúng để suy luận tần suất nhãn [14]. Tuy nhiên, khi một mô hình hội tụ, độ lớn của các gradient giảm đi đáng kể và trở nên cực kỳ nhạy cảm với nhiễu dương, dẫn đến sự suy giảm trầm trọng về hiệu suất tấn công [14, 16]. Hạn chế này khiến các cuộc tấn công LDI hiện tại trở nên rất thiếu thực tế trong các kịch bản MU ở thế giới thực, vì MU về bản chất nhắm đến các mô hình đã được huấn luyện tốt và đã hội tụ [16.

Hơn nữa, các nghiên cứu LDI trước đây chủ yếu tập trung vào các khía cạnh đại số của các vector gradient. Ví dụ, các phương pháp tiếp cận như RLU [16] xây dựng một bài toán bình phương tối thiểu để ước lượng nhãn dựa trên các cập nhật cục bộ, nhưng lại gần như bỏ qua các đặc tính hình học của các gradient.

Các bằng chứng cho thấy rằng các đặc điểm hình học trong không gian nhiều chiều mang những thông tin quan trọng và có khả năng chống chịu cao liên quan đến những thay đổi trong dự đoán của mô hình [16, 21]. Do đó, do bỏ qua những đặc trưng hình học phong phú này, các phương pháp hiện tại đã thất bại trong việc khai thác trọn vẹn thông tin gradient bị rò rỉ, khiến cho hiệu quả tổng thể của các cuộc tấn công LDI tiên tiến nhất hiện nay về cơ bản vẫn còn yếu kém [21].

Được thúc đẩy bởi mong muốn giải quyết các hạn chế nêu trên, trong nghiên cứu này, chúng tôi đề xuất Suy luận Nhãn dựa trên Vector (Vector-based Label Inference - LDI), một khuôn khổ nhằm suy luận chính xác phân phối nhãn của các tập dữ liệu đã bị hủy học. Chúng tôi đạt được điều này bằng cách khai thác sự chênh lệch trong các độ lệch (bias) ở lớp cuối cùng của mô hình trước và sau quá trình hủy học, đồng thời tận dụng các đặc tính hình học của vector biến thiên này. Cụ thể hơn, cơ chế đề xuất hoạt động thông qua ba giai đoạn cốt lõi: thứ nhất, đo lường độ lệch dữ liệu thông qua phép chiếu hình học của vector; thứ hai, tính toán độ dài của các vector đại diện tương ứng cho từng lớp; và cuối cùng, phân tách sự đóng góp của từng vector đại diện đặc trưng cho lớp từ vector tổng hợp chung để xác định chính xác số lượng mẫu bên trong mỗi lớp.

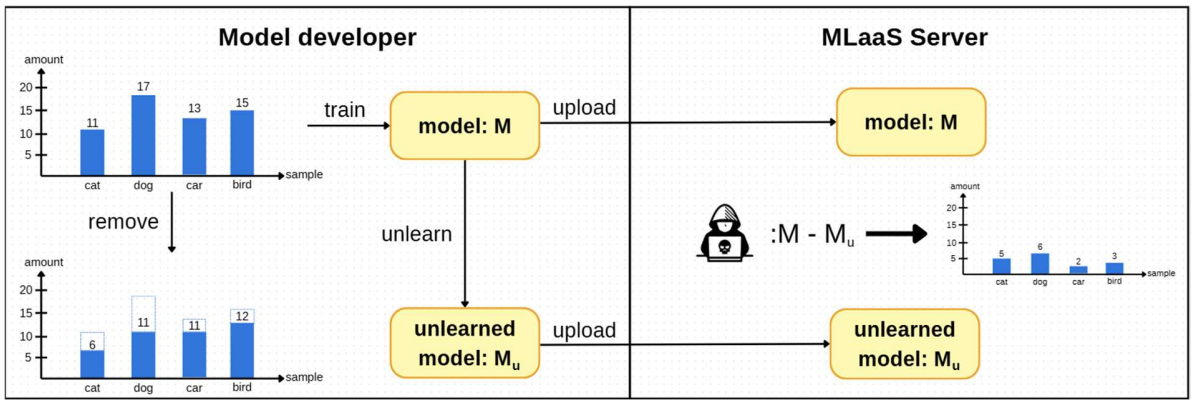
Những đóng góp của nghiên cứu này như sau:

- Chúng tôi đã cung cấp 1 giải pháp hiệu quả và toàn diện tận dụng thành công các ý nghĩa hình học của vector gradient để tấn công trên nhiều thuật toán hủy học (unlearning) khác nhau
- Chúng tôi đã tiến hành các thí nghiệm sâu rộng trên cả hai phương pháp hủy

học máy chính xác và xấp xỉ với nhiều kích thước lô (batch size) hủy học và các kiến trúc mô hình khác nhau, bao gồm MobileNet, ResNet18, CNN, trên các bộ dữ liệu CIFAR10 và CIFAR100 cũng như trên nhiều thuật toán hủy học khác nhau. Kết quả đã chứng minh hiệu quả của VLI trong việc hé lộ các thông tin riêng tư từ phần dữ liệu đã bị hủy học trong quá trình hủy học máy.

- Thông qua các thí nghiệm sâu rộng, chúng tôi chứng minh rằng VLI vượt trội hơn các phương pháp cơ sở (baselines) trên hai tập dữ liệu CIFAR10 và CIFAR100, đạt được mức cải thiện từ 10% đến 20% ở chỉ số được đánh giá. Chúng tôi cũng cung cấp một bản triển khai mã nguồn mở hoàn chỉnh, cho phép khả năng tái hiện kết quả và tạo điều kiện mở rộng nghiên cứu này cho các công trình trong tương lai.

2.3 Phạm vi của đề tài



Trong nghiên cứu này, chúng tôi xem xét mô hình Học máy như một Dịch vụ (Machine Learning as a Service - MLaaS), trong đó một nhà phát triển mô hình triển khai các mô hình đã được huấn luyện trước lên một Máy chủ MLaaS để

cung cấp các dịch vụ suy luận (inference services) cho người dùng cuối.

Học máy như một Dịch vụ (Machine Learning as a Service): Mô hình MLaaS là một thiết lập điện toán đám mây bao gồm ba thành phần tham gia chính: nhà phát triển mô hình, máy chủ MLaaS và người dùng cuối. Nhà phát triển mô hình sở hữu dữ liệu, huấn luyện mô hình hệ thống trên các tập dữ liệu riêng tư và triển khai chúng lên đám mây của máy chủ MLaaS. Khi có yêu cầu xóa dữ liệu, nhà phát triển sẽ chạy quá trình hủy học máy và tải lên mô hình hệ thống đã được cập nhật để thay thế mô hình cũ. Máy chủ MLaaS cung cấp cơ sở hạ tầng đám mây, tiếp nhận các mô hình này và cung cấp các API để truy cập từ bên ngoài. Cuối cùng, người dùng cuối sử dụng các API này để gửi dữ liệu và nhận về các dự đoán. Trong khi người dùng chỉ có quyền truy cập hộp đen (black-box access), nghĩa là họ chỉ nhìn thấy dữ liệu đầu vào của mình và đầu ra của mô hình, thì máy chủ MLaaS lại có quyền truy cập hộp trắng (white-box access) toàn diện vào tất cả các hoạt động bên trong của mô hình.

Trong mô hình mối đe dọa của chúng tôi, chúng tôi giả định máy chủ MLaaS đóng vai trò là một kẻ tấn công "trung thực nhưng tò mò" (honest-but-curious). Nó trung thực vì tuân thủ nghiêm ngặt tất cả các quy tắc triển khai và cập nhật mà không làm gián đoạn dịch vụ hoặc thay đổi cách thức hoạt động của mô hình. Tuy nhiên, nó tò mò vì thụ động thu thập, phân tích và so sánh các phiên bản khác nhau của mô hình để tái tạo lại thông tin riêng tư từ dữ liệu đã bị xóa (Hình 1). Kẻ tấn công này có toàn quyền truy cập vào các tham số bên trong của mô hình nhưng không thể nhìn thấy dữ liệu huấn luyện ban đầu. Cụ thể, kẻ tấn công biết chính xác các tham số của mô hình gốc trước khi hủy học, cũng như toàn bộ các tham số của mô hình đã được cập nhật sau yêu cầu xóa. Ngoài ra,

kẻ tấn công biết chính xác có bao nhiêu mẫu dữ liệu đã bị loại bỏ trong quá trình cập nhật, mặc dù chúng không biết nội dung thực tế hoặc nhãn thực của những mẫu đó.

Khả năng của kẻ tấn công: Vì kẻ tấn công sở hữu cả phiên bản gốc và phiên bản đã qua quá trình hủy học của mô hình, chúng có thể tiến hành một cuộc tấn công đảo ngược hủy học (unlearning inversion attack) bằng cách phân tích sự thay đổi của mô hình. Giả định rằng sự dịch chuyển trong các tham số của mô hình là do việc loại bỏ phần dữ liệu bị lãng quên, kẻ tấn công sẽ tính toán sự chênh lệch giữa hai mô hình. Sự chênh lệch tham số này đóng vai trò như một ước lượng về gradient của các mẫu đã bị hủy học, cho phép kẻ tấn công khai thác thông tin này.

Mục tiêu của kẻ tấn công và tiêu chí tấn công thành công: Trong các cuộc tấn công Suy luận Phân phối Nhãn (LDI) nhằm vào Hủy học máy, mục tiêu chính của kẻ tấn công là khám phá chính xác danh tính lớp (class identities) của dữ liệu bị lãng quên. Chính xác hơn, kẻ tấn công hướng tới việc tìm ra phân phối nhãn chuẩn xác của tập dữ liệu đã bị xóa. Để đo lường mức độ hiệu quả của cuộc tấn công, chúng tôi đánh giá tỷ lệ thành công của nó bằng cách so sánh tập hợp các nhãn mà kẻ tấn công dự đoán với các nhãn thực tế, chính xác của dữ liệu đã bị hủy học. Điểm độ chính xác càng cao đồng nghĩa với việc cuộc tấn công càng mạnh mẽ và thành công, cho thấy sự rò rỉ thông tin riêng tư càng nghiêm trọng.

2.4 Cách tiếp cận dự kiến

Cơ sở của lỗ hổng: Sự chênh lệch tham số giữa mô hình gốc và mô hình sau

khi hủy học tạo ra các ước lượng gradient chính xác. Kẻ tấn công lợi dụng các gradient này để dò ra nhãn của dữ liệu đã bị xóa.

Sự tiến hóa của các phương pháp tấn công và hạn chế:

- **Tấn công trên một mẫu duy nhất:**
    - *Cách hoạt động:* Lợi dụng tính chất gradient của lớp cuối cùng luôn hiển thị giá trị âm tại vị trí của nhãn đúng để tìm ra nhãn với độ chính xác 100% [12].
    - *Hạn chế:* Chỉ hoạt động được khi gradient xuất phát từ một mẫu dữ liệu duy nhất [12, 13].
- **Tấn công theo lô không có nhãn trùng:**
    - *Cách hoạt động:* Khôi phục nhãn cho cả một lô dữ liệu bằng cách tìm các giá trị gradient nhỏ nhất để giữ lại các dấu âm đặc trưng [14, 15].
    - *Hạn chế:* Sẽ thất bại hoàn toàn nếu trong lô dữ liệu có chứa các nhãn bị trùng lặp [14, 16].
- **Tấn công theo lô có nhãn trùng lặp:**
    - *Cách hoạt động:* ZLG [19] dùng dữ liệu giả để đếm số lần xuất hiện của nhãn. LLG và LLG+ [13] dựa vào mối tương quan giữa độ lớn của gradient và số lần xuất hiện của nhãn trong lô để tính toán.
    - *Hạn chế chung:* Hiệu suất tấn công bị suy giảm nghiêm trọng khi áp

dụng lên các mô hình đã hội tụ hoặc được huấn luyện quá tốt (well-trained models)[13, 16] .

- **Tấn công trên các mô hình đã hội tụ:**
    - *Cách hoạt động:* RLU [16] dự đoán nhãn bằng cách giải bài toán bình phương tối thiểu (least-square) liên kết nhãn thực với các cập nhật ở lớp đầu ra, giải quyết được cả bài toán nhãn trùng lặp và mô hình đã hội tụ.
    - *Hạn chế:* Rất thiếu tính thực tế trong các cuộc tấn công Hủy học máy ở thế giới thực vì sự thành công của nó phụ thuộc hoàn toàn vào việc phải có một tập dữ liệu phụ trợ (auxiliary dataset) để ước tính các tham số [16].

Quy trình của thuật toán VLI (4 bước):

- **Bước 1 - Ước lượng cơ sở:** Dựa trên giả định mô hình đã được huấn luyện rất tốt trước đó, thuật toán tính ra một giá trị gradient âm trung bình $\overline{g_{base}}$ đại diện cho các mẫu bị xóa.
- **Bước 2 - Kéo giãn thích ứng:** Để khắc phục tình trạng các tín hiệu âm bị che khuất trong các tập dữ liệu phân bố đều, VLI đánh giá độ lệch của dữ liệu hiện tại p_{max}và dùng một hệ số nhân γ để "phóng to" độ lớn của tín hiệu âm này lên g_{adj}, giúp nhận diện dễ dàng hơn.
- **Bước 3 - Xây dựng ma trận cơ sở:** Tận dụng tính chất "tổng các gradient

của một mẫu luôn bằng 0", thuật toán thiết lập một ma trận M .Mỗi hàng trong ma trận đại diện cho một "bản sắc" vector gradient của một lớp dự đoán (gồm một giá trị âm đặc trưng và các giá trị dương bù trừ được chia đều).

- **Bước 4 - Bóc tách lặp lại (Peeling):** Thuật toán bắt đầu với tổng độ lệch ΔB^L. Ở mỗi vòng lặp (với số vòng bằng số lượng mẫu bị xóa), nó tìm xem lớp nào có độ tương đồng cao nhất với độ lệch hiện tại. Khi tìm được nhãn đúng nhất, nó "bóc tách" (trừ đi) vector đại diện của nhãn đó ra khỏi tổng, rồi tiếp tục tìm kiếm ở phần dư còn lại cho đến khi đoán hết được toàn bộ nhãn của lô dữ liệu bị xóa.

2.5 Kết quả dự kiến của đề tài

Để đo lường định lượng tính hiệu quả của phương pháp VLI, chúng tôi đánh giá hiệu suất tấn công bằng cách sử dụng độ chính xác suy luận (inference accuracy). Chỉ số này được công thức hóa về mặt toán học như sau:

$$Accuracy = \frac{\hat{Y} \cap Y_{forget}}{n}$$

trong đó $\hat{Y}$ biểu thị tập hợp các nhãn ứng cử viên được trích xuất bởi thuật toán VLI, Y_{forget} biểu diễn tập hợp các nhãn thực (ground-truth labels) tương ứng với các mẫu trong lô dữ liệu đã bị hủy học (unlearned batch), và n là tổng kích thước của lô dữ liệu cần quên.

Mục tiêu đề tài bao gồm:

- **Hiệu quả vượt trội:** Phương pháp VLI chứng minh khả năng dự đoán cực kỳ chính xác phân phối nhãn của phần dữ liệu đã bị xóa chỉ bằng cách khai thác sự chênh lệch trọng số (ΔB^L) của mô hình.

- **Thiết lập tiêu chuẩn mới (State-of-the-Art):** VLI vươn lên trở thành phương pháp tiên tiến nhất, vượt xa các kỹ thuật cạnh tranh hiện có, đặc biệt là thể hiện sức mạnh trong các kịch bản hủy học máy xấp xỉ (approximate unlearning).

- **Cơ sở toán học vững chắc:** Sự thành công vượt trội này bắt nguồn từ những phân tích toán học chặt chẽ về hành vi của vector gradient. Bằng cách chuyển hóa thành công các giới hạn lý thuyết này thành một thuật toán "bóc tách thích ứng" (adaptive peeling), VLI đã tối ưu hóa được việc khai thác thông tin rò rỉ.

- **Mối đe dọa nghiêm trọng:** Nhờ những ưu điểm trên, VLI nổi lên như một trong những cuộc tấn công LDI (Suy luận Phân phối Nhãn) mạnh mẽ, bền bỉ và nguy hiểm bậc nhất trong bối cảnh hủy học máy hiện tại.

- **Khả năng tổng quát hóa cao (Generalization):** Các kết quả đánh giá cho thấy VLI không chỉ tối ưu cho một phương pháp đơn lẻ mà còn hoạt động cực kỳ hiệu quả và duy trì tính ổn định trên nhiều thuật toán hủy học máy cũng như các kiến trúc mô hình khác nhau. Điều này càng khẳng định tính thực tế và mức độ đe dọa diện rộng của phương pháp tấn công này.

2.6 Kế hoạch thực hiện

STT	Nội dung	Thời gian	Ghi chú
1	Trao đổi nhận chỉ dẫn từ giáo viên hướng dẫn	01/12/2025 - 7/12/2025	Đã xong
2	Hoàn thành Slide để chuẩn bị Thuyết Trình về các nội dung đã biết được về Machine Unlearning	08/12/2025 - 14/12/2025	Đã xong
3	So sánh với Inferring Class-Label Distribution in Federated Learning về phương pháp và ngữ cảnh	15/12/2025 - 21/12/2025	Đã xong
4	Tìm hiểu các công trình liên quan đến Label Distribution Inference	05/01/2026 - 11/01/2026	Đã xong
5	Đánh giá baseline	12/01/2026 - 18/01/2026	Đã xong
6	Đem các phương pháp trên lên môi trường Unlearning để report lại	19/01/2026 - 25/01/2026	Đã xong
7	"- Tìm hiểu lại cơ sở lí thuyết của phương pháp - Nhìn lại quá trình tạo non-probing samples xem có phát hiện không => Chỉ ra điểm hiệu quả của phương pháp non-	26/01/2026 - 01/02/2026	Đã xong

	probing samples so với phương pháp dùng probing samples - So sánh với các baseline trong ngữ cảnh Unlearning Approximate và Exact"		
8	- Đẩy phương pháp của mình cao hơn các phương pháp còn lại - Chạy các Reasearch Question 2 (RS1 là chứng minh hiệu quả trên nhiều tập) - Gắn thử AUX để xem hiệu quả so với những thằng còn lại - Tìm template khóa luận tốt nghiệp"	01/02/2026 – 07/02/2026	Đã xong
9	Viết báo cáo	Từ 07/02/2026 – 07/2026	Đang thực hiện

Tài liệu

[1] S. Garg, S. Goldwasser, and P. N. Vasudevan, “Formalizing Data Deletion in the Context of the Right to Be Forgotten,” in Lecture Notes in Computer Science, Cham: Springer International Publishing, 2020, pp. 373–402. Accessed: Apr. 06, 2026. [Online]. Available: https://doi.org/10.1007/978-3-030-45724-2_13

[2] L. Bourtoule et al., “Machine Unlearning,” arXiv.org. [Online]. Available: https://arxiv.org/abs/1912.03817

[3] Y. Xu, “Machine Unlearning for Traditional Models and Large Language Models: A Short Survey,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2404.01206

[4] A. Halimi, S. Kadhe, A. Rawat, and N. Baracaldo, “Federated Unlearning: How to Efficiently Erase a Client in FL?,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2207.05521

[5] J. Z. Di, J. Douglas, J. Acharya, G. Kamath, and A. Sekhari, “Hidden Poison: Machine Unlearning Enables Camouflaged Poisoning Attacks,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2212.10717

[6] A. Ginart, M. Y. Guan, G. Valiant, and J. Zou, “Making AI Forget You: Data Deletion in Machine Learning,” arXiv.org. [Online]. Available: https://arxiv.org/abs/1907.05012

[7] M. Chen, Z. Zhang, T. Wang, M. Backes, M. Humbert, and Y. Zhang, “When Machine Unlearning Jeopardizes Privacy,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2005.02205

[8] A. Ginart, M. Y. Guan, G. Valiant, and J. Zou, “Making AI Forget You: Data Deletion in Machine Learning,” arXiv.org. [Online]. Available: https://arxiv.org/abs/1907.05012

[9] H. Hu, S. Wang, T. Dong, and M. Xue, “Learn What You Want to Unlearn: Unlearning Inversion Attacks against Machine Unlearning,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2404.03233

[10] T. Cheng et al., “EC-LDA : Label Distribution Inference Attack against Federated Graph Learning with Embedding Compression,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2505.15140

[11] R. Shokri, M. Stronati, C. Song, and V. Shmatikov, “Membership Inference Attacks against Machine Learning Models,” arXiv.org. [Online]. Available: https://arxiv.org/abs/1610.05820

[12] B. Zhao, K. R. Mopuri, and H. Bilen, “iDLG: Improved Deep Leakage from Gradients,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2001.02610

[13] A. Wainakh et al., “User-Level Label Leakage from Gradients in Federated Learning,” arXiv.org. [Online]. Available: https://arxiv.org/abs/2105.09369

[14] K. Ma, Y. Sun, J. Cui, D. Li, Z. Guan, and J. Liu, “Instance-wise Batch Label Restoration via Gradients in Federated...,” OpenReview. [Online]. Available: https://openreview.net/forum?id=FIrQfNSOoTr

[15] H. Yin, A. Mallya, A. Vahdat, J. M. Alvarez, J. Kautz, and P. Molchanov, “See through Gradients: Image Batch Recovery via

GradInversion," arXiv.org. [Online]. Available: https://arxiv.org/abs/2104.07586

[16] H. Chen and H. Vikalo, "Recovering Labels from Local Updates in Federated Learning," arXiv.org. [Online]. Available: https://arxiv.org/abs/2405.00955

[17] A. Wainakh et al., "User-Level Label Leakage from Gradients in Federated Learning," arXiv.org. [Online]. Available: https://arxiv.org/abs/2105.09369

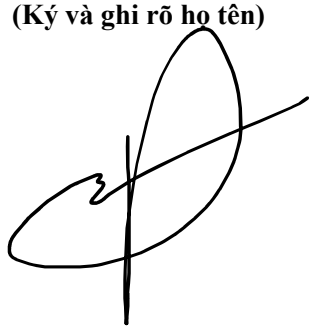
[18] L. Zhou and Y. Zhu, "Model Inversion Attack against Federated Unlearning," arXiv.org. [Online]. Available: https://arxiv.org/abs/2502.14558

[19] J. Geng *et al.*, "Towards General Deep Leakage in Federated Learning," arXiv.org. [Online]. Available: https://arxiv.org/abs/2110.09074

[20] A. Becker and T. Liebig, "Evaluating Machine Unlearning via Epistemic Uncertainty," arXiv.org. [Online]. Available: https://arxiv.org/abs/2208.10836

[21] J. Geiping, H. Bauermeister, H. Dröge, and M. Moeller, "Inverting Gradients -- How easy is it to break privacy in federated learning?," arXiv.org. [Online]. Available: https://arxiv.org/abs/2003.14053

XÁC NHẬN	**TP. Hồ Chí Minh, ngày 06 tháng 04 năm 2026**
CỦA NGƯỜI HƯỚNG DẪN	**NHÓM SINH VIÊN THỰC HIỆN**
(Ký và ghi rõ Họ tên)	**(Ký và ghi rõ họ tên)**



Lê Hoàng Đạt

YÊU CẦU VỀ HÌNH THỨC TRÌNH BÀY

- Nội dung phải được trình bày ngắn gọn, rõ ràng, mạch lạc, sạch sẽ, không được tẩy xóa, có đánh số trang, đánh số bảng biểu, hình vẽ, đồ thị.
- Font chữ Unicode: Times New Roman, kích thước (size) 13pt.
- Dãn dòng (line spacing) đặt ở chế độ 1.5 lines.
- Lề trên 3cm, dưới 3.5cm, trái 3.5cm, phải 2cm. Đánh số trang ở giữa bên dưới.
- Các bảng biểu trình bày theo chiều ngang khổ giấy thì đầu bảng là lề trái của trang.

Mục lục

Lời cam đoan **i**

Lời cảm ơn **ii**

Đề cương chi tiết **iii**

Mục lục **xxiii**

Tóm tắt **xxviii**

1 Giới thiệu **1**

1.1 Giới thiệu Machine Unlearning 1

1.2 Tấn công đảo ngược Gradient (Gradient Inversion attacks) 2

1.3 GIAs trong MU 2

1.4 Động lực nghiên cứu 3

1.5 Phương pháp đề xuất 4

1.5.1 Cách thức hoạt động của VLI 4

1.5.2 Điểm đổi mới của VLI 5

1.5.3 Đánh giá hiệu quả của VLI 5

1.5.4 Đóng góp của công trình 6

2 Các công trình nền tảng **7**

2.1 Machine Unlearning 7

2.2 Exact unlearning 9

2.3 Approximate unlearning 10

2.4 Gradient Inversion Attacks (GIAs) 12

2.5 Các công trình nghiên cứu về MU 13

2.5.1 Phương pháp huấn luyện lại từ đầu thuộc exact unlearning 13

2.5.2 Phương pháp SISA thuộc exact unlearning 14

2.5.3 Phương pháp NegGrad truyền thống thuộc approximate unlearning . . . 16
2.5.4 Phương pháp NegGrad+ thuộc approximate unlearning . . . 17
2.5.5 Phương pháp SCRUB thuộc approximate unlearning 18
2.5.6 Tóm tắt . . . 19
2.6 Các công trình nghiên cứu về GIAs tấn công khôi phục đặc trưng dữ liệu . . . 20
2.6.1 DLG và iDLG . . . 20
2.6.2 GradInversion . . . 21
2.7 Các công trình nghiên cứu về GIAs khôi phục mỗi nhãn . . 22
2.7.1 Phương pháp ZLG . . . 22
2.7.2 Phương pháp LLG và LLG+ . . . 23
2.7.3 Phương pháp RLG . . . 24
2.7.4 Phương pháp RLU . . . 25
2.8 Các công trình nghiên cứu áp dụng GIAs khôi phục dữ liệu và nhãn trong MU . . . 26
2.8.1 Unlearning Inversion Attacks . . . 26
2.9 Khoảng trống nghiên cứu . . . 28

3 Mô hình mối đe dọa 29
3.1 Machine Learning as a Service . . . 29
3.1.1 Vai trò và tri thức của kẻ tấn công . . . 30
3.1.2 Khả năng của kẻ tấn công . . . 31
3.1.3 Mục tiêu của kẻ tấn công và tiêu chí tấn công thành công . . . 31

4 Phương pháp đề xuất 32
4.1 Phát biểu bài toán . . . 32
4.2 Tầm quan trọng của dấu gradient . . . 33
4.3 Tầm quan trọng của sự mất cân bằng dữ liệu và phân phối non-IID . . . 35
4.4 Tầm quan trọng của trạng thái mô hình . . . 36
4.5 Vector-Based LDI (VLI) . . . 36

4.5.1 Giả định phân phối đều 37
4.5.2 Chi tiết thuật toán 37

5 Kết quả thực nghiệm **40**
5.1 Câu hỏi nghiên cứu 40
5.2 Thiết lập thực nghiệm 41
5.3 Thuật toán MU 42
5.4 Tinh chỉnh siêu tham số 43
5.5 Số đo đánh giá 43
5.6 Kết quả thực nghiệm trả lời cho câu hỏi nghiên cứu đầu tiên 44
5.6.1 Kết quả thực nghiệm NegGrad 44
5.6.2 Kết quả thực nghiệm trên các phương pháp MU khác 49
5.7 Kết quả thực nghiệm trả lời cho câu hỏi nghiên cứu thứ hai 51

6 Nghiên cứu loại bỏ **53**
6.1 Hiệu chỉnh siêu tham số alpha, beta 53
6.2 Đề xuất phương pháp phòng thủ bằng cách thêm một lượng noise vào cập nhật 55

7 Kết luận **57**
7.1 Kết quả đạt được của đề tài 57
7.2 Hạn chế của đề tài 58

Tài liệu tham khảo **59**

Danh sách hình

2.1 Mô tả mục tiêu của MU (tham khảo từ công trình của Xu, Heng và cộng sự [14]) 8
2.2 Mục tiêu của MU (tham khảo từ công trình của Xu, Heng và cộng sự [14]) 12
2.3 Toàn bộ phương pháp MU mà em tìm hiểu được 20

3.1 Tổng quan kiến trúc của cuộc tấn công GIAs nhằm khai thác nhãn trong môi trường MLaaS. Ở phía máy khách, nhà phát triển mô hình huấn luyện một mô hình ban đầu (M) trên tập dữ liệu đầy đủ, sau đó tải lên một mô hình (M_u) sau khi loại bỏ một tập hợp con dữ liệu cụ thể. Ở phía máy chủ, nhà cung cấp dịch vụ MLaaS độc hại, với lợi thế tiếp cận được ảnh chụp trạng thái của cả hai mô hình, sẽ tiến hành phân tích sự sai khác giữa hai phiên bản này để khôi phục nhãn thành công chính xác phân phối theo từng lớp của tập dữ liệu quên riêng tư. 29

4.1 Tổng quan các bước để triển khai cuộc tấn công của phương pháp VLI trải qua 5 giai đoạn khác nhau. 36

5.1 Mô tả quy trình MU bằng cách phân mảnh tập huấn luyện 42
5.2 Độ chính xác phục hồi nhãn iAcc của các phương pháp phục hồi nhãn khác nhau trên nhiều kích thước batch khác nhau trong thiết lập NegGrad. Các đường nét liền biểu thị hiệu suất tái cấu trúc của phương pháp VLI được đề xuất so với bốn phương pháp tấn công cơ sở trên ba cấu hình, bao gồm: MobileNetV2 trên SVHN, ResNet18 trên CIFAR-10, và ResNet18 trên CIFAR-100. 49

5.3 Biểu đồ biểu thị độ chính xác khôi phục nhãn iAcc trên nhiều phương pháp MU khác nhau bao gồm Scrub thuộc approximate unlearning, Retrain và Finetuning cùng thuộc exact unlearning. Nhìn chung các phương pháp đều giảm mạnh độ chính xác khôi phục nhãn trên tất cả các phương pháp này 50
5.4 Hình minh họa chi phí tính toán của từng phương pháp khôi phục nhãn trên các kiến trúc mô hình khác nhau dưới thiết lập NegGrad. Cụ thể, em đã đo lường chi phí tài nguyên thông qua số lượng phép tính dấu phẩy động (FLOPs) theo thang đo logarit và dung lượng bộ nhớ VRAM tiêu thụ tính bằng (MB) khi thực hiện các cuộc tấn công trên các mô hình đã được huấn luyện tốt được thảo luận ở phần trước. . . . 51

6.1 Thực hiện phòng thủ bằng cách thêm gausian noise vào trong gradient cập nhật mô hình. 55

Danh sách bảng

5.1 Kết quả thực nghiệm so sánh hiệu suất khôi phục nhãn giữa phương pháp VLI đề xuất và các phương pháp cơ sở phân tách theo các kịch bản cập nhật cục bộ. 45
5.2 Đánh giá hiệu năng của các cuộc tấn công khôi phục nhãn trong các cấu hình không đồng nhất dữ liệu khác nhau. . . 47

6.1 Đánh giá độ chính xác (iAcc và cAcc) của ResNet18 trên Cifar10 và Cifar100 khi thay đổi giá trị α và cố định $\beta = 30$. 53
6.2 Đánh giá iAcc và cAcc của ResNet18 trên CIFAR-10 và CIFAR-100 khi cố định $\alpha = 1$ và thay đổi β. Các kết quả tại $\beta \in \{0, 15, 30, 50\}$ của CIFAR-100 được thu thập từ thực nghiệm; các giá trị trung gian được ước lượng dựa trên các mốc thực nghiệm liền kề. 54

Tóm tắt

Trong kỷ nguyên số, các quy định quyền riêng tư thúc đẩy sự ra đời của Machine Unlearning nhằm xóa chọn lọc dữ liệu nhạy cảm . Tuy nhiên, sự biến động tham số trước và sau quá trình Machine Unlearning vô tình rò rỉ vết tích gradient của dữ liệu bị xóa, khiến hệ thống dễ bị tấn công đảo ngược gradient. Trong khi các nghiên cứu hiện tại tập trung vào khôi phục đặc trưng, hướng khôi phục nhãn thông qua các cuộc tấn công đảo ngược gradient lại bị bỏ ngỏ hoặc tốn chi phí tính toán lớn . Để khắc phục, đề tài phát triển phương pháp tấn công đảo ngược gradient tối ưu giúp ước tính chính xác phân phối nhãn dữ liệu bị xóa bỏ với chi phí cực thấp thông qua đề xuất thuật toán giải tích đột phá mang tên Suy luận nhãn dựa trên Vector, hoạt động bằng cách phân rã các đóng góp gradient từ lượng dịch chuyển định thiên ở lớp cuối cùng qua cơ chế kéo dãn thích nghi và bóc tách lặp động . Phương pháp được đánh giá thực nghiệm trên kiến trúc ResNet-18 và MobileNetV2 với bốn bộ dữ liệu chuẩn MNIST, SVHN, CIFAR-10 và CIFAR-100 trong bối cảnh giải học xấp xỉ NegGrad . Kết quả sau thực nghiệm cho thấy Suy luận nhãn dựa trên Vector vượt trội khi cải thiện độ chính xác cấp mẫu iAcc lên đến hơn 10% trong một số kịch bản tấn công trên phương pháp NegGrad truyền thống, đồng thời giảm lượng FLOPs và VRAM tiêu thụ về gần như bằng không . Nhờ đó, nghiên cứu đã làm rõ sự an toàn của các phương pháp unlearning hiện nay đối diện với tấn công đảo ngược gradient khôi phục nhãn, cung cấp công cụ kiểm thử rủi ro hiệu quả và thiết thực cho các dịch vụ học máy thực tế.

Chương 1

Giới thiệu

1.1 Giới thiệu Machine Unlearning

Bảo vệ dữ liệu nhạy cảm của người dùng đã trở thành một mối quan tâm hàng đầu trong kỷ nguyên kỹ thuật số, nơi thông tin ngày càng được thu thập, xử lý và phân phối trên phạm vi toàn cầu [1, 2]. Mối quan ngại này càng trở nên sâu sắc hơn do sự phát triển nhanh chóng của các hệ thống học máy, bởi quá trình huấn luyện không chỉ đòi hỏi các tập dữ liệu khổng lồ mà còn khiến dữ liệu bị ghi nhớ sâu hơn và khó xóa bỏ khỏi các mô hình đã được huấn luyện [2, 3, 4]. Để ứng phó với những lo ngại này, các quy định như Quy định chung về bảo vệ dữ liệu (GDPR) tại Liên minh Châu Âu [5] và Đạo luật quyền riêng tư của người tiêu dùng California (CCPA) tại Hoa Kỳ [6] đã ban hành "quyền được quên", cho phép người dùng yêu cầu các doanh nghiệp, tổ chức xóa bỏ hoặc gỡ bỏ dữ liệu cá nhân của họ [7, 8]. Nhằm đáp ứng các yêu cầu pháp lý này, các kỹ thuật Machine Unlearning (MU) đã được thiết kế để xóa bỏ một cách có chọn lọc dữ liệu huấn được luyện ra khỏi các mô hình đã được huấn luyện [9]. Về mặt kỹ thuật, quá trình này đòi hỏi các mẫu dữ liệu mục tiêu cùng với toàn bộ ảnh hưởng của chúng lên mô hình phải được xóa bỏ một cách nhanh chóng và triệt để ra khỏi cả tập dữ liệu huấn luyện lẫn cấu trúc tham số bên trong của mô hình [7, 10]. Đồng thời, một giải pháp MU hiệu quả không chỉ xóa đi ảnh hưởng của dữ liệu nhạy cảm đã huấn luyện mà còn phải bảo toàn tối đa hiệu năng và độ chính xác của mô hình đối với phần dữ liệu được giữ lại [11, 12]. Tóm lại, mục tiêu chính của MU là tạo ra một mô hình mới không có sự khác biệt so với mô hình được huấn luyện lại từ đầu mà không có dữ liệu cần xóa. Hiện nay các nghiên cứu đang chia các phương pháp MU ra làm 2 loại phổ biến là exact unlearning và approximate unlearning [7, 8, 13, 14].

1.2 Tấn công đảo ngược Gradient (Gradient Inversion attacks)

Tuy nhiên đi ngược lại với mục tiêu ban đầu của MU là bảo vệ quyền riêng tư của người dùng bằng cách ngăn chặn dữ liệu bị lưu lưu trữ và xử lí, nhiều nghiên cứu đã chứng minh rằng MU tồn tại các lỗ hỏng khiến cho dữ liệu của nạn nhân hoàn toàn có thể được khôi phục về đặc trưng và cả nhãn [15, 16]. Một trong những tấn công nhắm vào MU là tấn công đảo ngược gradient (GIAs). GIAs là nhóm tấn công xâm phạm quyền riêng tư nhắm vào việc khôi phục dữ liệu huấn luyện hoặc các thuộc tính nhạy cảm từ các thông tin về cập nhật mô hình được chia sẻ công khai [17, 18, 19]. Đã có nhiều công trình chỉ ra rằng nhóm tấn công này rất nguy hiểm trong các hệ thống học phân tán và học liên kết, nơi các bên tham gia trao đổi các tham số cập nhật hoặc gradient Δw thay vì dữ liệu thô với giả định rằng gradient là an toàn. Thật vậy, GIAs chứng minh gradient thực tế rò rỉ lượng thông tin khổng lồ và có thể bị khai thác để khôi phục chính xác đặc trưng của dữ liệu gốc và nhãn của dữ liệu đó. Các cuộc tấn công GIAs chủ yếu chia làm hai dạng, một dạng nhắm tới việc khôi phục đặc trưng của dữ liệu, dạng còn lại chỉ tập trung khôi phục nhãn của dữ liệu [15, 20].

1.3 GIAs trong MU

Trong khi đó, trong MU sự tồn tại song song của hai phiên bản mô hình trước và sau quá trình unlearn vô tình khiến cho MU trở nên nhạy cảm với các cuộc tấn công cho GIAs này [7, 21, 15]. Nghiên cứu trước đây đã chỉ ra rằng sự khác biệt giữa các tham số của mô hình gốc và mô hình sau khi xóa dữ liệu là một gradient sắp xỉ của phần dữ liệu bị xóa [15]. Việc rò rỉ ước tính gradient này khiến hệ thống MU trở nên vô cùng dễ bị tổn thương trước các cuộc tấn công GIAs, khi kẻ tấn công có thể áp dụng thuật toán dịch ngược gradient thành các đặc trưng gốc hoặc nhãn của dữ liệu bị xóa [15]. Mối đe dọa từ GIAs đã được chứng minh hoạt động hiệu quả trên approximate unlearning, trực tiếp đe dọa đến cam kết bảo mật cốt lõi của MU [15].

1.4 Động lực nghiên cứu

Mặc dù đã có các nghiên cứu chỉ ra sự khác biệt giữa hai mô hình trước và sau quá trình unlearn tạo ra một ước tính sắp xỉ cho gradient khiến cho MU trở nên dễ bị tấn công bởi GIAs, nhưng các nghiên cứu hiện tại chỉ dừng ở các cuộc tấn công nhắm vào việc khôi phục đặc trưng của dữ liệu mà chưa có các nghiên cứu về những cuộc tấn công GIAs tập trung vào khôi phục nhãn của dữ liệu trong MU. Mục tiêu chính của cuộc tấn công này là ước tính chính xác số lượng mẫu bị xóa bỏ của mỗi lớp nhằm suy diễn ra các thông tin nhạy cảm. Nguyên nhân cho sự thiếu vắng các nghiên cứu về các cuộc tấn công GIAs suy luận nhãn dữ liệu vì hiện tại các phương pháp khôi phục nhãn dữ liệu gặp 2 thách thức lớn trong ngữ cảnh MU. *Thách thức đầu tiên chính là MU chỉ thực sự có ý nghĩa và được đặt ra như một bài toán kỹ thuật khi mô hình đã học và ghi nhớ tốt các mẫu dữ liệu mục tiêu.* Tuy nhiên khi mô hình đã được huấn luyện tốt, nó sẽ trở nên đặc biệt nhạy cảm với các đặc trưng đầu vào [22]. Điều này có nghĩa là ngay cả một nhiễu loạn nhỏ cũng có thể làm thay đổi hoàn toàn kết quả dự báo của mô hình. Trong khi đó, các phương pháp tiên tiến nhất hiện nay (SOTA) lại phụ thuộc vào việc ước tính logits đầu ra hoặc các dự báo sau lớp softmax bằng cách sử dụng một tập dữ liệu phụ trợ [20, 23]. Do dự báo của mô hình có thể thay đổi nhanh chóng giữa các không gian đặc trưng khác nhau, một tập dữ liệu phụ trợ quy mô nhỏ không thể bao quát toàn diện các đặc trưng của tập dữ liệu. Hệ quả là việc phụ thuộc quá mức vào các ước tính từ những đặc trưng không tồn tại trong tập dữ liệu bị xóa sẽ dẫn đến sai số ước tính nghiêm trọng cho cuộc tấn công, đặc biệt là khi mô hình đã được huấn luyện tốt, điều mà thường xuất hiện trong MU [23]. Điều này khiến cho việc áp dụng các phương pháp tấn công GIAs hiện tại vào MU hiện nay vẫn còn khó khăn. *Thách thức thứ hai chính là trong MU, chỉ có mô hình trước và sau quá trình unlearn mới là thông tin dễ tiếp cận*[15, 24]. Tuy nhiên hiện nay các SOTA phụ thuộc nhiều vào tập dữ liệu phụ trợ, nơi mà có phân phối đặc trưng dữ liệu giống với dữ liệu đã được đem đi huấn luyện. Ngoài ra các phương pháp còn yêu cầu biết cả gradient chính xác của dữ liệu bị xóa và siêu tham số khác của quá trình xóa dữ liệu. Điều này khiến cho các phương pháp SOTA hiện tại trở

nên không khả thi khi áp dụng qua ngữ cảnh MU dẫn đến sự thiếu vắng các nghiên cứu đánh giá mối đe dọa của các phương pháp này trong MU.

1.5 Phương pháp đề xuất

Xuất phát từ động lực giải quyết các hạn chế nêu trên, trong nghiên cứu này, công trình của em đề xuất một khung thử nghiệm toàn diện nhằm đánh giá chính xác các tác động và mối đe dọa nghiêm trọng đối với quyền riêng tư của các cuộc tấn công GIAs suy luận nhãn trong môi trường MU, cùng với một phương pháp tấn công mới mang tên Vector-based Label Inference (VLI). Mục tiêu của phương pháp này là loại bỏ sự phụ thuộc vào các thông tin nghiêm ngặt và khó thu thập trong bối cảnh MU, chẳng hạn như các siêu tham số của quá trình unlearn hoặc dữ liệu phụ trợ. Điều này khiến cho phương pháp trở nên thực tế và dễ tiếp cận hơn. Ngoài ra, phương pháp còn được thiết kế giúp cho cuộc tấn công GIAs suy luận nhãn duy trì sự ổn định và hiệu quả cao kể cả khi mô hình được huấn luyện tốt, ngữ cảnh thực tế trong MU.

1.5.1 Cách thức hoạt động của VLI

VLI hoạt động chỉ dự trên sự khác biệt của mô hình trước và sau quá trình unlearn mà không cần phụ thuộc vào gradient chính xác. Cụ thể, VLI hoạt động dựa trên một lí thuyết các vector gradient tạo ra bởi các mẫu cùng một lớp tương đối giống nhau. Từ đó em đã thiết lập một ma trận biểu diễn vector gradient đại diện cho từng lớp và từng mẫu giống nhau khiến cho quá trình tấn công đơn giản hơn và giảm đi các yêu cầu về sức mạnh tính toán của phần cứng. Sau đó dựa trên hiện tượng chồng lấn vector gradient của các dữ liệu bị xóa và các quan sát về ảnh hưởng của độ lệch phân phối dữ liệu bị xóa để thiết lập nên một cơ chế kéo giãn, cải thiện việc mất thông tin và linh hoạt hơn với các cơ chế thích nghi với số lớp khác nhau và độ lệch dữ liệu khác nhau. Cuối cùng sau khi đã thành lập ma trận vector gradient cho các lớp và kéo giãn tránh mất thông tin, em đánh giá mức độ tác động của vector gradient của từng lớp lên vector gradient ước tính sinh ra bởi sự khác nhau của mô hình trước và sau quá

trình unlearn bằng cách thực hiện phép chiếu vector gradient ước tính lên các gradient của các lớp được thành lập trong ma trận vector gradient từ đó tìm ra lớp đã đóng góp vào vector gradient sắp xỉ trên. Sau đó vector gradient của lớp đó sẽ được bóc tách lặp và quá trình này sẽ diễn ra đến khi đạt được số lượng dữ liệu đã bị xóa đóng góp cho gradient để suy luận ra được số dữ liệu đã bị xóa mỗi lớp.

1.5.2 Điểm đổi mới của VLI

Điểm đổi mới của VLI là chỉ dựa vào gradient sắp xỉ có được từ sự khác nhau của mô hình trước và sau quá trình unlearn mà không phụ thuộc vào tập dữ liệu phụ trợ và gradient chính xác khắt khe giống phương pháp SOTA trước đây. Điều này khiến cho VLI trở nên vô cùng dễ áp dụng và khả thi hơn trong các điều kiện MU thực tế, khi việc truy cập vào các thông tin khác ngoài mô hình trước và sau là vô cùng khó khăn và phức tạp. Ngoài ra VLI còn có các cơ chế thích ứng số học đơn giản, khiến cho phương pháp vẫn duy trì được hiệu quả cũng như tốc độ tấn công trong nhiều điều kiện và thiết lập khác nhau đặc biệt là khi mô hình đã được huấn luyện tốt. Do đó, VLI yêu cầu lượng tài nguyên tính toán vô cùng ít so với các SOTA hiện nay dù vẫn duy trì được hiệu suất ở mức cao.

1.5.3 Đánh giá hiệu quả của VLI

Để kiểm chứng tính hiệu quả, VLI được thử nghiệm trên bốn bộ dữ liệu thông dụng, thường xuyên được sử dụng để huấn luyện mô hình và nghiên cứu gồm: CIFAR10, CIFAR100, MNIST, SVHN. Quá trình đánh giá tuân thủ các thiết lập mô hình mối đe dọa một cách nghiêm ngặt, không cho phép VLI truy cập các thông tin gì trong toàn bộ quá trình tấn công ngoại trừ mô hình trước và sau khi xóa bỏ dữ liệu và số lượng dữ liệu đã bị xóa. Hiệu suất được đo bằng hai chỉ số chính: độ chính xác ở mức dữ liệu đơn lẻ (iAcc) và độ chính xác ở mức lớp (cAcc) được định nghĩa ở phần 5.5. Sau đó, kết quả được so sánh với các phương pháp GIAs SOTA khác bao gồm ZLG, LLG và LLG+, RLU.

1.5.4 Đóng góp của công trình

Các đóng góp của công trình nghiên cứu này cụ thể như sau:

- Nghiên cứu là công trình đầu tiên chuẩn hóa và đánh giá một cách hệ thống các cuộc tấn công GIAs trích xuất mỗi nhãn dữ liệu bị xóa trong môi trường MU. Bằng việc thiết lập khung thử nghiệm này, em đánh giá các tác động nguy hiểm và mối đe dọa quyền riêng tư mà GIAs gây ra đối với dữ liệu bị xóa bỏ, từ đó trả lời cho khoảng trống quan trọng trong các nghiên cứu trước đây về tính bảo mật trong MU.

- Nghiên cứu đã đề xuất VLI, một phương pháp GIAs suy luận nhãn tối ưu hơn về hiệu suất và tính ứng dụng trong MU. Ưu điểm cốt lõi của VLI nằm ở tính thực tiễn cao khi loại bỏ hoàn toàn yêu cầu về thông tin tiên nghiệm nghiêm ngặt Bên cạnh đó, VLI khai thác các quan sát về các thuộc tính của vector gradient sắp xỉ và kết hợp các ảnh hưởng lên vector gradient đó gồm độ phân phối dữ liệu bị xóa và số lớp của tập dữ liệu. Nhờ đó, VLI mang lại chất lượng tấn công vượt trội và hiệu quả cao trong một số kịch bản hủy học thực tế.

- Thông qua các thực nghiệm khái quát đối với các kiến trúc mô hình tiêu biểu bao gồm ResNet18 và MobileNetV2, cùng các tập dữ liệu chuẩn như CIFAR-10, CIFAR-100, MNIST và SVHN, nghiên cứu đã chứng minh rằng VLI vượt trội hơn hẳn so với các baselines trong một số ngữ cảnh MU, đạt mức cải thiện lên đến hơn 10% đối với các chỉ số được đánh giá.

- Nghiên cứu cũng đã cung cấp cũng cung cấp mã nguồn mở hoàn chỉnh, cho phép tái lặp kết quả và mở rộng nghiên cứu này trong tương lai.

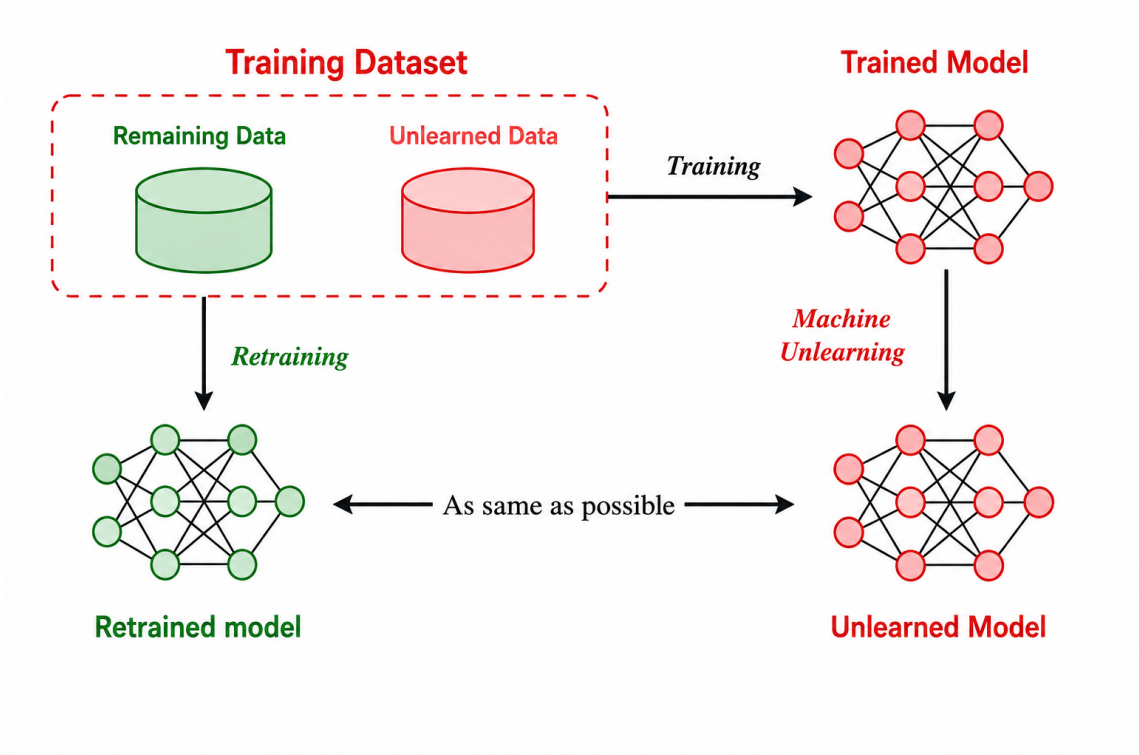
Chương 2

Các công trình nền tảng

2.1 Machine Unlearning

Machine Unlearning (MU), còn được gọi là xóa bỏ dữ liệu hoặc quên dữ liệu có chọn lọc hoặc làm sạch mô hình, là một quy trình kỹ thuật nhằm loại bỏ hoàn toàn và nhanh chóng ảnh hưởng của một nhóm dữ liệu cụ thể ra khỏi cấu trúc của một mô hình học máy đã được huấn luyện. Sự xuất hiện của khái niệm này bắt nguồn từ nhu cầu pháp lý thực tế khi các quy định bảo vệ dữ liệu nghiêm ngặt toàn cầu như Quy định chung về bảo vệ dữ liệu (GDPR) của Liên minh Châu Âu hay Đạo luật quyền riêng tư của người tiêu dùng California (CCPA) chính thức ban hành "quyền được quên". Chi tiết, "quyền được quên" cho phép người dùng rút lại sự đồng thuận và yêu cầu gỡ bỏ dữ liệu cá nhân của họ khỏi các hệ thống lưu trữ cũng như các mô hình trí tuệ nhân tạo được xây dựng từ dữ liệu cá nhân đó. Trong khi việc gỡ bỏ dữ liệu thô khỏi các cơ sở dữ liệu truyền thống ở phía máy chủ khá đơn giản, thì việc xóa bỏ tri thức đó trong các hệ thống học máy lại vô cùng phức tạp [2, 4, 25]. Điều này là do các mô hình học máy hiện đại, đặc biệt là các mạng thần kinh sâu, không chỉ học các đặc trưng chung mà còn có xu hướng ghi nhớ sâu sắc và nén các chi tiết của từng mẫu dữ liệu huấn luyện vào bên trong các trọng số của chúng. Nếu không có cơ chế MU triệt để, dữ liệu riêng tư của người dùng vẫn lưu vết trong trọng số mô hình và hoàn toàn có thể bị đánh cắp bởi kẻ tấn công thông qua các cuộc tấn công suy luận thành viên (MIA) hoặc tấn công đảo ngược mô hình [14, 26, 27].

Các nghiên cứu hiện nay cho rằng mục tiêu toán học tối cao của MU là biến đổi mô hình gốc sao cho mô hình sau khi xóa dữ liệu có phân phối đầu ra và tham số tương đồng nhất có thể với một mô hình lý được huấn luyện lại từ đầu mà chưa từng nhìn thấy dữ liệu cần xóa [25, 26, 28]. Do



Hình 2.1: Mô tả mục tiêu của MU (tham khảo từ công trình của Xu, Heng và cộng sự [14])

đó, giải pháp hiển nhiên nhất để đạt được mục tiêu này là huấn luyện lại mô hình từ đầu trên phần dữ liệu còn giữ lại, nhưng phương pháp này đòi hỏi chi phí tính toán và thời gian cực kỳ khổng lồ, đặc biệt đối với các mô hình lớn và phức tạp [7, 25, 29]. Do đó, các kỹ thuật MU hiện nay được thiết kế để thay đổi các trọng số hoặc lớp kích hoạt của mô hình một cách hiệu quả mà không cần phải thực hiện lại toàn bộ chu kỳ huấn luyện tốn kém. Tuy nhiên, quá trình MU phải đối mặt với nhiều thách thức kỹ thuật lớn do tính ngẫu nhiên của quy trình huấn luyện, nơi thứ tự của các batch dữ liệu được xáo trộn ngẫu nhiên khiến việc truy vết ảnh hưởng cực kỳ khó khăn [15, 28, 30]. Thêm vào đó, tính chất lũy tuyến của quá trình huấn luyện làm cho các cập nhật trọng số trên mẫu dữ liệu cũ tiếp tục ảnh hưởng dây chuyền đến hiệu năng của mô hình trên các mẫu dữ liệu nạp vào sau đó khiến cho việc truy vết và xóa dữ liệu gặp nhiều khó khăn, có thể khiến cho trọng số mô hình đã được huấn luyện bị thay đổi mạnh thậm chí sụp đổ [2, 28]. Ngoài ra, một thách thức nghiêm trọng khác là hiện tượng catastrophic forgetting xảy ra khi việc xóa bỏ quá nhiều dữ liệu hoặc xóa dữ liệu quá mạnh tay khiến hiệu năng dự đoán của mô hình bị

sụt giảm nghiêm trọng [14, 28, 31].

Ngoài mục đích bảo mật quyền riêng tư của người dùng, MU còn phục vụ nhiều ứng dụng quan trọng khác trong quản trị và tối ưu hóa hệ thống [11, 14]. Kỹ thuật này có thể được áp dụng để loại bỏ các đặc trưng thiên vị hoặc định kiến không mong muốn nhằm nâng cao tính công bằng của mô hình. Hơn thế nữa, nó cũng giúp giải quyết hiện tượng nhầm lẫn phân loại giữa các lớp bằng cách loại bỏ ảnh hưởng của các dữ liệu bị gán nhãn sai hoặc dữ liệu nhiễu. Đồng thời, MU cho phép gỡ bỏ các mẫu dữ liệu lỗi thời, các mẫu dữ liệu độc hại bị tiêm vào do tấn công đầu độc, hoặc các mẫu dị biệt để khôi phục độ chính xác và tính bền vững tổng thể cho mô hình. Hiệu quả của một quy trình MU thường được đánh giá đa chiều dựa trên ba yếu tố cốt lõi: tính triệt để trong việc xóa thông tin, tính bảo toàn chất lượng dự đoán trên dữ liệu giữ lại, và chi phí về mặt tài nguyên so với việc huấn luyện lại từ đầu [11, 32]. Sự thành công này phải được kiểm định gắt gao thông qua các cơ chế xác thực unlearning như feature injection test [33], đo lường xác suất lỗi dự đoán hoặc thực hiện các cuộc tấn công thử nghiệm để đảm bảo tác động của dữ liệu nhạy cảm thực sự biến mất [2]. Sự cân bằng tinh tế giữa hiệu năng xóa bỏ dữ liệu, độ chính xác của mô hình và chi phí lưu trữ, tính toán chính là bài toán trung tâm mà các nhà nghiên cứu trong lĩnh vực này liên tục tìm cách tối ưu hóa. Tóm lại, MU là một trụ cột công nghệ thiết yếu giúp chuyển đổi các hệ thống AI từ trạng thái tĩnh, ghi nhớ vĩnh viễn sang trạng thái động, có thể thích ứng linh hoạt và tôn trọng quyền kiểm soát dữ liệu cá nhân của con người [11, 13, 27, 28]. MU được nhiều nghiên cứu chia làm hai loại là exact unlearning và approximate unlearning [7, 14]

2.2 Exact unlearning

Exact unlearning là mục tiêu cốt lõi của MU, yêu cầu mô hình sau khi giải học phải loại bỏ một cách tuyệt đối và triệt để mọi dấu vết cũng như ảnh hưởng của tập dữ liệu cần xóa [16, 34]. Định nghĩa cốt lõi của exact unlearning thiết lập rằng phân phối xác suất của các mô hình được tạo ra từ thuật toán MU phải trùng khớp hoàn toàn với phân phối của mô hình lý tưởng được huấn luyện lại từ đầu trên tập dữ liệu giữ lại D_r. Về mặt

toán học, điều kiện này được biểu diễn thông qua sự đồng nhất về mặt phân phối giữa thuật toán huấn luyện $\mathcal{L}$ và thuật toán xóa bỏ dữ liệu $\mathcal{U}_{\mathcal{L}}$ trên không gian giả thuyết $\mathcal{H}$:

$$\Pr(\mathcal{L}(D_r)) = \Pr(\mathcal{U}_{\mathcal{L}}(D_{tr}, \mathcal{L}(D_{tr}), D_f))$$

trong đó D là tập dữ liệu ban đầu, D_f là tập cần xóa và $D_r = D \setminus D_f$ là tập dữ liệu giữ lại. Tổng quát hơn, đối với mọi tập con đo lường được $\mathcal{T}$ của không gian mô hình $\mathcal{H}$, đẳng thức sau phải được thỏa mãn:

$$P_{\mathcal{A}}(\mathcal{A}(D \setminus D_f) \in \mathcal{T}) = P_{\mathcal{A}}(\mathcal{U}(D, D_f, \mathcal{A}(D)) \in \mathcal{T})$$

với $\mathcal{A}$ là thuật toán huấn luyện và $\mathcal{U}$ là quy trình giải học.

Mục tiêu phân phối này có thể được xem xét dưới hai khía cạnh: sự đồng nhất trong không gian trọng số hoặc sự đồng nhất trong không gian kích hoạt đầu ra dự đoán [2, 13]. Do đó, phương pháp trực tiếp và hiển nhiên nhất để đạt được giải học chính xác là thực hiện huấn luyện lại mô hình từ đầu, tuy nhiên cách tiếp cận này tiêu tốn chi phí tính toán và thời gian cực kỳ khổng lồ đối với các mô hình học sâu phức tạp. Dù mang lại sự đảm bảo quyền riêng tư tuyệt đối trước các cuộc tấn công đảo ngược hay suy luận thành viên [14], việc thiết kế các thuật toán giải học chính xác hoạt động hiệu quả và tiết kiệm bộ nhớ trên các mạng thần kinh sâu phi tuyến phức tạp vẫn đang là một thách thức lớn trong thực tế [11, 14].

2.3 Approximate unlearning

Approximate unlearning là một hướng tiếp cận khác trong MU, được thiết kế để trực tiếp tinh chỉnh các tham số của mô hình hiện có nhằm loại bỏ ảnh hưởng của dữ liệu cần xóa mà không cần trải qua quy trình huấn luyện lại từ đầu cực kỳ tốn kém [11, 12, 13, 30]. Thay vì bắt buộc xóa hoàn toàn tác động của dữ liệu lên mô hình để đạt mức hoàn hảo, mục tiêu của giải học xấp xỉ là điều chỉnh trọng số mô hình sao cho hành vi của nó tiệm cận gần nhất với mô hình lý tưởng được huấn luyện lại từ đầu [11, 12]. Để định nghĩa ranh giới sai số toán học cho phép, các nghiên cứu

thường sử dụng khung lý thuyết của differential privacy để đưa ra khái niệm ϵ-certified removal [29, 32] thông qua công thức :

$$e^{-\epsilon} \leq \frac{P(\mathcal{A}(D \setminus \{x\}) \in \mathcal{T})}{P(\mathcal{U}(\mathcal{A}(D), D, x) \in \mathcal{T})} \leq e^{\epsilon}$$

trong đó $\mathcal{U}$ là cơ chế giải học, $\mathcal{A}$ là thuật toán học, D là tập dữ liệu ban đầu, x là mẫu dữ liệu cần quên, và $\mathcal{T}$ đại diện cho một tập con đo lường được của không gian giả thuyết $\mathcal{H}$. Công thức khẳng định rằng hành vi của hai mô hình này gần như trùng khớp hoàn toàn khiến cho kẻ tấn công không thể phân biệt được mô hình đã xóa dữ liệu và mô hình đã được huấn luyện lại từ đầu [11, 32].

Ngoài ra, định nghĩa xấp xỉ tổng quát hơn dựa trên tính không thể phân biệt (ϵ, δ)-indistinguishability [2, 16, 35] được biểu diễn bằng hệ bất đẳng thức song song:

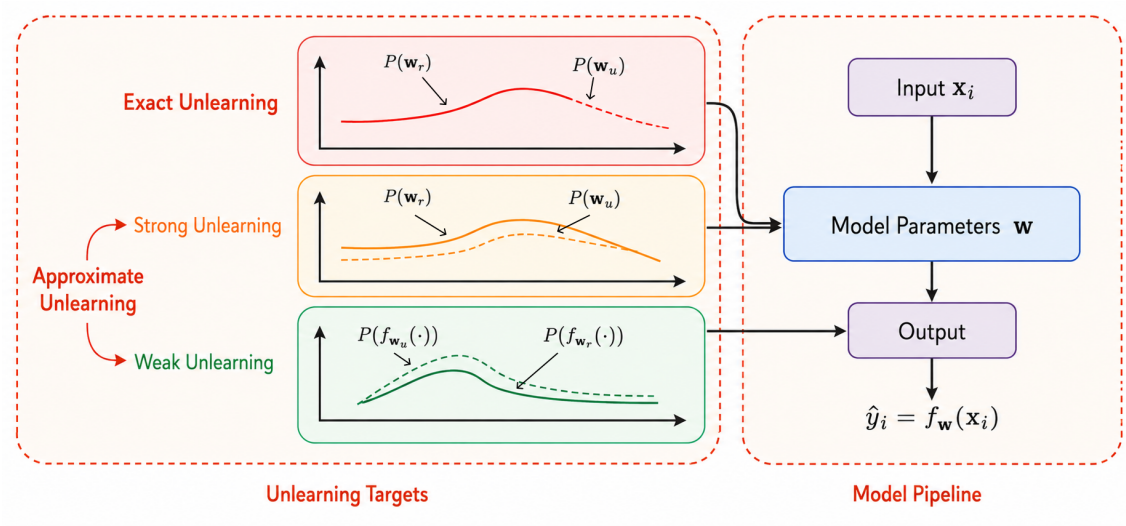
$$P(\mathcal{U}(\mathcal{A}(D), D, D_f) \in \mathcal{T}) \leq e^{\epsilon} P(\mathcal{A}(D \setminus D_f) \in \mathcal{T}) + \delta$$

$$P(\mathcal{A}(D \setminus D_f) \in \mathcal{T}) \leq e^{\epsilon} P(\mathcal{U}(\mathcal{A}(D), D, D_f) \in \mathcal{T}) + \delta$$

với D_f là tập quên và δ kiểm soát sai số xác suất nhỏ cho phép. Ý nghĩa cốt lõi của công thức là thừa nhận việc unlearning trong thực tế không cần phải đạt mức hoàn hảo tuyệt đối trong mọi tình huống, mà chỉ cần đảm bảo rằng đối với hầu hết mọi trường hợp thông thường, hai mô hình đã xóa dữ liệu và mô hình huấn luyện lại từ đầu hoạt động giống hệt nhau với tỷ lệ tin cậy cực kỳ cao [14, 31].

Nhóm phương pháp này thường được phân cấp thành hai hướng tiếp cận chính bao gồm Strong Unlearning nhắm vào việc so sánh độ tương đồng trong không gian trọng số của mô hình và Weak Unlearning chỉ yêu cầu sự tương đồng ở không gian kích hoạt đầu ra dự đoán [2, 14, 35].

Dù mang lại lợi thế vượt trội về tốc độ tính toán so exact unlearning, approximate unlearning vẫn đi kèm một rủi ro bảo mật tiềm ẩn do không thể loại bỏ hoàn toàn 100% ảnh hưởng của dữ liệu cần xóa [13, 11, 15]. Sự tồn tại ngầm của các đặc trưng dữ liệu cũ trong không gian trọng số xấp xỉ này chính là nguyên nhân khiến mô hình unlearn trở nên vô cùng nhạy



Hình 2.2: Mục tiêu của MU (tham khảo từ công trình của Xu, Heng và cộng sự [14])

cảm và dễ bị tổn thương trước các cuộc tấn công GIAs nhằm khôi phục lại trực quan hình ảnh nhạy cảm đã bị yêu cầu xóa hoặc nhãn của những dữ liệu đó [15, 36].

2.4 Gradient Inversion Attacks (GIAs)

Gradient Inversion Attacks đại diện cho một mối đe dọa nghiêm trọng đối với quyền riêng tư dữ liệu trong các hệ thống học máy [19, 37]. Dựa trên mục tiêu và cơ chế khai thác của kẻ tấn công, các cuộc tấn công này thường được phân chia thành hai nhóm chính với nguyên lý hoạt động khác nhau. Nhóm thứ nhất tập trung vào việc khôi phục các đặc trưng của dữ liệu thô nhạy cảm ban đầu. Nhóm này sử dụng thuật toán tối ưu hóa để giảm thiểu sai lệch giữa gradient giả lập và gradient thực tế nhằm tái tạo lại từng pixel ảnh hoặc từ ngữ gốc của dữ liệu [38, 39]. Hiện nay, đã có nhiều công trình nghiên cứu tiên phong chứng minh thành công mối nguy hiểm thực tế của nhóm tấn công khôi phục dữ liệu thô này trực tiếp trong bối cảnh MU [15]. Các nghiên cứu này chỉ ra rằng sự khác nhau tham số giữa mô hình gốc và mô hình sau khi xóa dữ liệu vô tình cung cấp một ước lượng gradient rất sát của dữ liệu bị xóa. Bằng cách khai thác hiệu số trọng số đó, kẻ tấn công có thể dễ dàng giải mã và dựng lại trực quan các hình ảnh nhạy cảm đã bị yêu cầu quên. Trái lại, nhóm thứ hai

của tấn công GIAs là các cuộc tấn công chuyên biệt chỉ dựa vào gradient để khôi phục nhãn phân tích. Các phương pháp này hoạt động bằng cách phân tích cấu trúc toán học của các gradient tại lớp kết nối đầy đủ cuối cùng để trích xuất nhãn mà không cần tối ưu hóa hình ảnh. Để xử lý các kịch bản thực tế phức tạp với kích thước batch lớn và nhãn trùng lặp, nhiều thuật toán tiên tiến như LLG [20], ZLG [1], iRLG [18] và RLU [23] đã lần lượt được đề xuất. Trong đó, iRLG thiết lập hệ phương trình tuyến tính từ embedding và xác suất hậu nghiệm để tính toán số lượng thực thể của mỗi lớp nhãn bằng thuật toán giả nghịch đảo Moore-Penrose [18]. Bên cạnh đó, thuật toán RLU vượt trội hơn khi giải bài toán bình phương tối thiểu từ mối tương quan giữa số lượng mẫu của từng nhãn và cập nhật của lớp đầu ra để đạt độ chính xác gần như tuyệt đối [23]. Tuy nhiên, khác với nhóm khôi phục đặc trưng dữ liệu thô, hiện nay vẫn đang hoàn toàn thiếu vắng các công trình nghiên cứu chuyên biệt về mối đe dọa chỉ khôi phục nhãn phân tích này trong bối cảnh MU. Sự thiếu hụt các nghiên cứu đánh giá rò rỉ nhãn từ sự khác nhau của mô hình trước và sau khi xóa dữ liệu vô tình tạo ra một lỗ hổng bảo mật lớn chưa được khám phá đầy đủ. Do đó, việc bổ sung các nghiên cứu về nguy cơ tấn công khôi phục nhãn loại hai trong các mô hình giải học là cực kỳ cấp thiết để đảm bảo an toàn thông tin toàn diện.

2.5 Các công trình nghiên cứu về MU

2.5.1 Phương pháp huấn luyện lại từ đầu thuộc exact unlearning

Một trong những phương pháp tiêu chuẩn để đạt được mục tiêu của MU là huấn luyện lại từ đầu [29, 32]. Phương pháp này hoạt động bằng cách loại bỏ hoàn toàn các mẫu dữ liệu cần xóa $\mathcal{D}_f$ khỏi tập dữ liệu huấn luyện gốc $\mathcal{D}$ [14, 34], sau đó chạy lại thuật toán huấn luyện $\mathcal{A}$ từ đầu trên phần dữ liệu giữ lại $\mathcal{D}_r = \mathcal{D} \setminus \mathcal{D}_f$ sử dụng cùng cấu trúc mạng và các siêu tham số huấn luyện ban đầu. Về mặt toán học, tham số của mô hình huấn luyện lại w_r được xác định thông qua việc tối thiểu hóa hàm mất mát trên tập dữ liệu giữ lại:

$$w_r = \mathcal{A}(\mathcal{D} \setminus \mathcal{D}_f)$$

Nhờ việc cách ly hoàn toàn dữ liệu cần xóa khỏi toàn bộ vòng đời huấn luyện, phương pháp này được coi là tiêu chuẩn để giải xóa dữ liệu khỏi mô hình [32]. Nó cung cấp một chứng chỉ quyền riêng tư hoàn hảo vì phân phối tham số của mô hình sau khi xóa dữ liệu sẽ trùng khớp tuyệt đối với mô hình lý tưởng chưa từng nhìn thấy dữ liệu đích [28]. Tuy nhiên, hạn chế lớn nhất của thuật toán huấn luyện lại từ đầu là chi phí tính toán và thời gian cực kỳ khổng lồ.

- **Gánh nặng tài nguyên:** Đối với các mô hình học sâu phức tạp, như ResNet-50 hoặc các mô hình ngôn ngữ lớn, huấn luyện trên các tập dữ liệu quy mô lớn, việc chạy lại toàn bộ đường dẫn tối ưu hóa có thể tốn từ vài ngày đến vài tuần và tiêu thụ lượng tài nguyên phần cứng vô cùng đắt đỏ.

- **Ràng buộc lưu trữ:** Phương pháp này bắt buộc nhà phát triển phải lưu trữ liên tục toàn bộ tập dữ liệu gốc [30]. Điều này thường bất khả thi trong môi trường Học liên kết hoặc các kịch bản Machine Learning as a Service nơi dữ liệu thô không được phép lưu trữ lâu dài do các ràng buộc pháp lý nghiêm ngặt về quyền riêng tư.

2.5.2 Phương pháp SISA thuộc exact unlearning

Nhằm hiện thực hóa mục tiêu giải học chính xác mà không phải gánh chịu chi phí tính toán quá lớn từ việc huấn luyện lại toàn bộ mô hình giống phương pháp huấn luyện lại từ đầu, Bourtoule và các cộng sự [28] đã đề xuất phương pháp SISA trong nghiên cứu tiên phong. Bản chất của SISA là một khung giải học dựa trên nguyên lý phân hoạch dữ liệu, giúp cô lập tầm ảnh hưởng của từng điểm dữ liệu đơn lẻ trong quá trình học, từ đó giảm thiểu tối đa phạm vi và thời gian retraining khi có yêu cầu xóa dữ liệu.

Quy trình vận hành của SISA được cấu thành từ bốn giai đoạn cốt lõi:

- **Phân mảnh:** Tập dữ liệu gốc $\mathcal{D}$ ban đầu được chia ngẫu nhiên và đồng đều thành S phân mảnh các tập dữ liệu không giao nhau ($\{\mathcal{D}_1, \mathcal{D}_2, \ldots, \mathcal{D}_S\}$). Trên mỗi phân mảnh này, một mô hình thành phần sẽ được huấn luyện hoàn toàn biệt lập. Việc không chia sẻ

gradient hay thông tin tham số giữa các phân mảnh đảm bảo rằng tầm ảnh hưởng của một mẫu dữ liệu bất kỳ chỉ giới hạn nghiêm ngặt bên trong mô hình thành phần duy nhất chứa nó.

- **Lát cắt (Slicing):** Nhằm tối ưu hóa hơn nữa tài nguyên tính toán, dữ liệu trong mỗi mảnh $\mathcal{D}_k$ tiếp tục được chia nhỏ thành R lát cắt tích lũy tuần tự ($\{\mathcal{D}_{k,1}, \mathcal{D}_{k,2}, \ldots, \mathcal{D}_{k,R}\}$). Quá trình huấn luyện diễn ra theo phương thức lũy tiến và ghi lại các điểm kiểm tra tham số trung gian. Cụ thể, mô hình ban đầu được khởi tạo ngẫu nhiên và huấn luyện trên lát cắt đầu tiên $\mathcal{D}_{k,1}$ trong e_1 epochs để lưu lại checkpoint $M_{k,1}$. Ở bước kế tiếp, mô hình $M_{k,1}$ tiếp tục được huấn luyện trên tập dữ liệu tích lũy $\mathcal{D}_{k,1} \cup \mathcal{D}_{k,2}$ trong e_2 epochs để thu được checkpoint $M_{k,2}$. Tiến trình này lặp lại liên tục cho đến lát cắt cuối cùng R, mang lại mô hình hoàn chỉnh M_k.

- **Hợp nhất:** Trong giai đoạn suy luận, các truy vấn từ người dùng sẽ được gửi đồng thời đến toàn bộ S mô hình thành phần. Kết quả dự đoán cuối cùng của hệ thống sẽ được tổng hợp thông qua cơ chế biểu quyết đa số hoặc tính trung bình cộng các vector xác suất đầu ra từ các mô hình này.

- **Giải học:** Khi nhận được yêu cầu xóa một mẫu dữ liệu d_u, hệ thống sẽ lập tức định vị chính xác mẫu đó thuộc phân mảnh $\mathcal{D}_k$ và lát cắt $\mathcal{D}_{k,u}$ nào. Thay vì phải huấn luyện lại toàn bộ hệ thống, SISA chỉ cần thu hồi lại checkpoint liền trước đó là $M_{k,u-1}$, thời điểm trước khi lát cắt chứa d_u được nạp vào, và tái khởi động quá trình huấn luyện lũy tiến từ bước thứ u với lát cắt đã loại bỏ mẫu dữ liệu ($\{\mathcal{D}_{k,u} \setminus \{d_u\}\}$). Toàn bộ $S-1$ phân mảnh còn lại được giữ nguyên vẹn 100%, giúp tiết kiệm đáng kể thời gian xử lý.

Để đảm bảo tổng thời gian huấn luyện lũy tiến khi áp dụng kỹ thuật chia lát cắt tương đương với thời gian huấn luyện thông thường, số lượng epoch tích lũy e được hiệu chỉnh chặt chẽ theo công thức:

$$e = \frac{R+1}{2R} e'$$

Trong đó, e' đại diện cho số lượng epoch huấn luyện gốc khi không phân chia lát cắt. Bên cạnh đó, hiệu năng thực tế của cơ chế giải học tuần tự cũng được chứng minh thông qua giá trị kỳ vọng về số lượng mẫu dữ liệu cần phải xử lý lại, tính toán bằng hệ thức:

$$E[C] = \left(\frac{S}{N} + \frac{2}{S} - 1\right) K - \frac{2}{S}K^2$$

Với N là kích thước của tập dữ liệu ban đầu, S là số lượng phân mảnh, và K biểu thị tổng số lượng yêu cầu giải học được gửi đến hệ thống.

2.5.3 Phương pháp NegGrad truyền thống thuộc approximate unlearning

Khác với hai phương pháp trên NegGrad [26] là phương pháp MU cập nhật trực tiếp trọng số mô hình giúp giảm tài nguyên huân luyện. Mục tiêu chính của NegGrad là tối đa hóa hàm mất mát trên tập dữ liệu cần xóa. Về mặt nguyên lý, nếu quá trình huấn luyện thông thường áp dụng thuật toán gradient descent để tối thiểu hóa hàm mất mát trên toàn bộ tập dữ liệu, thì NegGrad thực hiện quy trình tinh chỉnh bằng cách cập nhật tham số mô hình đi cùng hướng với gradient trên tập dữ liệu cần quên $\mathcal{D}_f$. Hành động này bản chất là thuật toán gradient ascent, cố tình tối đa hóa hàm mất mát nhằm phá hủy năng lực nhận diện và dự đoán của mô hình đối với các mẫu dữ liệu nhạy cảm cần xóa.

Dù rất dễ cài đặt và giúp tỷ lệ lỗi trên tập cần xóa tăng lên nhanh chóng, NegGrad truyền thống lại bộc lộ ba hạn chế nghiêm trọng về cả bảo mật lẫn hiệu năng:

- **Hiện tượng "ghost memory":** Tri thức thực chất chỉ bị che giấu tạm thời ở lớp đầu ra chứ chưa bị xóa khỏi không gian trọng số sâu. Khi đánh giá bằng thước đo thời gian học lại, mô hình sau khi xóa dữ liệu bằng NegGrad có thể nhanh chóng phục hồi hiệu năng hoàn hảo trên $\mathcal{D}_f$ chỉ sau vài bước tinh chỉnh ngắn [26].

- **Hiệu ứng Streisand:** Việc ép mô hình quên một cách thô bạo khiến phân phối xác suất dự đoán của các mẫu bị xóa trở nên dị biệt so

với mô hình chưa từng nhìn thấy dữ liệu đó. Sự bất thường này vô tình làm nổi bật các mẫu cần xóa, giúp kẻ tấn công dễ dàng nhận diện chúng thông qua các cuộc tấn công suy luận thành viên [26].

- **Phá hủy độ chính xác tổng thể:** Do chỉ tập trung leo dốc gradient trên $\mathcal{D}_f$ mà không có cơ chế ràng buộc để bảo vệ dữ liệu giữ lại $\mathcal{D}_r$, NegGrad gây ra hiện tượng quên thảm họa, làm sụt giảm nghiêm trọng độ chính xác của mô hình trên phần dữ liệu còn lại [11, 26].

2.5.4 Phương pháp NegGrad+ thuộc approximate unlearning

Để khắc phục nhược điểm phá hủy độ chính xác tổng thể mô hình của NegGrad phía trên, phương pháp cải tiến NegGrad+ đã được đề xuất bởi Kurmanji và các cộng sự [11] nhằm thiết lập trạng thái cân bằng giữa việc loại xóa dữ liệu cũ và duy trì hiệu năng hoạt động trên dữ liệu giữ lại . NegGrad+ thực hiện tối ưu hóa đồng thời hai mục tiêu trái ngược nhau trong cùng một hàm tổn thất kết hợp, áp dụng gradient descent trên tập dữ liệu giữ lại $\mathcal{D}_r$ để duy trì độ chính xác và khả năng tổng quát hóa, đồng thời duy trì gradient ascent trên tập dữ liệu cần quên $\mathcal{D}_f$ để xóa bỏ tri thức nhạy cảm.

Hàm mất mát tổng quát dùng để cập nhật trọng số w của mô hình trong quy trình NegGrad+ được định nghĩa chặt chẽ như sau:

$$\mathcal{L}(w) = \beta \cdot \frac{1}{|\mathcal{D}_r|} \sum_{i=1}^{|\mathcal{D}_r|} \ell(f(x_i; w), y_i) - (1 - \beta) \cdot \frac{1}{|\mathcal{D}_f|} \sum_{j=1}^{|\mathcal{D}_f|} \ell(f(x_j; w), y_j)$$

Trong đó, $\ell(\cdot)$ đại diện cho hàm mất mát tác vụ tiêu chuẩn thường là Cross-Entropy loss, và $\beta \in [0, 1]$ là siêu tham số điều phối sự đánh đổi giữa việc bảo toàn độ chính xác của dữ liệu giữ lại với mức độ giải học trên dữ liệu quên.

Trong triển khai thực tế, siêu tham số β vô cùng nhạy cảm và buộc phải thiết lập ở mức rất sát 1. Nếu cấu hình β quá nhỏ, đồng nghĩa với việc tăng trọng số cho nhánh gradient ascent, hàm tổn thất của mô hình sẽ lập tức bị bùng nổ chỉ sau vài bước lặp, khiến mô hình mất hội tụ.

Các đánh giá thực nghiệm trên các mạng sâu tiêu biểu như ResNet-18

trên tập CIFAR-10 chỉ ra rằng mặc dù NegGrad+ bảo vệ dữ liệu giữ lại tốt hơn NegGrad truyền thống, nó vẫn gây ra sự sụt giảm độ chính xác trên tập kiểm thử lớn hơn đáng kể so với các phương pháp MU tiên tiến khác như SCRUB, đồng thời khả năng xóa dữ liệu của phương pháp này cũng kém ổn định và kém nhất quán qua các thiết lập kịch bản khác nhau [11].

2.5.5 Phương pháp SCRUB thuộc approximate unlearning

SCRUB là một phương pháp khác được đề xuất bởi Kurmanji và các cộng sự (2023) từ Đại học Warwick và Google DeepMind trong nghiên cứu tiên phong [11], SCRUB đại diện cho một bước tiến đột phá trong nhóm các phương pháp approximate unlearning. Khác với các hướng tiếp cận trước đây vốn dựa trên các giả định ràng buộc phi thực tế về không gian trọng số làm hạn chế khả năng mở rộng trên mô hình lớn, SCRUB tiếp cận bài toán bằng một cơ chế giáo viên - học sinh chọn lọc hoàn toàn mới. Phương pháp này được chứng minh là đạt hiệu năng tối ưu và nhất quán nhất trên cả ba kịch bản cốt lõi của MU bao gồm loại bỏ định kiến, giải quyết nhầm lẫn nhãn, và bảo vệ quyền riêng tư người dùng.

Trong khung huấn luyện chọn lọc của SCRUB, mô hình gốc ban đầu đã được huấn luyện trên toàn bộ tập dữ liệu $\mathcal{D} = \mathcal{D}_r \cup \mathcal{D}_f$ bao gồm cả tập giữ lại $\mathcal{D}_r$ và tập cần quên $\mathcal{D}_f$ đóng vai trò là Giáo viên (w_o) và được đóng băng hoàn toàn tham số. Ngược lại, mô hình giải học mục tiêu đóng vai trò là Học sinh w_u, được khởi tạo bằng chính trọng số w_o để thừa kế hiệu năng tốt trên tập giữ lại, sau đó được tối ưu hóa để chủ động nghe lời giáo viên trên $\mathcal{D}_r$ nhưng chống lại giáo viên trên $\mathcal{D}_f$. Để đo lường sự sai lệch hành vi giữa học sinh và giáo viên trên một mẫu dữ liệu x, SCRUB sử dụng phép đo KL Divergence giữa phân phối xác suất đầu ra của hai mô hình:

$$d(x; w_u) = \mathcal{D}_{\mathrm{KL}}\big(p(f(x; w_o)) \parallel p(f(x; w_u))\big)$$

Nhằm giúp đẩy học sinh tránh xa giáo viên trên tập quên $\mathcal{D}_f$ nhưng giữ khoảng cách gần trên tập giữ lại $\mathcal{D}_r$, đồng thời tích hợp thêm hàm mất mát tác vụ tiêu chuẩn để bảo toàn hiệu năng hệ thống, công thức tổn thất tổng thể cuối cùng của SCRUB được định nghĩa dưới dạng bài toán tối ưu

hóa Min-Max:

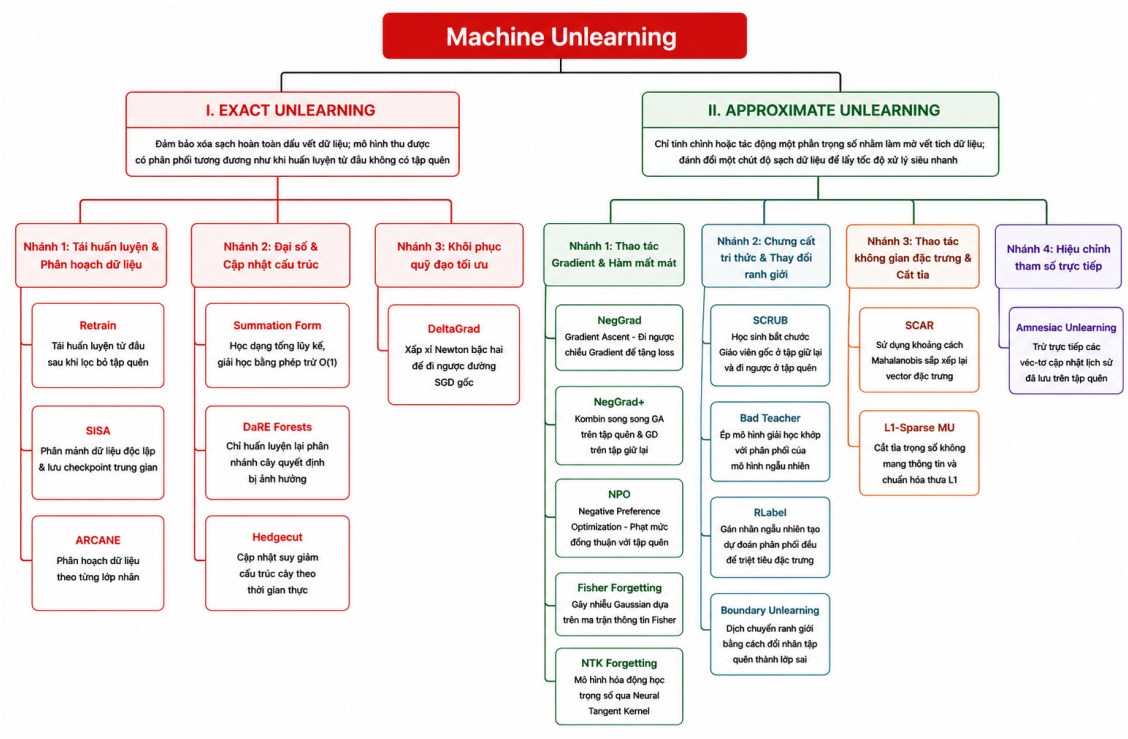
$$\min_{w_u} \frac{\alpha}{|\mathcal{D}_r|} \sum_{x_r \in \mathcal{D}_r} d(x_r; w_u) + \frac{\gamma}{|\mathcal{D}_r|} \sum_{(x_r, y_r) \in \mathcal{D}_r} \ell(f(x_r; w_u), y_r) - \frac{1}{|\mathcal{D}_f|} \sum_{x_f \in \mathcal{D}_f} d(x_f; w_u)$$

Trong đó, α và γ là các siêu tham số điều phối sự cân bằng giữa việc quên và nhớ các dự đoán của mô hình giáo viên, và thành phần Cross-Entropy đóng vai trò như một lớp bảo vệ quan trọng giúp tránh suy giảm hiệu năng tác vụ ngoài ý muốn.

Do việc tối ưu hóa đồng thời max-min ngược chiều rất dễ gây mất ổn định, SCRUB triển khai chiến lược tối ưu hóa xen kẽ [11]. Quy trình huấn luyện sẽ luân phiên tuần tự giữa bước cực đại thực hiện cập nhật trọng số trong 1 epoch trên tập quên $\mathcal{D}_f$ để chủ động đẩy học sinh ra xa giáo viên, ngay sau đó là bước cực tiểu thực hiện cập nhật trong 1 epoch trên tập giữ lại $\mathcal{D}_r$ để kéo học sinh quay lại gần phân phối của giáo viên. Cuối cùng, một chuỗi các bước cực tiểu liên tiếp sẽ được chạy thêm ở giai đoạn cuối để khôi phục triệt để hiệu năng của mô hình trên tập giữ lại.

2.5.6 Tóm tắt

Bên cạnh các phương pháp giải học cốt lõi đã được đề cập, nghiên cứu của em còn tìm hiểu thêm một loạt các kỹ thuật tiên tiến khác nhằm tối ưu hóa sự đánh đổi giữa hiệu năng và tính bảo mật. Tuy nhiên vì số lượng phương pháp lớn cùng với đó là mức độ phức tạp cài đặt của phương pháp nên trong phần thực nghiệm chúng em chỉ thực nghiệm các phương pháp được đề cập chi tiết ở phía trên. Tuy nhiên trong phần đánh giá, em cũng sẽ đưa ra nhận định chung của các tấn công GIAs hiện tại lên toàn bộ các phương pháp MU bằng các thực nghiệm tổng quan. Dưới đây là bảng tổng hợp chi tiết toàn bộ các phương pháp giải học thuộc nhóm exact unlearning và approximate unlearning được ghi nhận và phân loại từ các bài báo nghiên cứu:



Hình 2.3: Toàn bộ phương pháp MU mà em tìm hiểu được

2.6 Các công trình nghiên cứu về GIAs tấn công khôi phục đặc trưng dữ liệu

Mục tiêu chính của các cuộc tấn công GIAs này là khôi phục chính xác ở các đặc trưng của các mẫu dữ liệu của người dùng từ các bản cập nhật gradient được chia sẻ.

2.6.1 DLG và iDLG

Deep Leakage from Gradients (DLG) [38] và phiên bản cải tiến Improve Deep Leakage from Gradient (iDLG) [40] là hai thuật toán tấn công GIAs tiêu biểu khôi phục đặc trưng dữ liệu. Thuật toán DLG hoạt động bằng cách khởi tạo dữ liệu và nhãn giả lập ngẫu nhiên, sau đó tối ưu hóa đồng thời cả hai yếu tố này để giảm thiểu sai lệch Euclidean với gradient thực tế. Tuy nhiên, quy trình tối ưu hóa song song này của DLG thường gặp khó khăn trong việc hội tụ và thường khôi phục sai nhãn của mẫu dữ liệu huấn luyện. Để khắc phục điểm yếu đó, iDLG đề xuất một cơ chế phân tích toán học giúp trích xuất nhãn thực tế với độ chính xác 100% trước khi khôi phục đặc trưng dữ liệu. Cụ thể, iDLG khai thác mối quan hệ toán

học giữa các nhãn one-hot và dấu của gradient tại lớp kết nối đầy đủ cuối cùng của mô hình sử dụng hàm mất mát cross-entropy. Sau khi đã xác định chính xác nhãn, iDLG đóng băng nhãn đó và chỉ áp dụng thuật toán tối ưu hóa, L-BFGS, để cập nhật và tinh chỉnh đặc trưng của riêng dữ liệu giả lập. Sự cải tiến này giúp iDLG đạt tốc độ hội tụ nhanh hơn vượt trội và tái tạo hình ảnh với độ trung thực cao hơn rõ rệt.

2.6.2 GradInversion

Tuy nhiên cả DLG và iDLG bị giới hạn độ hiệu quả ở kích thước batch cực nhỏ, DLG chỉ hoạt động hiệu quả khi kích thước lô dữ liệu dưới 8 và iDLG chỉ trích xuất được nhãn khi lô dữ liệu chỉ có 1 mẫu duy nhất, và độ phân giải thấp. Nhằm cải tiến, thuật toán GradInversion được giới thiệu bởi đội ngũ nghiên cứu của NVIDIA [41] đã mở rộng ranh giới tấn công bằng cách khôi phục thành công các batch dữ liệu lớn với độ phân giải cao trên mô hình mạng sâu ResNet-50 sử dụng tập dữ liệu ImageNet. Để giải quyết bài toán đảo ngược gradient khi gradient mục tiêu bị trung bình hóa bởi các gradient của mẫu trong lô, GradInversion triển khai một hệ thống tối ưu hóa phức hợp bắt đầu bằng thuật toán khôi phục nhãn batch một bước để trích xuất trước danh sách nhãn từ gradient của lớp kết nối đầy đủ cuối cùng. Sau đó, để ngăn chặn việc tối ưu hóa sinh ra các ảnh nhiễu vô nghĩa, thuật toán áp dụng ràng buộc độ chân thực ảnh bằng cách tận dụng thông tin thống kê Batch Normalization có sẵn trong các tầng của mô hình kết hợp với chuẩn tổng biến thiên và chuẩn L2 để ép các phân phối đặc trưng trung gian hoạt động như ảnh tự nhiên. Cuối cùng, GradInversion tích hợp thêm ràng buộc đồng nhất nhóm chạy song song nhiều luồng tối ưu hóa từ các seed ngẫu nhiên, sử dụng thuật toán image registration để căn chỉnh và phạt các mẫu lệch khỏi ảnh trung bình của nhóm nhằm khôi phục các chi tiết pixel sắc nét nhất. Sự phối hợp chặt chẽ của các cơ chế này giúp GradInversion vượt trội hơn hẳn các thế hệ trước cả về mặt trực quan lẫn độ chính xác tái dựng so với DLG và iDLG. Tuy nhiên phương pháp GradInversion chỉ hoạt động dựa trên một giả định là các ảnh trong batch không bị trùng nhãn, điều này khiến cho GradInversion trở nên thiếu thực tế khi mẫu dữ liệu của người dùng thường có xu hướng phân phối bị

lệch về một vài lớp cụ thể, không phân phối đều về lớp như giả định của phương pháp [23]

2.7 Các công trình nghiên cứu về GIAs khôi phục mỗi nhãn

Ngoài các công trình GIAs khôi phục đặc trưng dữ liệu từ gradient, các công trình GIAs khôi phục mỗi nhãn từ gradient cũng được cải tiến mạnh mẽ qua nhiều nghiên cứu khác nhau. Mặc dù mục tiêu của hai loại tấn công gradient là khác nhau nhưng chúng thường hoạt động cùng nhau trong một quy trình thống nhất [18, 41]. Các phương pháp khôi phục nhãn hiện tại thường được triển khai trước các tấn công khôi phục dữ liệu, điều này khiến cho quá trình khôi phục đặc trưng dữ liệu giảm mạnh về không gian tìm kiếm và hội tụ nhanh hơn [23, 18, 41].

2.7.1 Phương pháp ZLG

ZLG được đề xuất bởi Geng và các cộng sự [1] đại diện cho một trong những giải pháp đầu tiên giải quyết thành công bài toán khôi phục nhãn trùng lặp mà GradInversion [41] gặp phải trong một lô dữ liệu mà không cần thực hiện quy trình tối ưu hóa dữ liệu đầu vào phức tạp. Về mặt nguyên lý, ZLG tận dụng triệt để tính chất toán học đặc thù của lớp phân loại tuyến tính cuối cùng bằng cách tiến hành cộng dồn các gradient thu được từ lớp kết nối đầy đủ cuối cùng dọc theo chiều đặc trưng, từ đó làm nổi bật sự đóng góp cụ thể của từng lớp nhãn. Để ước lượng chính xác phân phối nhãn, ZLG thiết lập một cơ chế xấp xỉ dựa trên việc nạp dữ liệu giả lập qua mô hình nhằm tính toán các giá trị xác suất hậu nghiệm cùng các kích hoạt trung gian. Nhờ các giá trị xấp xỉ này, hệ thống có thể thiết lập mối tương quan tuyến tính và đếm chính xác số lần xuất hiện của từng lớp nhãn cụ thể trong batch dữ liệu thực tế, ngay cả trong kịch bản các nhãn trùng lặp xuất hiện với tần suất cao. Việc xác định chính xác phân phối nhãn ngay từ giai đoạn khởi đầu của quy trình tấn công mang lại đóng góp quan trọng trong việc thu hẹp đáng kể không gian tìm kiếm cho các thuật toán khôi phục hình ảnh ở bước khôi phục đặc trưng bằng

thuật toán DLG tiếp theo [1]. Nhờ đó, các mẫu ảnh được tái tạo thuộc cùng một lớp nhãn sẽ giữ lại được các đặc trưng hình học cốt lõi của chúng mà không bị hiện tượng chồng chéo hay nhầm lẫn về mặt cấu trúc trực quan. Tuy nhiên, hạn chế lớn nhất của thuật toán ZLG nằm ở chỗ nó đặt ra giả định nghiêm ngặt về mặt kiến trúc khi mô hình đích bắt buộc phải sử dụng các hàm kích hoạt không âm, tiêu biểu như lớp ReLU [23].

2.7.2 Phương pháp LLG và LLG+

Tương tự, Label Leakage from Gradients (LLG) [20] cùng biến thể nâng cấp LLG+ tiếp cận bài toán khôi phục nhãn trùng lặp trong một lô dữ liệu thông qua việc khai thác mối liên hệ tuyến tính chặt chẽ giữa độ lớn gradient của lớp phân loại cuối cùng và tần suất xuất hiện của nhãn tương ứng. Cơ sở lý thuyết của phương pháp này dựa trên hai thuộc tính cốt lõi của gradient lớp cuối: thuộc tính chiều hướng chỉ ra rằng dấu của gradient phản ánh sự tồn tại của một nhãn lớp trong lô huấn luyện, và thuộc tính độ lớn khẳng định độ lớn của gradient tỷ lệ thuận với số lần trùng lặp của nhãn đó. Về mặt toán học, gradient của một nhãn lớp i được mô hình hóa tường minh qua phương trình tuyến tính:

$$g_i = \lambda_i m + s_i$$

Trong đó, λ_i đại diện cho số lần xuất hiện của nhãn i trong lô dữ liệu; m là hệ số ảnh hưởng tham số mang giá trị âm, hằng số và độc lập với nhãn; còn s_i là hệ số offset đặc trưng cho từng nhãn, đại diện cho các hình phạt phân loại sai của mô hình.

Sự khác biệt về mặt kịch bản tấn công dẫn đến hai cơ chế xử lý khác nhau giữa LLG và LLG+. Cụ thể, LLG hoạt động trong kịch bản hạn chế khi kẻ tấn công chỉ tiếp cận được các gradient chia sẻ. Lúc này, hệ số tác động m được ước lượng thô bằng cách tính trung bình các gradient mang giá trị âm, trong khi hệ số dịch lệch s_i không thể xác định trực tiếp nên tạm thời được bỏ qua và coi bằng 0. Ngược lại, LLG+ khai thác thêm tri thức tiên nghiệm nhờ việc sở hữu một tập dữ liệu phụ trợ nhỏ có cùng phân phối lớp. Bằng cách nạp tập dữ liệu này qua một mô hình bóng ma, LLG+ có thể tính toán chính xác giá trị tác động m thực tế và đặc biệt

là hệ số dịch lệch s_i thông qua việc đo lường mức độ phân loại sai thực nghiệm [20].

Quy trình tấn công tổng thể của họ thuật toán này được thực hiện qua ba bước thiết yếu: đầu trích xuất các nhãn tồn tại dựa trên dấu âm của gradient; kế tiếp tiến hành hiệu chỉnh gradient bằng cách trừ đi giá trị offset s_i; và cuối cùng lựa chọn nhãn có gradient âm lớn nhất rồi trừ dần giá trị impact m cho đến khi tổng số lượng nhãn khớp với kích thước của lô dữ liệu. Nhờ việc vận hành hoàn toàn dựa trên giải tích bậc một và các phép toán ma trận trực tiếp, LLG và LLG+ loại bỏ hoàn toàn các bước tối ưu hóa lặp phức tạp của các phương pháp tiền nhiệm như DLG, từ đó tối ưu hóa tốc độ thực thi và giảm thời gian tấn công xuống hàng chục lần. Nhưng cũng giống như ZLG, phương pháp yêu cầu một hàm kích hoạt không âm khiến cho phương pháp bị giới hạn trong một số trường hợp cụ thể [23].

2.7.3 Phương pháp RLG

Revealing Labels from Gradients (RLG) được đề xuất bởi Trung Dang và các cộng sự [42] là thuật toán giải tích tiên phong trong việc khôi phục nhãn ở mức độ từng thực thể mẫu bằng cách chuyển đổi bài toán tìm phân phối nhãn thành việc giải một hệ phương trình tuyến tính. Nguyên lý hoạt động của RLG dựa trên mối quan hệ giải tích chặt chẽ giữa gradient của hàm mất mát đối với các logits $p_i - y_i$ và các giá trị cập nhật của lớp phân loại cuối cùng. Quy trình của thuật toán bắt đầu bằng việc khôi phục các vector đặc trưng trung bình của từng lớp dựa trên tỷ lệ giữa gradient trọng số ∇W và gradient bias ∇b tại lớp phân loại kết nối đầy đủ cuối cùng. Sau đó, các đặc trưng trung bình này được nạp ngược lại vào lớp phân loại để tính toán các giá trị xác suất dự đoán sau softmax xấp xỉ. Cuối cùng, RLG thiết lập một hệ phương trình tuyến tính liên kết giữa số lượng thực thể cần tìm của mỗi lớp k_j, xác suất dự đoán tương ứng p_{cB_j}, và cập nhật bias thực tế thu được từ phía máy khách:

$$k_1 + k_2 + \cdots + k_C = K$$

$$\sum_j k_j p_{cB_j} - K\nabla b_c = k_c$$

Trong đó, K đại diện cho kích thước của lô dữ liệu và k_c là số lượng thực thể của lớp c cần xác định trong lô thực tế.

Do hệ phương trình tuyến tính trên thường có ma trận hệ số không vuông, RLG áp dụng toán tử giả nghịch đảo Moore-Penrose để tìm ra nghiệm bình phương tối thiểu, từ đó ước lượng chính xác số lượng thực thể của từng lớp nhãn cụ thể. Đóng góp lớn nhất của RLG là khả năng vận hành cực kỳ hiệu quả trên các mô hình chưa được huấn luyện, đạt độ chính xác nhận diện nhãn tồn tại vượt trội ngay cả trong kịch bản kích thước batch khổng lồ [42]. Tuy nhiên, hạn chế cốt lõi của iRLG nằm ở việc hiệu năng bị suy giảm nghiêm trọng khi mô hình đích bắt đầu hội tụ và đạt độ chính xác cao; nguyên nhân là do sự thay đổi của các phân phối logits khiến các ước lượng xấp xỉ đặc trưng trung bình ban đầu không còn duy trì được độ chính xác toán học cần thiết [23].

2.7.4 Phương pháp RLU

Để giải quyết các vấn đề của phương pháp trên Recovering Labels from Local Updates (RLU) [23] đại diện cho giải pháp khôi phục nhãn tiên tiến, được thiết kế nhằm khắc phục triệt để điểm yếu cố hữu của phương pháp ZLG, LLG và RLG, đồng thời mở rộng khả năng tấn công trong các kịch bản học liên kết thực tế phức tạp. Về mặt nguyên lý, RLU tập trung phân tích sâu sắc mối tương quan tuyến tính giữa số lượng mẫu dữ liệu của từng nhãn lớp trong lô huấn luyện với cập nhật cục bộ của lớp đầu ra, đặc biệt là vector cập nhật của thành phần bias Δb. Trọng tâm lý thuyết của họ thuật toán này nằm ở việc ước lượng giá trị kỳ vọng của "độ tin cậy sai lệch", $S_{n,j}$), đại diện cho xác suất mô hình phân loại nhầm một mẫu có nhãn thực tế là n sang một lớp mục tiêu j ($n \neq j$). Toàn bộ quy trình này được hiện thực hóa thông qua hai giai đoạn cốt lõi: ước lượng phân phối logits dựa trên kỹ thuật Monte Carlo và giải bài toán tối ưu hóa tuyến tính bằng phương pháp bình phương tối thiểu [23].

Cụ thể, RLU giả định các logits đầu ra $q(n)$ của mô hình tuân theo phân phối chuẩn đa biến $\mathcal{N}(\mu_n, \Sigma_n)$. Để tính toán kỳ vọng μ_n và ma trận

hiệp biến Σ_n tại mỗi vòng truyền thông, máy chủ tận dụng một tập dữ liệu phụ trợ nhỏ $\mathcal{A}$ chạy qua mô hình toàn cục hiện tại, sau đó áp dụng mô phỏng Monte Carlo để ước lượng phân phối logits cùng ma trận sai số xác suất $S_{n,j}$. Trong kịch bản mô hình được cập nhật qua duy nhất một bước lặp đơn lẻ ($m = 1$), số lượng mẫu của mỗi nhãn lớp z được xác định thông qua bài toán bình phương tối thiểu ràng buộc sau:

$$\min_{z \in R^N} \|\mathbf{A}z - u\|_2^2 \quad \text{s.t.} \quad 0 \leq z \leq 1 \ \wedge \ \|z\|_1 = 1$$

Trong đó, $u = \Delta b/\eta$ với η đại diện cho tốc độ học cục bộ. Ma trận hệ số $\mathbf{A}$ được cấu thành bởi các phần tử trên đường chéo chính $a_{j,j} = \sum_{n \neq j} S_{j,n}$ và các phần tử ngoài đường chéo $a_{n,j} = -S_{n,j}$.

Đối với kịch bản phức tạp hơn khi mô hình được cập nhật qua nhiều chu kỳ cục bộ $m > 1$, phân phối logits sẽ liên tục dịch chuyển qua từng epoch trung gian τ. Để giải quyết rào cản động học này, RLU đề xuất thuật toán Posterior Search nhằm thiết lập một hệ phương trình mô phỏng động học cập nhật tham số. Cơ chế này cho phép ước lượng đệ quy sự dịch chuyển của kỳ vọng logits $\mu_{n,j}^{(t,\tau)}$, từ đó hiệu chỉnh kịp thời ma trận hệ số $\mathbf{A}$ để đạt độ chính xác khôi phục tối ưu.

Đóng góp lớn nhất của RLU là thuật toán đầu tiên chứng minh khả năng khôi phục nhãn bền vững dưới các cập nhật mô hình trong nhiều chu kì [23]. Ngoài ra, RLU chứng minh tính tương thích ổn định khi vận hành ổn định trên các phân phối dữ liệu không đồng nhất [23]. Mặc dù như vậy, độ chính xác của RLU trên mô hình đã được huấn luyện tốt dù vẫn cao nhưng bị giảm mạnh [23], khiến RLU vẫn chưa là phương pháp tốt nhất trong kịch bản MU .

2.8 Các công trình nghiên cứu áp dụng GIAs khôi phục dữ liệu và nhãn trong MU

2.8.1 Unlearning Inversion Attacks

Phương pháp Unlearning Inversion Attacks được đề xuất bởi Hu và cộng sự [15] hướng tới mục đích khôi phục các đặc trưng trực quan nhạy

cảm và nhãn của dữ liệu đã bị yêu cầu xóa $\mathcal{D}_f$ bằng cách khai thác sự biến động tham số giữa hai phiên bản mô hình. Tấn công sử dụng triết lí của phương pháp DLG nhằm khi cố gắng tối thiểu hóa sai lệch về hướng của gradient sinh ra bởi dữ liệu dummy và gradient thật để khôi phục các đặc trưng của dữ liệu [15, 19, 38]. Trong kịch bản tấn công này, kẻ tấn công white-box được giả định là có quyền truy cập trực tiếp vào các tham số của cả mô hình gốc trước khi unlearn θ và mô hình giải học sau khi unlearn θ_{u}.

Do các thuật toán giải học cập nhật tham số dựa trên thông tin của tập quên, sự sai khác tham số được định nghĩa là:

$$\Delta^* = \theta - \theta_{\mathrm{u}}$$

Đây chính là một ước lượng toán học rất sát về thông tin gradient của chính dữ liệu đích đã bị loại bỏ. Tuy nhiên, vì Δ^* chỉ là một giá trị ước lượng thô từ hiệu số mô hình chứ không phải là giá trị gradient chính xác tuyệt đối, kẻ tấn công không thể áp dụng các phép đo khớp khoảng cách độ lớn thông thường như khoảng cách Euclidean.

Để vượt qua thách thức này, nghiên cứu đề xuất một hàm mục tiêu tối ưu hóa dựa trên việc cực đại hóa độ tương đồng cosine [43] nhằm khớp hướng thay vì khớp độ lớn giữa gradient của mẫu dummy ∇' và target gradient ước lượng Δ^*:

$$\max_{x',y'} \mathrm{CosSim}(\nabla', \Delta^*) = \max_{x',y'} \frac{\langle \nabla', \Delta^* \rangle}{\|\nabla'\|_2 \|\Delta^*\|_2}$$

Nhằm đảm bảo hình ảnh khôi phục có độ chân thực cao và không bị nhiễu hạt vô nghĩa, thuật toán tích hợp thêm số hạng điều hòa tổng biến thiên $\mathrm{TV}(x')$ đóng vai trò như một bộ lọc trơn ảnh tự nhiên. Quy trình này hoạt động hiệu quả ngay cả khi nhãn ban đầu của mẫu quên hoàn toàn chưa được biết trước, bằng cách xử lý nhãn như một biến số tối ưu hóa hoặc áp dụng các thuật toán phân tích dấu gradient lớp đầu ra để giải mã nhãn trước [15, 19].

Kết quả đánh giá thực nghiệm chỉ ra rằng approximate unlearning có độ rò rỉ thông tin cao hơn và dễ bị khôi phục đặc trưng hơn hẳn so với exact

unlearning [15]. Nguyên nhân là do approximate unlearning trực tiếp sửa đổi mô hình gốc qua một vài bước cập nhật cục bộ, khiến hiệu số trọng số của hai mô hình lưu giữ lại dấu vết gradient vô cùng rõ nét. Ngược lại, mô hình sau khi trải qua exact unlearning được huấn luyện lại hoàn toàn từ đầu, mang theo nhiều yếu tố ngẫu nhiên ngẫu sinh từ quá trình khởi tạo và tối ưu hóa, từ đó tạo ra một ước lượng gradient bị lệch làm suy giảm đáng kể chất lượng khôi phục đặc trưng ảnh [15].

2.9 Khoảng trống nghiên cứu

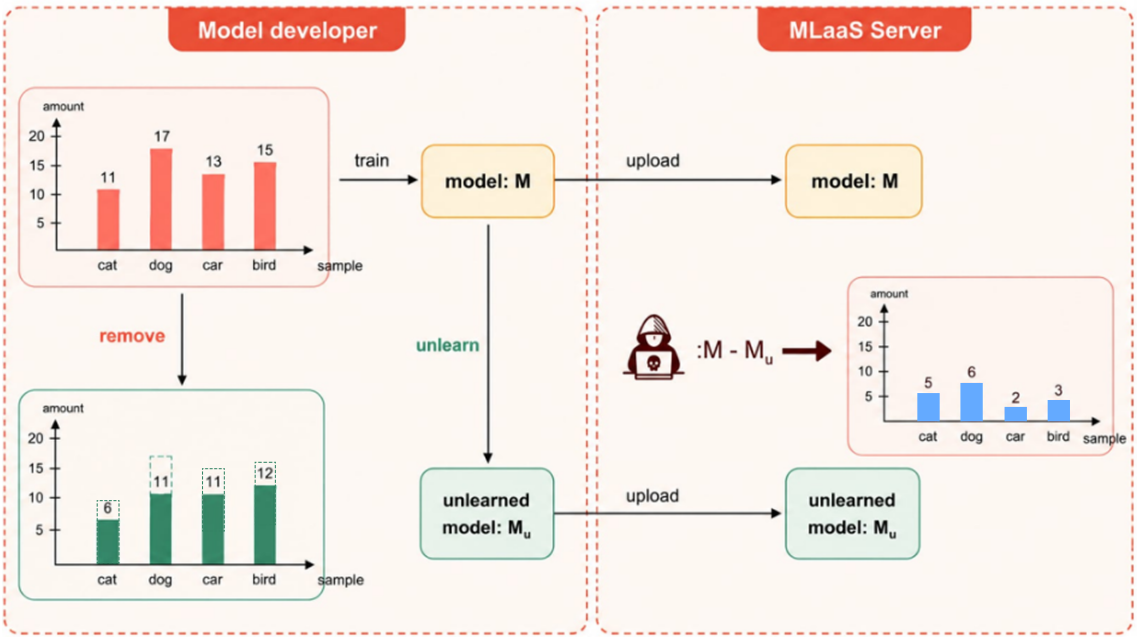
Việc thiếu vắng các phương pháp tấn công GIAs khôi phục chỉ nhãn nhằm vào MU hiện nay đang đặt ra một thách thức bảo mật cấp bách, khi mà những rủi ro về quyền riêng tư liên quan đến dữ liệu bị xóa bỏ phần lớn vẫn chưa được khai phá. Ngoài ra, mặc dù các cuộc tấn công GIAs nhắm vào nhãn đã liên tục phát triển và chứng minh được khả năng tổng quát hóa cao tập dữ liệu và kiến trúc mô hình khác nhau, hiệu suất của chúng thường bị suy giảm nghiêm trọng khi áp dụng cho các mô hình đã được huấn luyện tốt, điều mà thường xuyên bắt gặp trong MU. Trong khi phương pháp LLG có thể vượt qua rào cản này để duy trì tính hiệu quả trên các mô hình đã được huấn luyện tốt, nó lại thiếu đi khả năng tổng quát hóa khi tỷ lệ thành công bị sụt giảm lúc đối mặt với các tập dữ liệu đa dạng và các kiến trúc mô hình phức tạp. Cuối cùng, một hạn chế lớn của các phương pháp SOTA hiện nay là sự phụ thuộc của chúng vào các ước tính được rút ra từ một tập dữ liệu phụ trợ. Điều này làm kéo dài đáng kể thời gian thực thi và đòi hỏi kẻ tấn công phải sở hữu các tài nguyên phần cứng mạnh mẽ để tính toán. Hệ quả là, khi nhắm vào các mô hình học sâu và các tập dữ liệu có độ phân giải cao, cuộc tấn công sẽ tiêu thụ một lượng tài nguyên tính toán khổng lồ, bao gồm cả FLOPs và VRAM, khiến nó trở nên kém khả thi trong một số bối cảnh thực tế nhất định.

Chương 3

Mô hình mối đe dọa

Trong nghiên cứu này, em xem xét mô hình Machine Learning as a Service (MLaaS), nơi nhà phát triển mô hình triển khai các mô hình đã được huấn luyện trước lên một Máy chủ MLaaS để cung cấp dịch vụ suy diễn cho người dùng cuối.

3.1 Machine Learning as a Service



Hình 3.1: Tổng quan kiến trúc của cuộc tấn công GIAs nhằm khai thác nhãn trong môi trường MLaaS. Ở phía máy khách, nhà phát triển mô hình huấn luyện một mô hình ban đầu (M) trên tập dữ liệu đầy đủ, sau đó tải lên một mô hình (M_u) sau khi loại bỏ một tập hợp con dữ liệu cụ thể. Ở phía máy chủ, nhà cung cấp dịch vụ MLaaS độc hại, với lợi thế tiếp cận được ảnh chụp trạng thái của cả hai mô hình, sẽ tiến hành phân tích sự sai khác giữa hai phiên bản này để khôi phục nhãn thành công chính xác phân phối theo từng lớp của tập dữ liệu quên riêng tư.

Mô hình MLaaS là một cấu hình điện toán đám mây bao gồm ba thành phần tham gia chính: nhà phát triển mô hình, máy chủ MLaaS và người dùng cuối [15, 30]. Nhà phát triển mô hình sở hữu dữ liệu, tiến hành huấn luyện mô hình hệ thống trên các tập dữ liệu riêng tư và triển khai chúng lên nền tảng đám mây của máy chủ MLaaS. Khi có yêu cầu xóa dữ liệu phát sinh, nhà phát triển sẽ khởi chạy quy trình giải MU và tải lên mô hình hệ thống đã cập nhật để thay thế mô hình cũ. Máy chủ MLaaS cung cấp hạ tầng đám mây, chịu trách nhiệm tiếp nhận các mô hình này và cung cấp các giao diện lập trình ứng dụng API cho các truy cập bên ngoài. Cuối cùng, người dùng cuối sử dụng các API này để gửi dữ liệu và nhận kết quả dự đoán. Trong khi người dùng chỉ có quyền truy cập black-box, nghĩa là họ chỉ nhìn thấy dữ liệu đầu vào và kết quả đầu ra của mô hình, thì máy chủ MLaaS lại có quyền truy cập white-box toàn diện vào toàn bộ cơ chế vận hành bên trong của mô hình.

3.1.1 Vai trò và tri thức của kẻ tấn công

Trong mô hình đe dọa của mình, em giả định máy chủ MLaaS đóng vai trò là một kẻ tấn công trung thực nhưng tò mò. Máy chủ được coi là trung thực vì nó tuân thủ nghiêm ngặt tất cả các quy tắc triển khai và cập nhật mà không gây gián đoạn dịch vụ hoặc làm thay đổi hành vi của mô hình. Tuy nhiên, nó lại tò mò vì sẽ thu thập, phân tích và so sánh các phiên bản mô hình khác nhau một cách thụ động nhằm khôi phục thông tin riêng tư từ dữ liệu bị xóa. Kẻ tấn công này có quyền truy cập toàn diện vào các tham số nội bộ của mô hình nhưng không thể nhìn thấy dữ liệu huấn luyện gốc. Cụ thể, kẻ tấn công biết chính xác các tham số của mô hình gốc trước khi giải học, cũng như toàn bộ tham số của mô hình đã được cập nhật sau khi có yêu cầu xóa dữ liệu. Ngoài ra, kẻ tấn công cũng biết chính xác số lượng mẫu dữ liệu đã bị gỡ bỏ trong quá trình cập nhật, mặc dù chúng hoàn toàn không biết nội dung thực tế hay nhãn thực của các mẫu đó.

3.1.2 Khả năng của kẻ tấn công

Bởi vì kẻ tấn công sở hữu cả hai phiên bản mô hình gốc và mô hình giải học, chúng có thể khởi chạy một cuộc tấn công GIAs bằng cách phân tích sự thay đổi của mô hình. Dựa trên giả định rằng sự dịch chuyển trong các tham số của mô hình hoàn toàn do việc loại bỏ dữ liệu cần quên gây ra, kẻ tấn công sẽ tính toán hiệu số giữa hai mô hình này. Hiệu số tham số này đóng vai trò như một ước lượng về gradient của các mẫu dữ liệu đã bị unlearn, cho phép kẻ tấn công khai thác triệt để thông tin đó.

3.1.3 Mục tiêu của kẻ tấn công và tiêu chí tấn công thành công

Trong các cuộc tấn công GIAs nhằm việc khai thác nhãn dữ liệu bị xóa trong MU, mục tiêu chính của kẻ tấn công là thiết lập chính xác danh tính lớp nhãn của dữ liệu bị xóa. Nói một cách chính xác hơn, kẻ tấn công hướng tới việc xác định chính xác phân phối nhãn của tập dữ liệu đã bị xóa bỏ. Để đo lường mức độ hiệu quả của cuộc tấn công, em đánh giá tỷ lệ thành công của nó bằng cách so sánh tập hợp các nhãn mà kẻ tấn công dự đoán với các nhãn thực tế của dữ liệu giải học được đề cập ở phần 5.5. Chỉ số độ chính xác càng cao chứng tỏ cuộc tấn công càng mạnh mẽ và thành công, đồng nghĩa với việc mức độ rò rỉ thông tin riêng tư càng nghiêm trọng.

Chương 4

Phương pháp đề xuất

Trong phần này, trước hết em sẽ tiến hành mô hình hóa bài toán tấn công GIAs trong môi trường MU tại mục 4.1. Tiếp theo, em tiến hành phân tích hai yếu tố cốt lõi có tầm ảnh hưởng quyết định đến gradient của mô hình đã được huấn luyện tốt, bao gồm: dấu của vector gradient đối với một mẫu dữ liệu đơn lẻ tại mục 4.2, sự mất cân bằng dữ liệu tại mục 4.3 và trạng thái của mô hình ở mục 4.4. Dựa trên việc kết hợp toàn diện các yếu tố này, em đã đề xuất phương pháp Vector-based Label Inference (VLI), thông tin chi tiết được trình bày tại mục 4.5.

4.1 Phát biểu bài toán

Trong lĩnh vực học máy bảo toàn quyền riêng tư, mục tiêu của MU là loại bỏ hoàn toàn ảnh hưởng của một tập dữ liệu quên D_f cụ thể ra khỏi một mô hình đã được huấn luyện. Để hình thức hóa quy trình này, gọi M là mô hình gốc được huấn luyện trên toàn bộ tập dữ liệu đầy đủ, và phiên bản đã xóa bỏ được tác động dữ liệu cần được xóa của nó là M_u. Em ký hiệu các tham số của các mô hình này tại mỗi lớp $k \in \{1, \ldots, L\}$ sao cho trọng số và bias của mô hình được biểu diễn lần lượt là w^k và b^k, trong khi các tham số đã cập nhật của trạng thái giải học được ký hiệu là w_u^k và b_u^k. Trong nghiên cứu này, em tập trung vào lượng cập nhật *bias* tại lớp cuối cùng L, được định nghĩa như sau:

$$\Delta b^L = b_u^L - b^L$$

Em giả định rằng sự dịch chuyển tham số Δb^L xấp xỉ với gradient *bias* tích lũy ∇_b^L của tập dữ liệu cần quên tại lớp cuối cùng:

$$\Delta b^L \approx \nabla_B^L = \sum_{x_i \in \mathcal{D}_\text{f}} \nabla_B^L(x)$$

Trong đó, $\nabla_B^L(x)$ đại diện cho đạo hàm riêng của hàm mất mát đối với thành phần *bias* của lớp cuối cùng cho từng mẫu dữ liệu bị xóa x.

4.2 Tầm quan trọng của dấu gradient

Bản chất của các cuộc tấn công GIAs khôi phục lại nhãn xoay quanh một thuộc tính nền tảng của hàm mất mát cross-entropy tại lớp phân loại cuối cùng [19, 40]. Cụ thể, gradient lớp cuối của một mẫu dữ liệu đơn lẻ x_i chứa các đạo hàm của hàm mất mát đối với thành phần bias b_j của một lớp phân loại j cụ thể [19, 40]. Giả định mô hình mạng thần kinh sử dụng hàm mất mát Cross-Entropy tiêu chuẩn đối với một mẫu dữ liệu x_i có nhãn thực tế dạng one-hot vector là $y_i \in \{0, 1\}^C$, với C là số lượng lớp phân loại:

$$\mathcal{L}(x_i, y_i) = -\sum_{c=1}^{C} y_{i,c} \log(p_{i,c}) \tag{4.1}$$

Trong đó, $p_i \in [0; 1]^C$ là vector xác suất dự đoán đầu ra sau hàm kích hoạt softmax của mô hình gốc M trên mẫu dữ liệu x_i:

$$p_{i,j} = \text{softmax}(z_i)_j = \frac{e^{z_{i,j}}}{\sum_{c=1}^{C} e^{z_{i,c}}} \tag{4.2}$$

Với $z_{i,j}$ là giá trị logit của lớp cuối cùng tương ứng với mẫu dữ liệu x_i tại lớp phân loại j. Đạo hàm riêng của hàm mất mát $\mathcal{L}$ đối với từng thành phần bias lớp cuối $\nabla_B^L(x_i)$ được xác định bằng công thức:

$$\nabla b_j = \begin{cases} p_j - 1, & \text{nếu } j = y \\ p_j, & \text{nếu } j \neq y \end{cases} \tag{4.3}$$

Trong đó, p_j biểu thị xác suất dự đoán cho lớp j, và y đại diện cho nhãn thực tế của dữ liệu đầu vào x_i. Đối với lớp trùng khớp với nhãn thực tế $j = y$, thành phần gradient $\nabla b_y = p_y - 1$ chắc chắn mang giá trị âm vì xác suất dự đoán $p_y \in (0, 1)$. Thành phần này trong phần còn lại của bài sẽ được gọi là thành phần âm tạo bởi 1 điểm dữ liệu. Điều này tạo ra một dấu hiệu đặc trưng tại chính xác vị trí chỉ mục của nhãn đúng. Ngược lại, đối với tất cả các lớp không chính xác $j \neq y$, gradient $\nabla b_j = p_j$ luôn mang giá trị dương. Thành phần này trong phần còn lại của bài sẽ được gọi là thành phần dương tạo bởi 1 điểm dữ liệu Sự tương phản rõ rệt về dấu của gradient này cung cấp một cơ chế trực tiếp cho phép kẻ tấn công nhận diện chính xác sự tồn tại của nhãn đó trong một batch [40].

Tuy nhiên, gradient sắp xỉ được ước tính từ sự khác nhau của mô hình trước và sau giải học sẽ thay đổi bản chất và cấu trúc tùy thuộc vào từng thiết lập MU cụ thể [15]. Ví dụ trong approximate unlearning, thuật toán unlearning thường trực tiếp sửa đổi mô hình gốc M hiện tại thông qua một vài bước cập nhật cục bộ để tạo ra mô hình sau khi xóa dữ liệu M_u. Vì M_u được sinh ra trực tiếp từ M chỉ qua một vài biến đổi tham số nhỏ, hiệu số trọng số $w^k - w_u^k$ sẽ ghi lại một cách hoàn hảo và sạch sẽ vết tích gradient của chính các mẫu dữ liệu bị xóa [15]. Do đó, kẻ tấn công dễ dàng thu được một ước lượng gradient cực kỳ tốt mà không bị lẫn, giúp khôi phục các đặc trưng trực quan nhạy cảm một cách dễ dàng và chính xác. Tuy nhiên, trong exact unlearning, thuật toán buộc phải loại bỏ hoàn toàn dữ liệu quên khỏi tập dữ liệu huấn luyện, sau đó tiến hành tái huấn luyện lại toàn bộ mô hình M_u từ đầu [14]. Trong suốt chu kỳ huấn luyện lại này, vô số yếu tố ngẫu nhiên ngẫu sinh [14, 15]. Những yếu tố ngẫu nhiên này đẩy mô hình huấn luyện lại M_u hội tụ về một điểm cực trị cục bộ hoặc một quỹ đạo tối ưu hóa hoàn toàn khác biệt so với mô hình gốc M. Lúc này, phép trừ $w^k - w_u^k$ không còn đại diện tốt cho gradient của dữ liệu bị xóa nữa, mà bị lấn át hoàn toàn bởi nhiễu ngẫu nhiên sinh ra từ hai quá trình huấn luyện độc lập. Hệ quả là, kẻ tấn công sẽ thu được một ước lượng gradient bị lệch nghiêm trọng và hỗn loạn, khiến thuật toán tấn công GIAs hoàn toàn thất bại trong việc tái tạo dữ liệu [15].

4.3 Tầm quan trọng của sự mất cân bằng dữ liệu và phân phối non-IID

Kế thừa từ phân tích về gradient của một mẫu dữ liệu đơn lẻ tại mục 4.2, khi một máy khách tính toán gradient trên một lô dữ liệu $\mathcal{B}$, gradient lớp cuối cùng đối với thành phần bias của bất kỳ lớp j nào, ký hiệu là ∇b_j, được định nghĩa về mặt toán học như sau:

$$\nabla b_j = \frac{1}{|\mathcal{B}|} \left(\sum_{x \in \text{class } j} (p_j(x) - 1) + \sum_{x \notin \text{class } j} p_j(x) \right) \tag{4.4}$$

Trong đó, $\sum_{x \in \text{class } j}(p_j(x) - 1)$ đại diện cho tổng các thành phần âm của các mẫu x thuộc về lớp j, và $\sum_{x \notin \text{class } j} p_j(x)$ được gọi là tổng tích lũy các xác suất dự đoán của các mẫu không thuộc về lớp j sẽ được gọi là các thành phần dương.

Trong các môi trường non-IID cực đoan, dữ liệu của một lô trở nên mất cân bằng nghiêm trọng và chỉ tập trung vào một vài lớp nhất định. Đối với lớp thực tế j, tần suất xuất hiện hay số lượng mẫu thuộc lớp j là rất lớn, khiến thành phần âm mang giá trị âm cực kỳ cao. Vì lô dữ liệu hầu như không chứa mẫu nào từ các lớp khác, giá trị dương $\sum_{x \notin \text{class } j} p_j(x)$ duy trì ở mức nhỏ không đáng kể. Kết quả là, thành phần âm chiếm ưu thế hoàn toàn và dễ dàng lấn át thành phần dương.

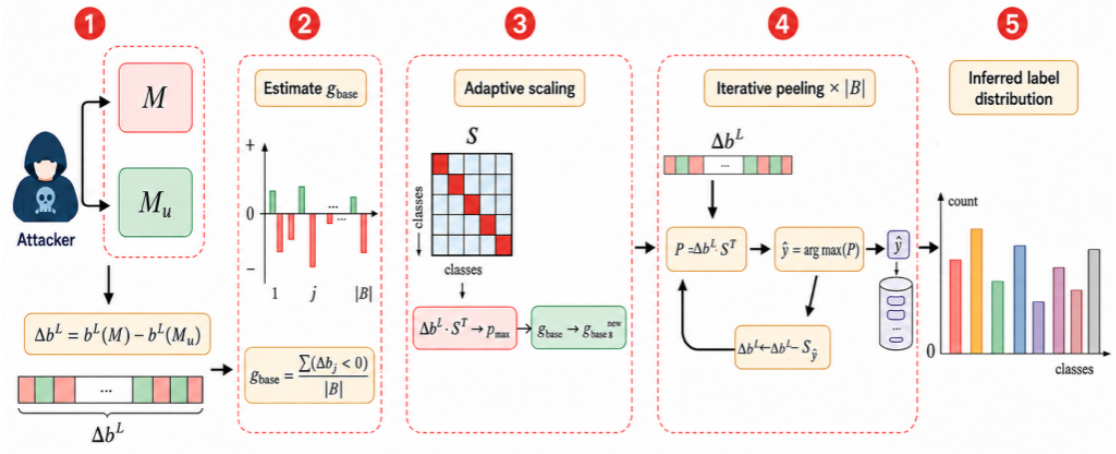
Tuy nhiên, trong các thiết lập IID, phân phối nhãn của máy khách là đồng đều, đồng nghĩa với việc số lượng mẫu thuộc về lớp thực tế i trong lô dữ liệu là tương đối ít. Do đó, thành phần $\sum_{x \in \text{class } j}(p_j(x) - 1)$ chỉ mang giá trị âm nhẹ. Ngược lại, đối với một lượng lớn các mẫu trong lô thuộc về các lớp khác, một mô hình chưa được huấn luyện hoàn hảo vẫn sẽ đưa ra một xác suất dư thừa $p_j(x) > 0$ cho lớp j. Mặc dù từng xác suất riêng lẻ có thể rất nhỏ, nhưng khi tích lũy trên một số lượng lớn các mẫu ngoại lớp, tổng thành phần dương này sẽ bị thổi phồng lên đáng kể, khiến cho các thành phần âm bị che lắp mạnh gây mất thông tin về nhãn tồn tại trong gradient.

4.4 Tầm quan trọng của trạng thái mô hình

Đối với một mô hình chưa được huấn luyện, các xác suất dự đoán thường phân phối đều, xấp xỉ bằng $\frac{1}{n}$ cho mỗi lớp, trong đó n đại diện cho tổng số lượng lớp phân loại. Ở trạng thái này, thành phần âm $\sum_{x \in \text{class } j}(p_j(x) - 1)$ trở nên cực kỳ âm vì $p_j(x) - 1 \approx \frac{1}{n} - 1 \approx -1$. Trong khi đó, các thành phần dương tích lũy $\sum_{x \notin \text{class } j} p_j(x)$ duy trì ở mức rất nhỏ.

Tuy nhiên, khi mô hình được huấn luyện tốt và hội tụ về một điểm cực trị cục bộ, giá trị của $p_j(x)$ đối với các mẫu dữ liệu x thực sự thuộc về lớp j sẽ tiến dần về 1. Hệ quả là, thành phần âm $\sum_{x \in \text{class } j}(p_j(x) - 1)$ sẽ thu hẹp lại và tiệm cận mức 0. Điều này vì cho xác suất dự đoán của các lớp khác nhau trở nên gần lại, trực tiếp làm giảm sự chênh lệch đáng kể của thành phần âm của mỗi mẫu dữ liệu thuộc các lớp khác nhau. Điều này trở nên quan trọng, đóng góp vào một trong những giả định cốt lõi của phương pháp VLI.

4.5 Vector-Based LDI (VLI)



Hình 4.1: Tổng quan các bước để triển khai cuộc tấn công của phương pháp VLI trải qua 5 giai đoạn khác nhau.

Dựa trên các quan sát lý thuyết về hành vi của gradient, em đề xuất phương pháp Suy luận nhãn dựa trên Vector (Vector-Based LDI - VLI). Mục tiêu cốt lõi của VLI là khai thác lượng dịch chuyển định thiên tích lũy ΔB^L nhằm ước lượng chính xác đóng góp gradient riêng lẻ của các mẫu

dữ liệu bị unlearn. Thuật toán vận hành thông qua một quy trình được cơ sở hóa toán học chặt chẽ, bao gồm các bước kéo dãn thích nghi và bóc tách lặp, chi tiết cụ thể như sau:

4.5.1 Giả định phân phối đều

Khi mô hình được huấn luyện tốt, độ chính xác dự đoán trên tất cả các lớp là tương đối cao và đồng đều, đồng nghĩa với việc xác suất dự đoán cho lớp nhãn thực tế sẽ tiệm cận về 1. Theo các phân tích tại mục 4.2 và mục 4.4, sự nhất quán này khiến cho gradient lớp cuối cùng đối với thành bias của mỗi mẫu dữ liệu thuộc các lớp khác nhau xuất hiện các thành phần âm tương tự nhau. Thêm vào đó, các nghiên cứu tiền đề như nghiên cứu của Ma và cộng sự [18] và Cheng và cộng sự [44] đã chỉ ra rằng các gradient của cập nhật trọng số hoặc bias lớp cuối cùng của các dữ liệu trong cùng một lớp có xu hướng tương đồng. Do đó, nghiên cứu đưa ra giả định rằng khi mô hình đã được huấn luyện tốt, tất cả các điểm dữ liệu đều tạo ra các gradient chứa các giá trị âm có độ lớn tương đương nhau.

4.5.2 Chi tiết thuật toán

Dựa trên giả định này, em giả định rằng các thành phần âm của tất cả các mẫu dữ liệu huấn luyện sẽ tập trung chặt chẽ quanh một giá trị trung bình, ký hiệu là g_{base}. Trước hết, phương pháp ước lượng thực nghiệm giá trị này bằng cách tính trung bình cộng của tổng các thành phần âm xuất hiện trong bias lớp cuối cùng của Δb_L cho trước:

$$g_{\text{base}} = \frac{\sum_{j,\Delta b_j<0} \Delta b_j}{|\mathcal{B}|} \tag{4.5}$$

Trong đó, $|\mathcal{B}|$ là kích thước lô dữ liệu của tập huấn luyện. Tuy nhiên, dựa trên các phân tích tại mục 4.2,4.3 và 4.4, giá trị thành phần âm ban đầu g_{base} trên thực tế đã bị che lấp do ảnh hưởng tích lũy từ các thành phần dương $\sum_{x\notin\text{class } j} p_j(x)$. Dựa trên những quan sát về việc các thành phần bị che lấp bởi hiện tượng phân phối cân bằng dữ liệu, để khôi phục giá trị thực của g_{base} trước khi hiện tượng che lấp này xảy ra, em đề xuất một phương pháp hiệu chỉnh dựa trên phân phối cân bằng dữ liệu. Để tính

toán mức độ mất cân bằng dữ liệu, em xây dựng một ma trận đại diện $S \in R^{n \times n}$, trong đó n là số lượng lớp phân loại và mỗi hàng j biểu diễn một gradient lớp cuối cùng đối với thành phần định thiên (*bias*) của lớp j. Phần tử nằm trên đường chéo chính $S_{j,j}$ đại diện cho giá trị g_{base}. Các phần tử ngoài đường chéo chính $S_{j,i}$ $(j \neq y)$ biểu thị xác suất một mẫu dữ liệu thuộc về lớp j nhưng lại bị phân loại nhầm sang lớp i. Để đơn giản hóa mô hình, em giả định rằng xác suất phân loại nhầm này phân phối đều giữa các lớp còn lại. Tiếp theo, phương pháp tính tích vô hướng *dot product* giữa vector gradient định thiên lớp cuối cùng do máy khách tải lên máy chủ với từng hàng của ma trận S để xác định xem vector này có bị lệch quá mức về bất kỳ lớp cụ thể nào hay không. Bằng cách kết hợp đồng các yếu tố đã quan sát và đo được từ việc mất cân bằng dữ liệu, em đề xuất một hệ số tỷ lệ động dành cho g để bù đắp cho sự che lấp gây ra bởi các thành phần dương, được định nghĩa như sau:

$$g_{base}^{new} = g_{base} \cdot (\alpha + \beta \cdot (1 - p_{\max}) \cdot (1 + \frac{1}{n})) \tag{4.6}$$

Trong đó, p_{max} là giá trị lớn nhất của kết quả thu được từ phép chiếu lên các gradient đặc trưng của từng lớp nhãn và n là số lớp dự đoán đầu ra. Ngoài ra hai hệ số α và β là các siêu tham số của phương pháp. Cuối cùng, phương pháp VLI trích xuất các nhãn ứng viên bằng cách sử dụng một thuật toán bóc tách lặp nhằm phân rã một cách hệ thống gradient định thiên lớp cuối cùng. Em đã khởi tạo một vector dư R chính là vector gradient định thiên lớp cuối cùng. Quy trình trích xuất sau đó được thực hiện qua n chu kỳ lặp liên tiếp, tương ứng với kích thước của lô dữ liệu huấn luyện. Tại mỗi bước $t \in \{1, \ldots, n\}$, phương pháp tính toán các điểm số tương thích giữa vector dư hiện tại R và ma trận cơ sở tổng hợp S thông qua phép tích vô hướng, thu được một vector điểm số:

$$P = R \cdot S^T \tag{4.7}$$

Lớp phân loại hiển thị điểm số tương thích cao nhất sẽ lập tức được xác định là nhãn ứng viên có khả năng xảy ra nhất, được thiết lập về mặt toán

học như sau:

$$\hat{y} = \arg\max(P) \tag{4.8}$$

Ngay sau khi nhãn này được xác định, phương pháp thực hiện thao tác bóc tách bằng cách trừ vector cơ sở tương ứng của nó ra khỏi vector dư, cập nhật trạng thái hệ thống theo công thức:

$$R \leftarrow R - S_{\hat{y}} \tag{4.9}$$

Bằng cách chiếu lặp đi lặp lại vector dư và trừ đi các tín hiệu lớp chiếm ưu thế theo phương thức này, thuật toán cô lập và trích xuất một cách hiệu quả tất cả đóng góp của từng nhãn riêng lẻ cho đến khi vector dư định thiên R được giải quyết hoàn toàn.

Chương 5

Kết quả thực nghiệm

Trong phần này, công trình đã tiến hành đánh giá toàn diện hiệu quả của phương pháp VLI đề xuất. Để phân tích một cách hệ thống năng lực và sự ổn định của cách tiếp cận này, các thực nghiệm của nghiên cứu được định hướng bởi hai câu hỏi nghiên cứu trọng tâm. Phần còn lại của mục này được tổ chức như sau: Mục 5.1 hình thức hóa các câu hỏi nghiên cứu của nghiên cứu. Mục 5.2 mô tả chi tiết thiết lập thực nghiệm, bao gồm các tập dữ liệu, mô hình đích và cấu hình MU. Mục 5.3 định nghĩa các số đo đánh giá . Cuối cùng, mục 5.4 và Mục 5.5 trình bày kết quả thực nghiệm toàn diện nhằm trả lời các câu hỏi nghiên cứu được đặt ra. Trong các thực nghiệm của mình, em đã phát triển hệ thống dựa trên mã nguồn chính thức được cung cấp trong bài báo RLU và công trình [15], đồng thời tích hợp phương pháp LLG và phương pháp VLI đề xuất để tiến hành quá trình đánh giá.

5.1 Câu hỏi nghiên cứu

Nghiên cứu này nhằm mục đích đánh giá một cách toàn diện hiệu quả của phương pháp VLI trong bối cảnh MU bằng cách giải quyết các câu hỏi nghiên cứu trọng tâm sau đây:

- **RQ1:** Phương pháp VLI đề xuất đạt hiệu quả như thế nào trong việc trích xuất chính xác nhãn của dữ liệu huấn luyện khi so sánh với các phương pháp GIAs tiên tiến nhất SOTA trên nhiều tập dữ liệu chuẩn và kiến trúc mô hình đích khác nhau?

- **RQ2:** Hiệu suất tính toán và chi phí tài nguyên của phương pháp VLI như thế nào khi so sánh với các phương pháp cơ sở ?

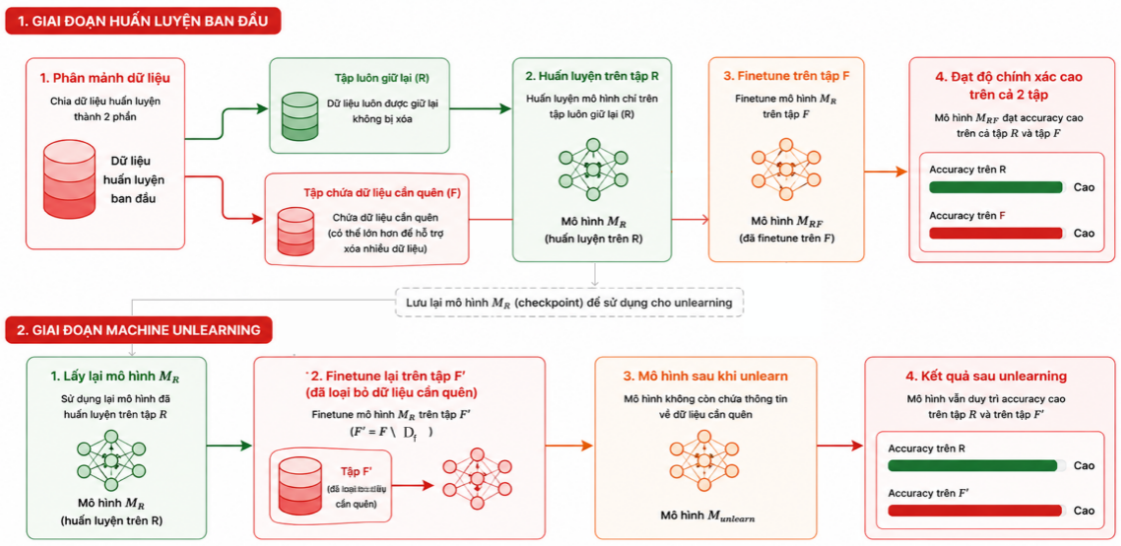
5.2 Thiết lập thực nghiệm

Công trình đã tiến hành các thực nghiệm trên bốn tập dữ liệu bao gồm: CIFAR-10, CIFAR-100, MNIST và SVHN để đánh giá hiệu suất của phương pháp khôi phục nhãn được đề xuất. Trong số đó, tập dữ liệu SVHN được sử dụng đặc biệt nhằm đánh giá hiệu suất của phương pháp khi mô hình được huấn luyện trên dữ liệu phân phối non-IID toàn hệ thống, dẫn đến độ chính xác dự đoán rất không đồng đều giữa các lớp nhãn. Cụ thể, kiến trúc MobileNetV2 được triển khai với kích thước lô dữ liệu là 64 đối với SVHN và 64 đối với MNIST; trong khi đó, ResNet-18 được áp dụng với kích thước lô dữ liệu lần lượt là 64 đối với CIFAR-10 và 256 đối với CIFAR-100. Trên tất cả các kiến trúc mô hình được sử dụng, hàm chỉnh lưu tuyến tính ReLU được áp dụng làm hàm kích hoạt. Tất cả mô hình được huấn luyện dưới bộ tối ưu SGD. Việc huấn luyện mô hình và mã nguồn được tham khảo từ công trình [15]. Cụ thể, việc huấn luyện mô hình chia làm hai giai đoạn. Ở giai đoạn đầu tiên mô hình sẽ được huấn luyện trên tập huấn luyện đã bị cắt xén, bỏ đi 10000 dữ liệu ở đầu tiên. Sau đó, ở giai đoạn hai, 10000 dữ liệu này sẽ được coi là tập chứa dữ liệu cần quên và sẽ được finetune tiếp trên mô hình đã được huấn luyện phía trên. Điều này sẽ tạo ra một mô hình được huấn luyện trên cả tập dữ liệu ban dầu đã bị cắt xén và finetune trên 10000 dữ liệu còn lại giúp mô hình học tốt hết toàn bộ tập dữ liệu. Việc này tạo sự thuận lợi để thực hiện các thuật toán, cũng như làm giảm chi phí tính toán các thuật toán MU xuống mức thấp.

Đối với các phương pháp yêu cầu dữ liệu phụ trợ, em đã giữ lại 1000 tập dữ liệu chứa dữ liệu cần quên để xây dựng tập dữ liệu phụ trợ này. Cuối cùng, để mô phỏng các cuộc tấn công GIAs thực tế trong môi trường dữ liệu cục bộ không đồng nhất, công trình áp dụng chiến lược phân chia dữ liệu dựa trên phân phối Dirichlet. Concentration parameter của phân phối Dirichlet được thiết lập ở mức $\alpha = 0.1$ đối với CIFAR-100, và $\alpha = 0.5$ đối với tất cả các tập dữ liệu còn lại. Mã nguồn mở của toàn bộ thực nghiệm được công khai và cập nhật tại: `https://github.com/HoangDat2204/Mathematic_Label_Inference_Attack_Machine_Unlearning`

5.3 Thuật toán MU

Nhằm đánh giá mức độ khả thi của các phương pháp GIAs hiện tại trên các thuật toán MU, công trình này đã thiết lập các thuật toán tương tự công trình của Hu và các cộng sự [15] gồm phân mảnh tập huấn luyện và NegGrad.



Hình 5.1: Mô tả quy trình MU bằng cách phân mảnh tập huấn luyện

Cụ thể việc phân mảnh tập huấn luyện là phương pháp trong đó sử dụng lại mô hình đã được huấn luyện trên tập dữ liệu huấn luyện cắt xén ban đầu sau đó finetune tiếp trên tập chứa dữ liệu cần quên nhưng không bao gồm các dữ liệu cần xóa bỏ được mô tả giống hình 5.1. Quá trình tinh chỉnh lại này bắt buộc phải sử dụng cùng một số lượng epoch và các siêu tham số tối ưu hóa hoàn toàn trùng khớp với quá trình huấn luyện mô hình gốc trước đó trên tập chứa dữ liệu cần quên. Đối với NegGrad em thực hiện đánh giá sâu thông qua nhiều thực nghiệm chi tiết và đa dạng, từ đó chứng minh được mối nguy của tấn công GIAs lên phương pháp MU này. Ngoài ra em còn thiết lập thêm các thuật toán ngoài những thuật toán đã được thiết lập trong nghiên cứu [15] bao gồm Retrain from scratch, NegGrad+ và SCRUB. Tất cả các phương pháp trên luôn được đảm bảo mức độ hiệu quả xóa dữ liệu bằng phương pháp đo lường xác suất lỗi để mô phỏng những trường hợp sát với thực tế nhất.

5.4 Tinh chỉnh siêu tham số

Phương pháp có hai tham số α và β luôn được gán cứng lần lượt là 1.0 và 30.0 xuyên suốt quá trình thực nghiệm. Việc cố định hai tham số này nhưng vẫn đạt được kết quả vượt trội thể hiện được tính khái quát và tính ứng dụng được trong nhiều trường hợp của VLI. Điều này khiến VLI trở nên vô cùng thực tế trong các ngữ cảnh MU thực tế.

5.5 Số đo đánh giá

Em sử dụng hai số đo tiêu chuẩn được đề xuất trong nghiên cứu RLU để định lượng và đánh giá hiệu suất của các phương pháp khôi phục nhãn: Độ chính xác cấp lớp (cAcc) và Độ chính xác cấp mẫu (iAcc). Cụ thể, cAcc đo lường tỷ lệ các lớp nhãn được khôi phục chính xác dựa trên sự xuất hiện của chúng trong các lô dữ liệu bị xóa, được tính toán theo công thức:

$$\text{cAcc}(\hat{y}_c, y_c) = \frac{|\hat{y}_c \text{ XNOR } y_c|}{N} \tag{5.1}$$

Trong đó, y_c đại diện cho các lớp nhãn thực tế, $\hat{y}_c$ biểu thị các lớp nhãn được ước lượng bởi phương pháp tấn công, và N là tổng số lượng lớp trong nhiệm vụ phân loại.

Để phân tích mức độ rò rỉ thông tin một cách chi tiết hơn, số đo iAcc được sử dụng để phản ánh tỷ lệ các nhãn riêng lẻ được khôi phục chính xác so với tổng số lượng mẫu dữ liệu, được định nghĩa như sau:

$$\text{iAcc}(\hat{y}_i, y_i) = \frac{|\hat{y}_i \cap y_i|}{m \cdot |\mathcal{B}|} \tag{5.2}$$

Trong đó, y_i biểu thị tập hợp các nhãn thực tế, $\hat{y}_i$ đại diện cho tập hợp các nhãn được ước lượng, m là số lượng chu kỳ huấn luyện cục bộ, và $|\mathcal{B}|$ là kích thước lô dữ liệu. Do đó, iAcc được coi là một số đo quan trọng, phản ánh nguy cơ bảo mật nghiêm trọng hơn so với cAcc nhờ khả năng khôi phục chính xác số lượng cụ thể của từng nhãn dữ liệu.

5.6 Kết quả thực nghiệm trả lời cho câu hỏi nghiên cứu đầu tiên

Trong phần này em chia ra làm hai phần là kết quả thực nghiệm của VLI so với các phương pháp GIAs cơ sở khác trên phương pháp NegGrad thuộc approximate unlearning và phần còn lại là kết quả thực nghiệm tấn công của các phương pháp GIAs hiện tại trên các phương pháp MU còn lại. Việc chia ra làm hai phần giúp có các kết luận khách quan tổng thể trên toàn bộ các phương pháp MU hiện tại mà không bị giới hạn bởi một vài phương pháp MU đã được thực nghiệm.

5.6.1 Kết quả thực nghiệm NegGrad

Để đánh giá một cách chặt chẽ hiệu quả của khung phương pháp VLI và giải quyết câu hỏi nghiên cứu 1, em tiến hành so sánh cách tiếp cận của mình với các phương pháp LDI tiên tiến nhất hiện nay. Các phương pháp cơ sở được lựa chọn bao gồm: ZLG+, LLG+, RLU, ZLG và LLG. Với ZLG+ là phiên bản ZLG tuy nhiên ZLG+ sẽ được sử dụng tập dữ liệu phụ trợ thay vì sử dụng một ảnh dummy để ước tính tham số chuẩn bị cho cuộc tấn công. Ngoài ra dù đề tài hiện tại có đề cập đến phương pháp iRLG nhưng trong thực nghiệm sẽ không cài đặt vì mức độ phức tạp của thuật toán. Theo hiểu biết tốt nhất của em hiện tại, các phương pháp này đại diện cho những kỹ thuật tiên tiến nhất hiện có để trích xuất thông tin nhãn từ gradient của mô hình trong các bối cảnh bảo vệ quyền riêng tư.

Trong thiết lập cơ sở đầu tiên NegGrad với 1 local epoch và 1 batch, khi các cập nhật mô hình phản ánh trực tiếp gradient mất mát của từng mẫu dữ liệu đơn lẻ, phương pháp VLI đề xuất thể hiện hiệu suất cạnh tranh vượt trội, liên tục đạt kết quả tốt nhất ở hầu hết các kịch bản thử nghiệm trên chỉ số iAcc. Đáng chú ý, trên tập dữ liệu MNIST với kiến trúc MobileNetV2, VLI vượt qua tất cả các phương pháp cơ sở ở số đo iAcc với giá trị ấn tượng là 0.731 cao hơn phương pháp đứng thứ hai hơn 11%. Tương tự, trên tập dữ liệu phức tạp về phân phối dữ liệu huấn luyện, có độ phân giải cao SVHN, VLI đã đạt được giá trị iAcc 0.790, đồng thời ghi nhận khả năng khôi phục đáng nể trên CIFAR-10 với kiến trúc ResNet-18

Model	Dataset	BatchSize	Metric	ZLG+	LLG+	RLU	ZLG	LLG	VLI (Ours)
NegGrad with 1 local epochs - 1 batch									
Resnet18	CIFAR10	64	iAcc	0.638	0.743	0.567	0.673	0.736	**0.811**
			cAcc	0.721	0.726	0.685	**0.763**	0.528	0.709
	CIFAR100	256	iAcc	0.331	0.558	0.563	0.543	0.762	**0.801**
			cAcc	0.308	0.309	0.314	0.307	**0.551**	0.494
MobilenetV2	MNIST	64	iAcc	0.558	0.589	0.504	0.587	0.618	**0.731**
			cAcc	0.746	0.747	0.743	**0.764**	0.558	0.698
	SVHN	64	iAcc	0.447	0.483	0.664	0.652	0.710	**0.790**
			cAcc	0.727	**0.733**	0.725	0.734	0.536	0.678
NegGrad with 5 local epochs - 4 batchs									
Resnet18	CIFAR10	64	iAcc	0.736	0.511	0.708	0.701	0.731	**0.827**
			cAcc	0.516	0.463	0.476	0.499	0.523	**0.725**
	CIFAR100	256	iAcc	0.783	0.348	0.773	0.766	0.767	**0.809**
			cAcc	0.538	**0.556**	0.540	0.544	0.556	0.504
MobilenetV2	MNIST	64	iAcc	0.746	0.577	0.678	0.718	0.656	**0.756**
			cAcc	0.633	0.462	0.514	0.523	0.496	**0.698**
	SVHN	64	iAcc	0.781	0.507	0.705	0.697	0.713	**0.796**
			cAcc	**0.750**	0.474	0.508	0.493	0.516	0.681

Bảng 5.1: Kết quả thực nghiệm so sánh hiệu suất khôi phục nhãn giữa phương pháp VLI đề xuất và các phương pháp cơ sở phân tách theo các kịch bản cập nhật cục bộ.

khi đạt iAcc lên tới 0.811 cao hơn rất nhiều so với các phương pháp khác. Kết quả này khẳng định năng lực mạnh mẽ của VLI trong việc trích xuất thông tin nhãn chính xác ngay cả trong các cấu hình mạng diện rộng và môi trường dữ liệu không đồng nhất như SVHN. Mặc dù ở số đo cấp lớp cAcc, VLI ghi nhận kết quả thấp hơn một chút so với một số phương pháp như ZLG+, ZLG hay LLG+ trên một vài cấu hình, tuy nhiên khoảng cách này là không đáng kể và không quá sâu. Ví dụ trên SVHN, cAcc của VLI đạt 0.678 so với 0.733 của LLG+. Sự vượt trội của VLI càng được thể hiện một cách rõ rệt và xuất sắc hơn trong kịch bản NegGrad phức tạp với 5 local epochs - 4 batches. Đây là thiết lập thực tế và thách thức hơn rất nhiều khi các cập nhật cục bộ tích lũy liên tục dẫn đến hiện tượng nhiễu gradient nghiêm trọng và chồng lấn tín hiệu. Bằng cách chứng minh khả năng phục hồi phi thường trước sự chồng lấn gradient lan rộng qua nhiều chu kỳ cục bộ, VLI hoàn toàn thống trị số đo cấp mẫu iAcc trên tất cả các mô hình và tập dữ liệu được đánh giá trong cấu hình này. Cụ thể, trên ResNet-18 huấn luyện trên CIFAR10, VLI đạt iAcc cao nhất với 0.827 và cAcc vượt trội ở mức 0.725, cao hơn tất cả các phương pháp còn lại. Ngay cả với tập dữ liệu nhiều lớp như CIFAR-100, VLI vẫn duy trì vị thế dẫn đầu trong bối cảnh đó, VLI không chỉ duy trì vị thế thống trị tuyệt đối ở

số đo iAcc mà còn ghi nhận một sự ổn định trong chỉ số cAcc trong khi các phương pháp đa số chứng kiến sự giảm mạnh. Cụ thể, trên tập dữ liệu CIFAR-10, cAcc của VLI tăng nhẹ từ 0.709 lên 0.725; trên MNIST ổn định ở mức 0.698 giữ vững độ chính xác cao; và trên SVHN, cAcc của VLI tăng nhẹ từ 0.678 lên 0.681 trong khi các đối thủ khác như LLG+ lao dốc từ 0.733 xuống 0.474, RLU giảm từ 0.725 xuống 0.508 hay ZLG giảm từ 0.734 xuống 0.493 trong cùng tập SVHN. Điểm đặc biệt quan trọng thể hiện trong khi hiệu suất của các phương pháp tiên tiến hiện nay như LLG+ có xu hướng suy giảm nghiêm trọng hoặc không ổn định khi số lượng chu kỳ cục bộ tăng lên, VLI lại cho thấy khả năng duy trì độ chính xác khôi phục ở mức cực kỳ ổn định. Khả năng này trong việc tối ưu hóa độ chính xác dưới tác động của huấn luyện đa chu kỳ đã chứng minh rằng VLI có sự ổn định tốt và sự thích nghi cao cho các trường hợp.

Ngoài thực nghiệm trên, sự bất đồng nhất dữ liệu đại diện cho một thách thức lớn trong việc triển khai MU trong thực tế. Vì dữ liệu người dùng sở hữu thường có sự bất đồng nhất do đó việc yêu cầu xóa dữ liệu cũng sẽ thường nằm trong trường hợp bất đồng nhất trên. Do đó, em đã tiến hành đánh giá chỉ số iAcc của phương pháp VLI so với các phương pháp SOTA dưới nhiều mức độ bất đồng nhất thống kê cục bộ khác nhau, được điều tiết bởi tham số tập trung Dirichlet $\alpha \in \{0.1, 0.5, 1\}$ trong thuật toán NegGrad. Thực nghiệm sử dụng các mô hình đã được huấn luyện tốt thu được từ cấu hình ở phần trước. Cụ thể bao gồm: mạng ResNet-18 huấn luyện trên tập CIFAR-10 và CIFAR-100, cùng mạng MobileNetV2 huấn luyện trên tập MNIST và SVHN. Giá trị α càng nhỏ biểu thị phân phối cục bộ non-IID bị lệch cực kỳ nghiêm trọng, trong khi giá trị α lớn hơn sẽ chỉ ra rằng phân phối dữ liệu đang tiếp cận dần về trạng thái đồng đều IID.

Cụ thể, trong môi trường dữ liệu non-IID cực đoan ($\alpha = 0.1$), khi các nhãn dữ liệu bị xóa thiên vị mạnh về lớp, tín hiệu gradient phân tách tương đối rõ ràng. Trong kịch bản thuận lợi này cho các cuộc tấn công đảo ngược nhãn, VLI thể hiện hiệu suất cực kỳ mạnh mẽ khi đạt vị trí dẫn đầu tuyệt đối trên cấu hình ResNet-18 huấn luyện trên CIFAR-100 với iAcc đạt 0.809. Mặc dù ở một số cấu hình như CIFAR-10 hoặc SVHN, thuật toán LLG hoặc ZLG+ có thể tạm thời chiếm ưu thế, tuy nhiên khoảng

α	ZLG+	LLG+	RLU	ZLG	LLG	VLI (Ours)
Resnet18 trained on Cifar10						
0.1	0.859	0.724	0.851	0.848	**0.875**	0.843
0.5	0.736	0.511	0.708	0.701	0.731	**0.827**
1.0	0.701	0.447	0.668	0.667	0.674	**0.843**
Resnet18 trained on Cifar100						
0.1	0.783	0.348	0.773	0.766	0.767	**0.809**
0.5	0.715	0.373	0.681	0.690	0.665	**0.729**
1.0	**0.677**	0.380	0.632	0.630	0.612	0.673
Mobilenetv2 trained on SVHN						
0.1	**0.886**	0.703	0.833	0.833	0.767	0.810
0.5	0.781	0.507	0.705	0.697	0.713	**0.796**
1.0	0.756	0.491	0.659	0.669	0.638	**0.794**
Mobilenetv2 trained on MNIST						
0.1	0.848	0.723	0.833	**0.860**	0.858	0.824
0.5	0.746	0.577	0.678	0.689	0.656	**0.756**
1.0	**0.788**	0.582	0.633	0.660	0.572	0.733

Bảng 5.2: Đánh giá hiệu năng của các cuộc tấn công khôi phục nhãn trong các cấu hình không đồng nhất dữ liệu khác nhau.

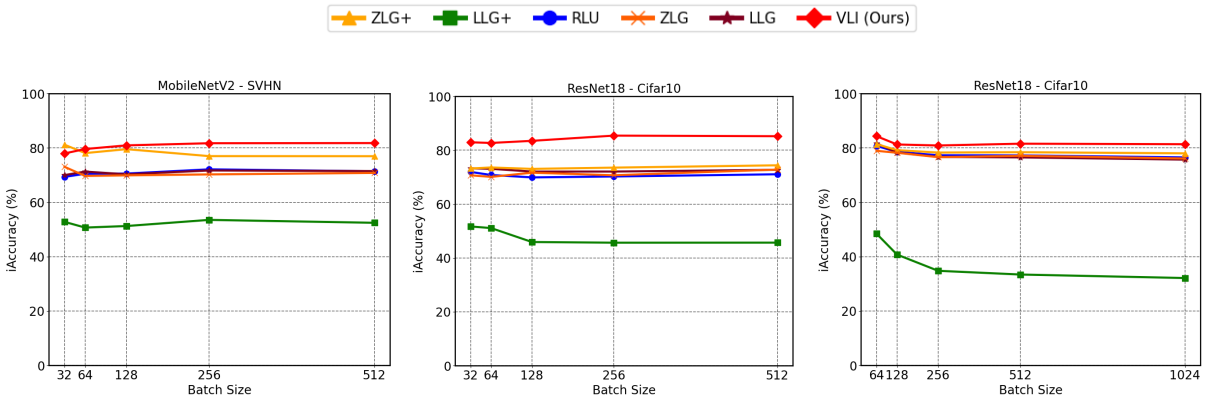
cách hiệu suất giữa VLI và phương pháp đứng đầu là vô cùng hẹp và không đáng kể, chỉ chênh lệch từ 0.03 đến 0.08. Hệ quả này minh chứng rằng VLI không hề bị suy giảm năng lực cốt lõi ngay cả khi đặt trong các kịch bản bất đồng nhất cao độ.

Đặc biệt, khi môi trường phân phối dữ liệu dịch chuyển dần về trạng thái đồng đều hơn ($\alpha = 0.5$ và $\alpha = 1.0$), kịch bản vốn dĩ gây nhiễu loạn tín hiệu gradient nghiêm trọng do sự lan rộng của các thành phần dương trong quá trình huấn luyện đa chu kỳ, VLI lập tức chứng tỏ sự ổn định ngoạn mục. Trong khi hiệu suất khôi phục của tất cả các phương pháp nền tảng lao dốc rất nhanh khi α tăng, cụ thể như: Phương pháp LLG+ trên tập dữ liệu CIFAR-10 bị tụt giảm nghiêm trọng từ 0.724 (tại $\alpha = 0.1$) xuống chỉ còn 0.447 (tại $\alpha = 1.0$) và ZLG giảm từ 0.848 xuống 0.667. Tương tự, trên tập dữ liệu phức tạp hơn là CIFAR-100, phương pháp RLU trải qua một đợt suy giảm hiệu suất rõ rệt từ 0.773 xuống còn 0.632. Ngay cả trên tập SVHN, một thuật toán SOTA khác là ZLG+ cũng bị mất đi lợi thế ban đầu khi giảm từ 0.886 xuống còn 0.756. VLI luôn giữ được hiệu suất cao ví dụ đạt iAcc 0.827 và 0.843 trên CIFAR-10; 0.796 và 0.794 trên SVHN. Tính ổn định đa cấu hình này khẳng định một luận điểm khoa học quan trọng: cơ chế hiệu chỉnh thích ứng của VLI không phụ thuộc vào một

phân phối dữ liệu cố định nào. Bằng việc duy trì vị thế dẫn đầu tuyệt đối khi dữ liệu phân tán đều và đảm bảo biên độ sai lệch tối thiểu khi dữ liệu bị lệch, VLI đã chứng minh thực nghiệm được tính khả thi cao và sự bền vững tuyệt đối khi triển khai trong các hệ thống MU thực tế vốn đầy biến động.

Ngoài ra, để thể hiện tự tổng quát trong trường hợp khi mỗi người dùng khác nhau có thể yêu cầu số lượng dữ liệu cần xóa bỏ khác nhau. Em đã tiến hành thực nghiệm phương pháp VLI so với các phương pháp tấn công cơ sở trong thiết lập NegGrad trên nhiều kích thước lô khác nhau. Cụ thể các kích thước lô {32, 64, 128, 256, 512} sẽ được áp dụng cho hai tập dữ liệu là SVHN và Cifar10, trong khi đó các kích thước lô {64, 128, 256, 512, 1024} sẽ được áp dụng cho tập dữ liệu Cifar100. Có thể thấy được trong kịch bảng nhiều kích thước lô khác nhau, VLI không giảm đi hiệu năng ngược nhưng ngược lại còn tăng nhẹ ở thiết lập MobileNetV2 huấn luyện trên SVHN và Resnet18 huấn luyện trên Cifar10. Mặc dù mô hình Resnet18 huấn luyện trên Cifar100 có giảm nhẹ về độ chính xác dự đoán nhưng vẫn duy trì được vị trí dẫn đầu so với các phương pháp cơ sở. Trong khi đó một vài phương pháp khác thể hiện sự không ổn định rõ rệt khi có sự thay đổi về độ chính xác iAcc trên nhiều kích thước lô khác nhau ví dụ như LLG+ đã giảm từ 0.517 xuống 0.457 trên thiết lập ResNet18-Cifar10 và LLG+ cũng giảm từ0.4847 xuống 0.3214, và RLU suy yếu từ 0.8075 xuống 0.7652 trong thiết lập ResNet18-Cifar100 . Lưu ý trong các thiết lập này là NegGrad luôn giữ số vòng lặp cục bộ là 5 và luôn giữ cho tập cần quên bị chia ra làm 4 phần. Các hyperparameter bao gồm hệ số xóa học và chỉ số α dirichlet được giữ nguyên như thực nghiệm ở thực nghiệm 5.1

Trong khi đó, phương pháp VLI không những thiết lập vị thế dẫn đầu tuyệt đối xuyên suốt tất cả các kịch bản thử nghiệm, mà còn thể hiện một hiện tượng tăng trưởng hiệu suất ngược dòng vô cùng ấn tượng khi kích thước lô tăng lên . Cụ thể, trên cấu hình MobileNetV2 huấn luyện trên SVHN, iAcc của VLI tăng tiến liên tục từ 0.7797 tại kích thước lô 32 lên mức 0.8179 kích thước lô 512, trong khi đối thủ mạnh nhất là ZLG+ lại tụt giảm từ 0.8119 xuống 0.7696. Trên tập CIFAR-10 với mạng ResNet-18, VLI tăng hiệu suất từ 0.8294 lên đỉnh điểm 0.8542 khi kích thước lô mở



(a) MobileNetV2 on SVHN. (b) ResNet18 on CIFAR-10. (c) ResNet18 on CIFAR-100.

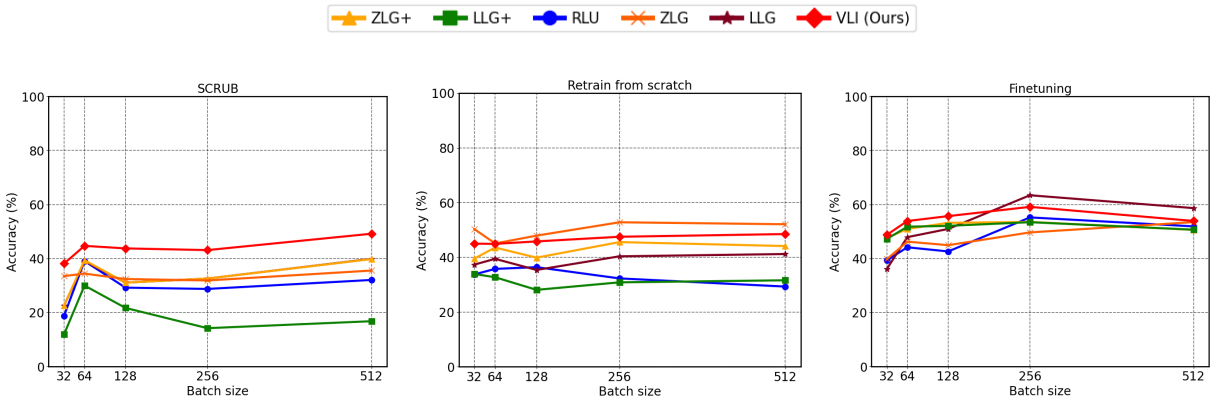
Hình 5.2: Độ chính xác phục hồi nhãn iAcc của các phương pháp phục hồi nhãn khác nhau trên nhiều kích thước batch khác nhau trong thiết lập NegGrad. Các đường nét liền biểu thị hiệu suất tái cấu trúc của phương pháp VLI được đề xuất so với bốn phương pháp tấn công cơ sở trên ba cấu hình, bao gồm: MobileNetV2 trên SVHN, ResNet18 trên CIFAR-10, và ResNet18 trên CIFAR-100.

rộng từ 32 lên 256.

Hệ quả thực nghiệm này mang một ý nghĩa đặc biệt quan trọng trong bối cảnh thực tế của bài toán MU. Trong các hệ thống phân tán thực tế, các yêu cầu xóa bỏ từ người dùng luôn mang tính ngẫu nhiên và biến động cao, đòi hỏi mô hình phải xử lý các lô dữ liệu có quy mô hoàn toàn khác biệt. Việc VLI liên tục duy trì vị trí đứng đầu tuyệt đối, đồng thời tối ưu hóa độ chính xác khôi phục đồng thuận với sự gia tăng của kích thước lô dữ liệu, đã xác thực thực nghiệm rằng cơ chế bóc tách lặp động của phương pháp có khả năng tận dụng cấu trúc thông tin tích lũy trong các lô lớn để khử nhiễu ma trận cơ sở một cách hiệu quả. Điều này biến VLI thành một công cụ đánh giá rủi ro bảo mật đáng tin cậy và sát với các kịch bản triển khai thực tế hiện nay so với các phương pháp khác.

5.6.2 Kết quả thực nghiệm trên các phương pháp MU khác

Nhằm đánh giá khả năng khôi phục nhãn của các phương pháp GIAs hiện nay, em đã tiến hành xem xét trên các phương pháp còn lại. Các thực nghiệm trên đều được thực hiện trên mô hình Resnet18 được huấn luyện trên Cifar10. Tuy nhiên vì chi phí của các phương pháp này tương đối cao ví dụ như retrain from scratch tốn chi phí huấn luyện lại từ đầu trên tập



(a) SCRUB (b) Retrain from scratch (c) Finetuning

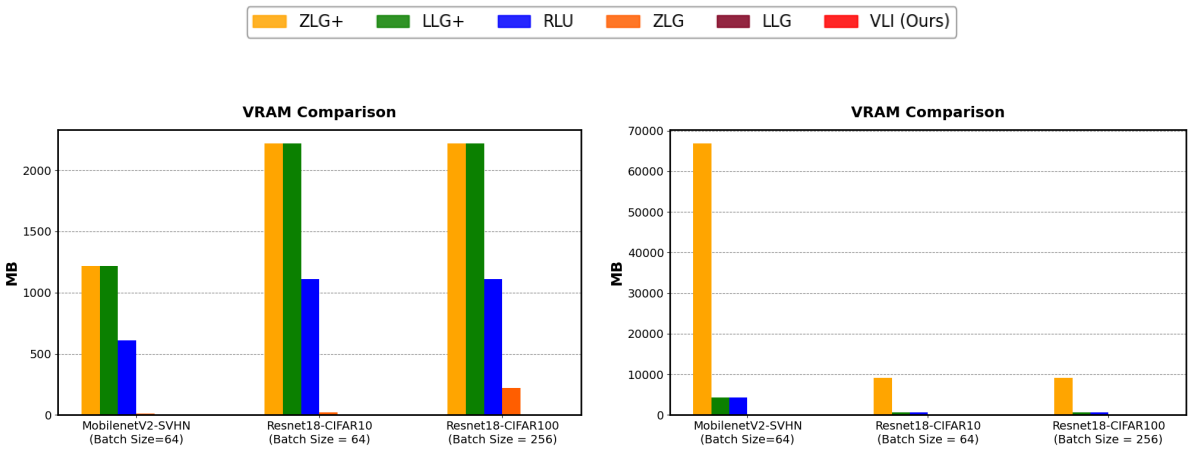
Hình 5.3: Biểu đồ biểu thị độ chính xác khôi phục nhãn iAcc trên nhiều phương pháp MU khác nhau bao gồm Scrub thuộc approximate unlearning, Retrain và Finetuning cùng thuộc exact unlearning. Nhìn chung các phương pháp đều giảm mạnh độ chính xác khôi phục nhãn trên tất cả các phương pháp này

cần giữ lại nên tất cả các phương pháp MU được thực nghiệm trong phần này đều chỉ thực hiện trên 20 vòng lặp sau đó lấy trung bình để ra được kết quả tấn công của từng phương pháp. Tất cả các phương pháp MU được thực nghiệm trong phần này đều được đảm bảo về độ hiệu quả bằng phương pháp đo lường xác suất lỗi để đảm bảo rằng các phương pháp xóa dữ liệu trên giống với các trường hợp thực tế nhất.

Nhìn chung tất cả các phương pháp đều bị giảm về độ chính xác iAcc khi thực nghiệm trên các phương pháp khác. Điều này có thể dễ dàng lí giải được vì các phương pháp này hầu như không tính trực tiếp gradient trên tập cần quên như phương pháp NegGrad trong khi các phương pháp GIAs hiện tại đều phụ thuộc mạnh vào gradient tạo bởi các dữ liệu nhằm khôi phục lại đặc trưng và nhãn. Cụ thể, các phương pháp MU khác đều tồn tại các yếu tố ngẫu nhiên như điểm khởi tạo hay sự xáo trộn ngẫu nhiên tập huấn luyện. Những yếu tố ngẫu nhiên này tích tụ qua hàng nghìn vòng lặp khiến quỹ đạo hội tụ của mô hình sau khi xóa dữ liệu rẽ sang các hướng hoàn toàn khác nhau . Khi kẻ tấn công lấy hiệu số trọng số giữa hai mô hình, thông tin gradient thực tế của mẫu cần xóa bị che lấp hoàn toàn bởi các nhiễu ngẫu nhiên này, dẫn đến việc ước lượng gradient bị sai lệch nghiêm trọng và GIA gần như không thể khôi phục được các đặc trưng hoặc nhãn của dữ liệu gốc.

5.7 Kết quả thực nghiệm trả lời cho câu hỏi nghiên cứu thứ hai

Trong phần này em tiến hành đánh giá hiệu quả của phương pháp VLI so với các phương pháp tấn công cơ sở bằng cách đo lường cả lượng tính toán của GPU (FLOPs) và dung lượng bộ nhớ VRAM tiêu thụ, nhằm giải quyết câu hỏi nghiên cứu thứ hai về hiệu suất tính toán và chi phí tài nguyên. Cụ thể, các số liệu này được ghi nhận nghiêm ngặt trong suốt giai đoạn tấn công thực tế, tính từ thời điểm các phương pháp nhận được hai mô hình trước và sau khi xóa dữ liệu cho đến khi hoàn thành quá trình khôi phục nhãn. Phương pháp VLI đề xuất hoạt động trực tiếp trên các model trước và sau xóa dữ liệu mà không cần bất kỳ bước ước lượng nào trước đó. Ngược lại, các phương pháp cơ sở như RLU, ZLG+ và LLG+ lại phụ thuộc vào giai đoạn tiền ước lượng trước khi chính thức bắt đầu tấn công. Kết quả ở Hình 2 vẫn cho thấy ZLG+, LLG+ và RLU đòi hỏi tài nguyên cực kỳ lớn ngay trong giai đoạn thực thi thực tế, trong khi VLI luôn duy trì được mức chi phí tài nguyên rất thấp.



(a) Floating Point Operations (GFLOPs) (b) GPU VRAM

Hình 5.4: Hình minh họa chi phí tính toán của từng phương pháp khôi phục nhãn trên các kiến trúc mô hình khác nhau dưới thiết lập NegGrad. Cụ thể, em đã đo lường chi phí tài nguyên thông qua số lượng phép tính dấu phẩy động (FLOPs) theo thang đo logarit và dung lượng bộ nhớ VRAM tiêu thụ tính bằng (MB) khi thực hiện các cuộc tấn công trên các mô hình đã được huấn luyện tốt được thảo luận ở phần trước.

Trên thang đo logarit, phép so sánh FLOPs đã làm nổi bật hiệu suất

vượt trội của VLI. Trong khi ZLG+, LLG+ và RLU liên tục đòi hỏi lượng tính toán trong khoảng từ 500 đến hơn 2000 GFLOPs do phải thực hiện quá trình ước lượng trên tập dữ liệu phụ trợ và ZLG vẫn yêu cầu tính trên GPU bằng những ảnh dữ liệu dummy, thì LLG và VLI không yêu phép tính trên GPU , thể hiện một sự sụt giảm khổng lồ về độ phức tạp tính toán. Sự cắt giảm mạnh mẽ này cho phép thực hiện các cuộc tấn công rò rỉ nhãn tức thời, đồng thời loại bỏ hoàn toàn nút thắt cổ chai về thời gian vốn là rào cản lớn đối với các cuộc tấn công rò rỉ dữ liệu nhãn hiện nay. Hiệu quả này còn được thể hiện rõ nét hơn qua chi phí bộ nhớ VRAM. Trong khi các phương pháp cơ sở yêu cầu tới 66902 MB VRAM, đặc biệt là trên tập dữ liệu SVHN, thì VLI tiêu thụ lượng bộ nhớ gần như không đáng kể. Sự chênh lệch này làm nổi bật một hạn chế nghiêm trọng của các phương pháp tấn công dựa trên dữ liệu phụ trợ, khi nhu cầu tài nguyên của chúng leo thang nhanh chóng theo độ phân giải hình ảnh cao hơn, khiến chúng trở nên thiếu thực tế đối với các ứng dụng dành cho người dùng hiện tại thường có độ phân giải cao. Đối với ZLG+, LLG+ và RLU, việc xử lý các đầu vào quy mô lớn như vậy đòi hỏi phải lưu trữ các bản đồ kích hoạt khổng lồ trong quá trình lan truyền ngược lặp đi lặp lại, làm mất đi tính khả thi của chúng. Ngược lại, vì phương pháp giải tích VLI của nghiên cứu hoạt động nghiêm ngặt trên các bản cập nhật của lớp cuối cùng, chi phí tài nguyên của nó hoàn toàn độc lập với kích thước đầu vào và không bị ảnh hưởng bởi các tập dữ liệu phức tạp hoặc có độ phân giải cao. Cuối cùng, VLI đạt được độ chính xác khôi phục nhãn vượt trội với chi phí gần như bằng không, khẳng định vị thế là một mối đe dọa quyền riêng tư chi phí thấp, có tính thực tiễn cao và dễ dàng vận hành trên các phần cứng thương mại thông thường.

Chương 6

Nghiên cứu loại bỏ

6.1 Hiệu chỉnh siêu tham số alpha, beta

Để đánh giá độ nhạy của VLI đối với các siêu tham số, em tiến hành thay đổi lần lượt α và β trên kiến trúc ResNet-18 với hai tập dữ liệu CIFAR-10 và CIFAR-100. Kết quả trong Bảng 6.1 cho thấy VLI tương đối nhạy cảm với sự thay đổi của α. Khi α tăng từ 1 lên 3, iAcc trên CIFAR-10 giảm liên tục từ 0.8334 xuống còn 0.6944. Mức độ ảnh hưởng thể hiện rõ rệt hơn trên CIFAR-100 khi iAcc giảm mạnh từ 0.8594 xuống 0.5264, đồng thời cAcc cũng giảm từ 0.5633 xuống chỉ còn 0.2922. Đặc biệt, hiệu suất đã suy giảm đáng kể ngay khi α tăng từ 1 lên 1.2 trên CIFAR-100. Điều này cho thấy giá trị α quá lớn có thể làm sai lệch quá trình hiệu chỉnh và làm giảm đáng kể khả năng khôi phục nhãn của VLI, nhất là trên các tập dữ liệu có số lượng lớp lớn và phân phối phức tạp.

α	β	**ResNet18 - Cifar10**		**ResNet18 - Cifar100**	
		iAcc	**cAcc**	**iAcc**	**cAcc**
1	30	0.8334	0.7653	0.8012	0.5042
1.2	30	0.7834	0.7769	0.8062	0.4285
1.4	30	0.7694	0.7752	0.7882	0.3789
1.6	30	0.7572	0.7740	0.7347	0.3494
1.8	30	0.7481	0.7599	0.6903	0.3314
2.0	30	0.7375	0.7652	0.6516	0.3213
2.2	30	0.7262	0.7609	0.6192	0.3103
2.4	30	0.7172	0.7596	0.5907	0.3052
2.6	30	0.7091	0.7560	0.5657	0.2999
2.8	30	0.6994	0.7567	0.5452	0.2951
3.0	30	0.6944	0.7564	0.5264	0.2922

Bảng 6.1: Đánh giá độ chính xác (iAcc và cAcc) của ResNet18 trên Cifar10 và Cifar100 khi thay đổi giá trị α và cố định $\beta = 30$.

Ngược lại, kết quả trong Bảng 6.2 cho thấy VLI không quá nhạy cảm với siêu tham số β. Khi β thay đổi từ 0 đến 50, hiệu suất của phương

α	β	**ResNet18 – CIFAR-10**		**ResNet18 – CIFAR-100**	
		iAcc	**cAcc**	**iAcc**	**cAcc**
1	0	0.8422	0.6631	0.7653	0.5273
1	5	0.8684	0.7137	0.7778	0.5489
1	10	0.8669	0.7307	0.7891	0.5742
1	15	0.8544	0.7628	0.7970	0.5965
1	20	0.8334	0.7653	0.8008	0.5687
1	25	0.8156	0.7729	0.7994	0.5351
1	30	0.8334	0.7653	0.8012	0.5042
1	35	0.7838	0.7771	0.8036	0.4958
1	40	0.7709	0.7679	0.8024	0.4831
1	45	0.7569	0.7657	0.8071	0.4748
1	50	0.7425	0.7527	0.8056	0.4622

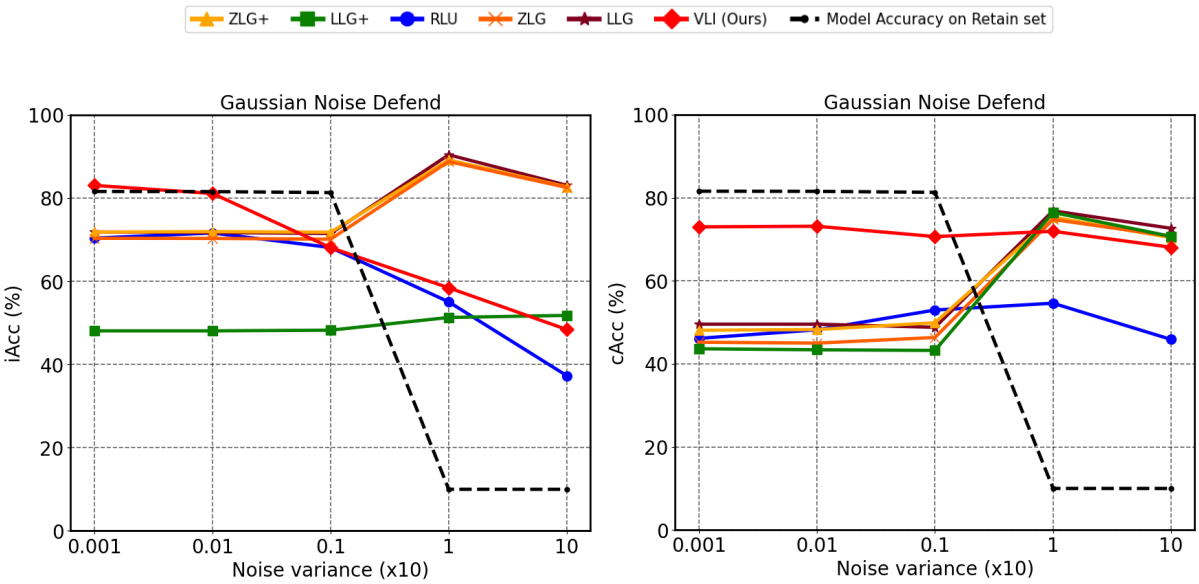
Bảng 6.2: Đánh giá iAcc và cAcc của ResNet18 trên CIFAR-10 và CIFAR-100 khi cố định $\alpha = 1$ và thay đổi β. Các kết quả tại $\beta \in \{0, 15, 30, 50\}$ của CIFAR-100 được thu thập từ thực nghiệm; các giá trị trung gian được ước lượng dựa trên các mốc thực nghiệm liền kề.

pháp có xuất hiện một số dao động nhưng vẫn được duy trì tương đối tốt trong một khoảng giá trị rộng. Trên CIFAR-10, iAcc đạt giá trị cao nhất 0.8684 tại $\beta = 5$ và vẫn duy trì trên 0.81 trong khoảng từ 0 đến 30. Trong khi đó, cAcc tăng từ 0.6631 tại $\beta = 0$ lên 0.7771 tại $\beta = 35$, cho thấy việc thay đổi β không gây ra sự suy giảm nghiêm trọng trên cả hai chỉ số. Trên CIFAR-100, iAcc tăng từ 0.7653 tại $\beta = 0$ lên mức cao nhất 0.8594 tại $\beta = 30$, sau đó chỉ giảm xuống 0.8056 khi $\beta = 50$. Mặc dù cAcc có xu hướng giảm khi β quá lớn, sự thay đổi này vẫn diễn ra từ từ và không làm hiệu suất của VLI sụt giảm đột ngột.

Nhìn chung, kết quả thực nghiệm cho thấy VLI nhạy cảm với α hơn đáng kể so với β. Trong khi việc tăng α làm hiệu suất suy giảm liên tục, đặc biệt trên CIFAR-100, VLI vẫn duy trì khả năng khôi phục tương đối ổn định khi β thay đổi trong một khoảng rộng. Vì vậy, cấu hình $\alpha = 1$ và $\beta = 30$ được lựa chọn làm cấu hình mặc định nhằm đạt được sự cân bằng giữa iAcc và cAcc, đồng thời duy trì hiệu suất tốt trên cả CIFAR-10 và CIFAR-100.

6.2 Đề xuất phương pháp phòng thủ bằng cách thêm một lượng noise vào cập nhật

Để đánh giá khả năng chống lại VLI, em tiến hành bổ sung nhiễu Gaussian với các mức phương sai khác nhau vào cập nhật mô hình. Kết quả cho thấy khi phương sai nhiễu tăng, hiệu suất iAcc của VLI giảm rõ rệt từ khoảng 0.83 xuống còn 0.48. RLU cũng ghi nhận xu hướng tương tự khi iAcc giảm từ khoảng 0.71 xuống 0.37. Nguyên nhân là VLI và RLU phụ thuộc trực tiếp vào kết quả dự đoán cũng như sự dịch chuyển của bias tại lớp cuối. Do độ lớn của dịch chuyển bias tương đối nhỏ, ngay cả một lượng nhiễu Gaussian thấp cũng có thể làm sai lệch tín hiệu này và làm giảm độ chính xác khôi phục nhãn.



(a) iAcc on defend

(b) cAcc on defend

Hình 6.1: Thực hiện phòng thủ bằng cách thêm gausian noise vào trong gradient cập nhật mô hình.

Ngược lại, hiệu suất của ZLG+, LLG+, ZLG và LLG gần như được giữ nguyên, thậm chí còn tăng lên tại một số mức phương sai. Đặc biệt, khi phương sai tăng lên 1, iAcc của ZLG+, ZLG và LLG tăng lên gần 90

Mặc dù bổ sung nhiễu Gaussian có thể làm giảm hiệu suất của VLI và RLU, đường nét đứt màu đen cho thấy độ chính xác của mô hình trên tập dữ liệu giữ lại cũng suy giảm đặc biệt nghiêm trọng. Khi phương sai tăng lên 1, độ chính xác của mô hình giảm mạnh từ khoảng 0.81 xuống chỉ còn

gần 0.1 tức đoán mò và tiếp tục duy trì ở mức rất thấp. Điều này cho thấy lượng nhiễu đủ lớn để phòng thủ hiệu quả cũng đồng thời phá hủy nghiêm trọng khả năng dự đoán của mô hình. Do đó, mặc dù cơ chế bổ sung nhiễu Gaussian có tác dụng nhất định đối với VLI, phương pháp phòng thủ này không thực tế vì phải đánh đổi gần như toàn bộ hiệu năng của mô hình.

Chương 7

Kết luận

7.1 Kết quả đạt được của đề tài

Công trình của em dưới sự hướng dẫn chi tiết và hiệu quả của hai thầy PGS.TS Lê Kim Hùng và ThS. Trần Anh Duy đã hoàn thành trọn vẹn các mục tiêu nghiên cứu đặt ra, giải quyết thành công lỗ hổng bảo mật về nguy cơ rò rỉ thông tin nhãn dữ liệu trong bối cảnh MU . Nghiên cứu đã tiên phong thiết lập và chuẩn hóa một khung thử nghiệm toàn diện đầu tiên để đánh giá rủi ro từ các cuộc tấn công đảo ngược gradient GIAs nhằm mục đích trích xuất phân phối nhãn của tập dữ liệu đã bị xóa bỏ trong môi trường MLaaS . Đóng góp khoa học cốt lõi của công trình là thuật toán đột phá VLI, một giải pháp giải tích cho phép khôi phục với độ chính xác cao thông tin về nhãn từ sự khác biệt tham số giữa mô hình gốc và mô hình sau unlearn mà không cần phụ thuộc vào các điều kiện tiên nghiệm khắt khe như tập dữ liệu phụ trợ hay tốc độ học cục bộ trên thuật toán unlearn NegGrad. VLI vận hành hiệu quả dựa trên giả thuyết phân phối đều của các thành phần gradient âm khi mô hình đã huấn luyện tốt, kết hợp cơ chế kéo dãn thích nghi để khắc phục hiện tượng che lấp thông tin và thuật toán bóc tách lặp động để phân rã một cách hệ thống các đóng góp gradient của từng lớp nhãn . Các thực nghiệm diện rộng trên các kiến trúc mô hình ResNet18 và MobileNetV2 với các tập dữ liệu MNIST, SVHN, CIFAR-10 và CIFAR-100 dưới thiết lập giải học xấp xỉ NegGrad đã chứng minh VLI vượt trội vượt bậc so với các phương pháp SOTA hiện nay ZLG+, LLG+, RLU, LLG, đạt mức cải thiện chỉ số độ chính xác cấp mẫu iAcc lên hơn 10% trong một số kịch bản NegGrad thực tế . Đặc biệt, VLI thể hiện ưu thế tuyệt đối khi chi phí tính toán thực tế FLOPs và dung lượng bộ nhớ VRAM tiêu thụ gần như bằng không do thuật toán hoạt động giải tích trực tiếp trên lớp phân loại cuối cùng độc lập với độ phân giải đầu vào,

loại bỏ hoàn toàn nút thắt tài nguyên của các phương pháp tối ưu hóa lặp truyền thống . Đồng thời, nghiên cứu cũng làm rõ mối đe dọa của các tấn công GIAs lên các cơ chế unlearn khi chứng minh thực nghiệm rằng các phương pháp unlearn sử dụng trực tiếp gradient từ dữ liệu bị xóa để cập nhật mô hình có độ rò rỉ thông tin cao nhất, trong khi các phương pháp exact unlearning như Retrain hoặc approximate unlearning tiên tiến như SCRUB có khả năng chống chịu tấn công tốt hơn nhờ sự tích lũy các yếu tố ngẫu nhiên trong quá trình huấn luyện lại làm mờ nhạt đi vết tích gradient của dữ liệu bị xóa . Cuối cùng, việc công bố mã nguồn mở hoàn chỉnh của đề tài đã tạo một nền tảng thực nghiệm vững chắc để các nhà nghiên cứu tiếp theo dễ dàng tái lặp kết quả và phát triển mở rộng

7.2 Hạn chế của đề tài

Bên cạnh những kết quả xuất sắc đạt được, em cũng thẳng thắn nhìn nhận một số hạn chế kỹ thuật cần được khắc phục trong các nghiên cứu tiếp theo. Hạn chế lớn nhất là hiệu năng khôi phục nhãn của thuật toán VLI tương tự như các phương pháp tấn công đảo ngược gradient khác bị sụt giảm rất mạnh khi đối đầu với các cơ chế unlearning phức tạp có độ ngẫu nhiên cao như exact unlearning như retrain from scratch hoặc approximate unlearning tiên tiến như SCRUB . Nguyên nhân là do các phương pháp giải học này tích lũy nhiều yếu tố ngẫu nhiên từ quá trình khởi tạo trọng số và tối ưu hóa qua hàng nghìn vòng lặp, khiến hiệu số trọng số giữa hai phiên bản mô hình không còn phản ánh trực tiếp gradient sạch của dữ liệu bị xóa mà bị che lấp hoàn toàn bởi nhiễu ngẫu nhiên . Ngoài ra, thuật toán VLI hiện tại đang phụ thuộc chặt chẽ vào việc khai thác thông tin từ các bản cập nhật bias ở lớp kết nối đầy đủ cuối cùng Δb^L. Do đó, tính khả thi và hiệu năng thực tế của phương pháp đối với các kiến trúc mô hình không sử dụng bias lớp cuối, hoặc các tác vụ học máy phức tạp ngoài phân loại hình ảnh như xử lý ngôn ngữ tự nhiên hay dữ liệu dạng bảng vẫn chưa được thử nghiệm và đánh giá một cách sâu sắc trong khuôn khổ khóa luận này

Tiếng Anh

[1] Geng, Jiahui et al. *Towards General Deep Leakage in Federated Learning*. 2022. arXiv: 2110.09074 [cs.LG]. URL: https://arxiv.org/abs/2110.09074.

[2] Nguyen, Thanh Tam et al. "A Survey of Machine Unlearning". In: *ACM Trans. Intell. Syst. Technol.* 16.5 (Sept. 2025). ISSN: 2157-6904. DOI: 10.1145/3749987. URL: https://doi.org/10.1145/3749987.

[3] Carlini, Nicholas et al. "The secret sharer: evaluating and testing unintended memorization in neural networks". In: *Proceedings of the 28th USENIX Conference on Security Symposium*. SEC'19. Santa Clara, CA, USA: USENIX Association, 2019, 267–284. ISBN: 9781939133069.

[4] Feldman, Vitaly. "Does learning require memorization? a short tale about a long tail". In: *Proceedings of the 52nd Annual ACM SIGACT Symposium on Theory of Computing*. STOC 2020. Chicago, IL, USA: Association for Computing Machinery, 2020, 954–959. ISBN: 9781450369794. DOI: 10.1145/3357713.3384290. URL: https://doi.org/10.1145/3357713.3384290.

[5] Mantelero, Alessandro. "The EU Proposal for a General Data Protection Regulation and the roots of the 'right to be forgotten'". In: *Computer Law Security Report* 29 (June 2013), pp. 229–235. DOI: 10.1016/j.clsr.2013.03.010.

[6] Pardau, Stuart L. "The california consumer privacy act: Towards a european-style privacy regime in the united states". In: *J. Tech. L. & Pol'y* 23 (2018), p. 68.

[7] Chen, Min et al. "When Machine Unlearning Jeopardizes Privacy". In: *Proceedings of the 2021 ACM SIGSAC Conference on Computer and Communications Security*. CCS '21. Virtual Event, Republic of Korea: Association for Computing Machinery, 2021, 896–911. ISBN: 9781450384544. DOI: 10.1145/3460120.3484756. URL: https://doi.org/10.1145/3460120.3484756.

[8] Xu, Yi. *Machine Unlearning for Traditional Models and Large Language Models: A Short Survey*. 2024. arXiv: 2404.01206 [cs.LG]. URL: https://arxiv.org/abs/2404.01206.

[9] Sun, Hui et al. "Generative Adversarial Networks Unlearning". In: *IEEE Transactions on Dependable and Secure Computing* 22.5 (2025), pp. 5303–5320. DOI: 10.1109/TDSC.2025.3564992.

[10] Cao, Yinzhi and Yang, Junfeng. "Towards Making Systems Forget with Machine Unlearning". In: *Proceedings of the 2015 IEEE Symposium on Security and Privacy*. SP '15. USA: IEEE Computer Society, 2015, 463–480. ISBN: 9781467369497. DOI: 10.1109/SP.2015.35. URL: https://doi.org/10.1109/SP.2015.35.

[11] Kurmanji, Meghdad et al. "Towards unbounded machine unlearning". In: *Proceedings of the 37th International Conference on Neural Information Processing Systems*. NIPS '23. New Orleans, LA, USA: Curran Associates Inc., 2023.

[12] Chen, Jiaao and Yang, Diyi. "Unlearn What You Want to Forget: Efficient Unlearning for LLMs". In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Ed. by Bouamor, Houda, Pino, Juan, and Bali, Kalika. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 12041–12052. DOI: 10.18653/v1/2023.emnlp-main.738. URL: https://aclanthology.org/2023.emnlp-main.738/.

[13] Thudi, Anvith et al. " Unrolling SGD: Understanding Factors Influencing Machine Unlearning ". In: *2022 IEEE 7th European Symposium on Security and Privacy (EuroSP)*. Los Alamitos, CA, USA: IEEE Computer Society, June 2022, pp. 303–319. DOI: 10.1109/EuroSP53844.2022.00027. URL: https://doi.ieeecomputersociety.org/10.1109/EuroSP53844.2022.00027.

[14] Xu, Heng et al. "Machine Unlearning: A Survey". In: *ACM Comput. Surv.* 56.1 (Aug. 2023). ISSN: 0360-0300. DOI: 10.1145/3603620. URL: https://doi.org/10.1145/3603620.

[15] Hu, Hongsheng et al. " Learn What You Want to Unlearn: Unlearning Inversion Attacks against Machine Unlearning ". In: *2024 IEEE Symposium on Security and Privacy (SP)*. Los Alamitos, CA, USA: IEEE Computer Society, May 2024, pp. 3257–3275. DOI: 10.1109/SP54263.2024.00248. URL: https://doi.ieeecomputersociety.org/10.1109/SP54263.2024.00248.

[16] Chen, Aobo et al. "A survey of security and privacy issues of machine unlearning". In: *AI Mag.* 46.1 (Jan. 2025). ISSN: 0738-4602. DOI: 10.1002/aaai.12209. URL: https://doi.org/10.1002/aaai.12209.

[17] Jiang, Le, Ma, Liyan, and Yang, Guang. *Shadow defense against gradient inversion attack in federated learning*. 2025. arXiv: 2506.15711 [cs.LG]. URL: https://arxiv.org/abs/2506.15711.

[18] Ma, Kailang et al. "Instance-wise Batch Label Restoration via Gradients in Federated Learning". In: *The Eleventh International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=FIrQfNSOoTr.

[19] Geiping, Jonas et al. "Inverting gradients - how easy is it to break privacy in federated learning?" In: *Proceedings of the 34th International Conference on Neural Information Processing Systems*. NIPS '20. Vancouver, BC, Canada: Curran Associates Inc., 2020. ISBN: 9781713829546.

[20] Wainakh, Aidmar et al. "User-level label leakage from gradients in federated learning". In: *arXiv preprint arXiv:2105.09369* (2021).

[21] Gao, Ji et al. "Deletion inference, reconstruction, and compliance in machine (un) learning". In: *arXiv preprint arXiv:2202.03460* (2022).

[22] Mickisch, David et al. "Understanding the decision boundary of deep neural networks: An empirical study". In: *arXiv preprint arXiv:2002.01810* (2020).

[23] Chen, Huancheng and Vikalo, Haris. "Recovering labels from local updates in federated learning". In: *Proceedings of the 41st International Conference on Machine Learning*. ICML'24. Vienna, Austria: JMLR.org, 2024.

[24] Wang, Wei et al. “Label Inference Attacks Against Federated Unlearning”. In: *Knowledge Science, Engineering and Management: 18th International Conference, KSEM 2025, Macao, China, August 4–7, 2025, Proceedings, Part I*. Macao, China: Springer-Verlag, 2025, 1–16. ISBN: 978-981-95-3000-7. DOI: 10.1007/978-981-95-3001-4_1. URL: https://doi.org/10.1007/978-981-95-3001-4_1.

[25] Ginart, Antonio et al. *Making AI Forget You: Data Deletion in Machine Learning*. 2019. arXiv: 1907.05012 [cs.LG]. URL: https://arxiv.org/abs/1907.05012.

[26] Golatkar, Aditya, Achille, Alessandro, and Soatto, Stefano. “ Eternal Sunshine of the Spotless Net: Selective Forgetting in Deep Networks ”. In: *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Los Alamitos, CA, USA: IEEE Computer Society, June 2020, pp. 9301–9309. DOI: 10.1109/CVPR42600.2020.00932. URL: https://doi.ieeecomputersociety.org/10.1109/CVPR42600.2020.00932.

[27] Chen, Kongyang, Huang, Yao, and Wang, Yiwen. “Machine unlearning via GAN”. In: *ArXiv* abs/2111.11869 (2021). URL: https://api.semanticscholar.org/CorpusID:244488551.

[28] Bourtoule, Lucas et al. “Machine Unlearning”. In: *2021 IEEE Symposium on Security and Privacy (SP)*. 2021, pp. 141–159. DOI: 10.1109/SP40001.2021.00019.

[29] Brophy, Jonathan and Lowd, Daniel. “Machine Unlearning for Random Forests”. In: *Proceedings of the 38th International Conference on Machine Learning*. Ed. by Meila, Marina and Zhang, Tong. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 1092–1104. URL: https://proceedings.mlr.press/v139/brophy21a.html.

[30] Hu, Hongsheng et al. *A Duty to Forget, a Right to be Assured? Exposing Vulnerabilities in Machine Unlearning Services*. 2024. arXiv: 2309.08230 [cs.CR]. URL: https://arxiv.org/abs/2309.08230.

[31] Xu, Xiaoyu et al. *Unlearning Isn't Deletion: Investigating Reversibility of Machine Unlearning in LLMs*. 2026. URL: https://openreview.net/forum?id=7cEMkTu7Lf.

[32] Becker, Alexander and Liebig, Thomas. "Evaluating Machine Unlearning via Epistemic Uncertainty". In: *CoRR* abs/2208.10836 (2022). DOI: 10.48550/ARXIV.2208.10836. arXiv: 2208.10836. URL: https://doi.org/10.48550/arXiv.2208.10836.

[33] Cao, Zihao et al. "Machine Unlearning Method Based On Projection Residual". In: *2022 IEEE 9th International Conference on Data Science and Advanced Analytics (DSAA)*. 2022, pp. 1–8. DOI: 10.1109/DSAA54385.2022.10032413.

[34] Liu, Bo, Liu, Qiang, and Stone, Peter. "Continual Learning and Private Unlearning". In: *Proceedings of The 1st Conference on Lifelong Learning Agents*. Ed. by Chandar, Sarath, Pascanu, Razvan, and Precup, Doina. Vol. 199. Proceedings of Machine Learning Research. PMLR, 2022, pp. 243–254. URL: https://proceedings.mlr.press/v199/liu22a.html.

[35] Neel, Seth, Roth, Aaron, and Sharifi-Malvajerdi, Saeed. "Descent-to-Delete: Gradient-Based Methods for Machine Unlearning". In: *Proceedings of the 32nd International Conference on Algorithmic Learning Theory*. Ed. by Feldman, Vitaly, Ligett, Katrina, and Sabato, Sivan. Vol. 132. Proceedings of Machine Learning Research. PMLR, 2021, pp. 931–962. URL: https://proceedings.mlr.press/v132/neel21a.html.

[36] Zhang, Fuyao et al. "Verifiably Forgotten? Gradient Differences Still Enable Data Reconstruction in Federated Unlearning". In: *arXiv preprint arXiv:2505.11097* (2025).

[37] Zhang, Rui et al. "A Survey on Gradient Inversion: Attacks, Defenses and Future Directions". In: *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence, IJCAI-22*. Ed. by Raedt, Lud De. Survey Track. International Joint Conferences on Artificial Intelligence Organization, July 2022, pp. 5678–5685. DOI:

10.24963/ijcai.2022/791. URL: https://doi.org/10.24963/ijcai.2022/791.

[38] Zhu, Ligeng, Liu, Zhijian, and Han, Song. "Deep leakage from gradients". In: *Proceedings of the 33rd International Conference on Neural Information Processing Systems*. Red Hook, NY, USA: Curran Associates Inc., 2019.

[39] Zhu, Junyi and Blaschko, Matthew B. "R-{GAP}: Recursive Gradient Attack on Privacy". In: *International Conference on Learning Representations*. 2021. URL: https://openreview.net/forum?id=RSU17UoKfJF.

[40] Zhao, Bo, Mopuri, Konda Reddy, and Bilen, Hakan. *iDLG: Improved Deep Leakage from Gradients*. 2020. arXiv: 2001.02610 [cs.LG]. URL: https://arxiv.org/abs/2001.02610.

[41] Yin, Hongxu et al. " See through Gradients: Image Batch Recovery via GradInversion ". In: *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Los Alamitos, CA, USA: IEEE Computer Society, June 2021, pp. 16332–16341. DOI: 10.1109/CVPR46437.2021.01607. URL: https://doi.ieeecomputersociety.org/10.1109/CVPR46437.2021.01607.

[42] Dang, Trung et al. "Revealing and protecting labels in distributed training". In: *Proceedings of the 35th International Conference on Neural Information Processing Systems*. NIPS '21. Red Hook, NY, USA: Curran Associates Inc., 2021. ISBN: 9781713845393.

[43] Geiping, Jonas et al. "Inverting Gradients - How easy is it to break privacy in federated learning?" In: *Advances in Neural Information Processing Systems*. Ed. by Larochelle, H. et al. Vol. 33. Curran Associates, Inc., 2020, pp. 16937–16947. URL: https://proceedings.neurips.cc/paper_files/paper/2020/file/c4ede56bbd98819ae6112b20a
Paper.pdf.

[44] Cheng, Tong et al. "EC-LDA: Label Distribution Inference Attack Against Federated Graph Learning with Embedding Compression".

In: *2025 IEEE International Conference on Data Mining (ICDM)*. 2025, pp. 159–168. DOI: 10.1109/ICDM65498.2025.00023.